

分类号: TP391.4
盲审代码:

UDC: 004.8
密级: 公开

硕士学位论文

面向高维医学数据的元启发特征选择 方法研究

学科、专业: 计算机科学与技术
研究方向: 智能计算与数据挖掘
完成日期: 2026 年 3 月 1 日

面向高维医学数据的元启发特征选择方法研究

摘 要

随着生物信息学的快速发展，病理数据的维度迅速增长，高维医疗数据已成为医学研究与临床实践的核心数据基础。但对高维医疗数据的有效分析却面临着特征数量致使计算复杂度剧增、机器学习模型性能劣化、计算资源消耗大等严峻挑战。高维医学特征的有效解析，已成为医学研究与临床实践的关键技术问题。特征选择作为高维数据处理的核心技术，通过筛选原始数据中最具相关性与代表性的特征，从而提高机器学习模型性能，降低计算消耗。元启发算法作为一种有效手段曾被广泛用于特征选择，但是朴素启发式算法面临着诸多问题，诸如开发与探索的平衡问题，早熟收敛问题等。

为了解决元启发算法的这些问题，本论文提出了二种改进型的启发式算法，通过引入针对性的改进机制，解决了两种算法原本的弊端和面对高维医学数据时的不足。

在第三章中，本文针对雾凇算法（RIME）的不足，提出一种改进的雾凇算法（IRIME），它结合信息熵评估策略、随机重启机制和拉格朗日插值方法来克服这些局限。信息熵评估策略通过对特征动态加权增强种群多样性，随机重启机制防止过早收敛，拉格朗日插值方法通过逼近全局最优解加速收敛。在 CEC 2017 测试集上的大量对比实验表明，IRIME 的性能不仅优于原算法 RIME，而且优于其他 7 种知名算法。在 30 维度和 50 维度的弗里德曼检验中分别排名 1.31 和 1.21，大幅领先于其他 8 种算法，其收敛速度更快且稳定性更高。在随后的特征选择实验中，我们宽泛地选取了 8 个中低维度数据集和 4 个高维数据集进行实验，这些数据集均来自真实的临床数据，涵盖多样的数据特性。实验结果显示，IRIME 在适应度值、准确率以及特征子集大小方面，均保持领先地位。特别在高维数据集 ALLAML 和 TOX-171 上，IRIME 分别以 100% 和 88.24% 的分类准确率夺得第一。经实验验证，IRIME 方法在医学数据特征选择场景下展现出优异的实用价值，为医学数据特征选择领域补充了一种可靠的技术手段。

在第四章中，为解决原始哈里斯鹰优化算法（HHO）在迭代过程中易陷入局部最优、种群多样性下降、后期收敛精度不足等问题，提出一种融合多策略的改进哈里斯鹰优化算法（IHHO）。本文首先引入经验互益策略，整合历史种群的有效搜索信息，增强种群个体间的信息交互能力，提升算

法跳出局部最优的潜能；其次设计能量自适应扰动策略，依据猎物逃逸能量动态调整扰动比例，实现全局广域探索与局部精准开发的动态平衡；最后提出精英方差引导开发策略，通过计算精英个体的逐维方差确定局部搜索步长，解决算法后期搜索的局部振荡问题，提升局部优化精度。在 CEC 2020 标准测试函数集，将其与原始 HHO 及另外 5 种经典群智能优化算法进行对比实验。实验结果显示，IHHO 的弗里德曼平均排名为 1.44，显著优于对比算法。将 IHHO 算法应用于高维特征选择问题，选取 8 个高维数据集开展实验，从适应度值、分类准确率与特征压缩效果等维度进行验证。结果显示，IHHO 在 Breast、CNS、Leukemia 等多数高维数据集中取得了更低的平均适应度值与更高的分类准确率，部分数据集分类准确率达到 100%，所选特征子集兼具良好的判别性与泛化性，有效实现了高维特征的精准筛选与冗余特征消除。以上实验表明，所提多策略改进方法能显著提升哈里斯鹰优化算法的综合性能，并在连续函数优化与高维特征选择领域均具有良好的应用效果与推广价值。

关键词： 元启发算法，雾凇算法，哈里斯鹰算法，特征选择，医学数据处理，高维医学数据

STUDY ON META-HEURISTIC FEATURE SELECTION METHODS FOR HIGH-DIMENSIONAL MEDICAL DATA

ABSTRACT

With the rapid development of bioinformatics, the dimensionality of pathological data has grown exponentially, making high-dimensional medical data the core foundation for medical research and clinical practice. However, effective analysis of such data faces severe challenges, including a sharp increase in computational complexity, degradation of machine learning model performance, and excessive consumption of computational resources. Efficient mining of high-dimensional medical features has become a critical technical bottleneck in both academic research and clinical diagnosis.

Feature selection, a core technique in high-dimensional data processing, enhances machine learning performance and reduces computational overhead by screening the most relevant and representative features. While meta-heuristic algorithms have been widely adopted for feature selection, vanilla versions suffer from issues such as the imbalance between exploration and exploitation, as well as premature convergence.

To address these limitations, this thesis proposes two improved heuristic algorithms. By introducing targeted optimization mechanisms, these methods overcome the inherent drawbacks of the original algorithms and their deficiencies when handling high-dimensional medical data.

In Chapter 3, an Improved RIME (IRIME) is proposed to address the shortcomings of the original RIME algorithm. IRIME integrates an information entropy evaluation strategy, a random restart mechanism, and Lagrange interpolation to overcome these limitations. The information entropy strategy enhances population diversity through dynamic feature weighting, the random restart mechanism prevents premature convergence, and the Lagrange interpolation method accelerates convergence by approximating the global optimal solution. Extensive comparative experiments on the CEC 2017 test suite demonstrate that IRIME outperforms the original RIME and seven other well-known algorithms. In the Friedman test, IRIME ranked 1.31 and 1.21 for 30 and 50 dimensions respectively, significantly leading the other eight algorithms with faster convergence

and higher stability. Subsequent feature selection experiments using eight low-to-medium dimensional datasets and four high-dimensional datasets-all derived from real clinical data-showed that IRIME maintains a leading position in fitness values, accuracy, and feature subset size. Notably, on the high-dimensional datasets ALLAML and TOX-171, IRIME achieved first place with classification accuracies of 100% and 88.24%, respectively. Experimental results verify that the IRIME method possesses excellent practical value for medical feature selection.

In Chapter 4, an Improved Harris Hawks Optimization (IHHO) algorithm incorporating multiple strategies is proposed to resolve issues in the original HHO, such as susceptibility to local optima, declining population diversity, and insufficient convergence precision in later stages. First, an experience mutual-benefit strategy is introduced to integrate effective search information from historical populations, enhancing information interaction and the potential to escape local optima. Second, an energy adaptive perturbation strategy is designed to dynamically adjust perturbation ratios based on prey escape energy, achieving a balance between global exploration and local exploitation. Finally, an elite variance-guided exploitation strategy is proposed to determine local search step sizes by calculating the dimensional variance of elite individuals, addressing local oscillations and improving precision. Comparative experiments on the CEC 2020 benchmark functions against the original HHO and five other classic swarm intelligence algorithms show that IHHO achieved a Friedman mean rank of 1.44, significantly outperforming competitors. When applied to high-dimensional feature selection across eight datasets, IHHO achieved lower mean fitness values and higher classification accuracies in most sets (such as Breast, CNS, and Leukemia), with some reaching 100% accuracy. The selected feature subsets exhibit strong discriminative power and generalization, effectively achieving precise screening and redundancy elimination. These results indicate that the proposed multi-strategy improvements significantly enhance the comprehensive performance of HHO, offering high application value in both continuous function optimization and high-dimensional feature selection.

KEY WORDS: meta-heuristic, RIME, harris hawks optimization, feature selection, medical data processing, high-dimensional medical data

目 录

摘 要.....	I
ABSTRACT	III
目 录.....	V
图 目 录	VIII
表 目 录	X
1 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	2
1.2.1 雾凇算法国内外研究现状	3
1.2.2 哈里斯鹰算法国内外研究现状	4
1.3 本文组织结构	5
2 相关背景知识介绍	7
2.1 特征选择方法	7
2.1.1 过滤式方法	7
2.1.2 包裹式方法	8
2.1.3 嵌入式方法	8
2.1.4 解的表达	8
2.1.5 适应度函数	9
2.2 雾凇算法	9
2.2.1 算法概述	9
2.2.2 种群初始化	12
2.2.3 软雾凇搜索	12
2.2.4 硬雾凇穿刺	13
2.2.5 积极的贪婪选择机制	13
2.3 哈里斯鹰算法	14
2.3.1 算法概述	14
2.3.2 种群初始化	14
2.3.3 探索阶段	15
2.3.4 从探索到开发的过渡阶段	15

2.3.5	开发阶段	15
2.3.6	HHO 算法伪代码	16
2.4	本章小结	17
3	基于经验互益与自适应扰动的改进哈里斯鹰特征选择方法	18
3.1	引言	18
3.2	算法介绍	18
3.2.1	信息熵评估策略	18
3.2.2	拉格朗日插值法	20
3.2.3	随机重启机制	21
3.2.4	时间复杂度分析	21
3.3	实验设计	23
3.3.1	基准函数对比实验	23
3.3.2	特征选择应用	29
3.3.3	消融实验	38
3.4	本章小结	41
4	基于多策略改进的哈里斯鹰算法	42
4.1	引言	42
4.2	算法介绍	42
4.2.1	经验互益策略	42
4.2.2	能量自适应柯西-高斯扰动策略	44
4.2.3	精英方差引导开发策略	46
4.2.4	时间复杂度分析	47
4.2.5	算法实现	47
4.3	实验设计	49
4.3.1	基准函数对比实验	49
4.3.2	特征选择应用	54
4.3.3	消融实验	60
4.3.4	参数敏感度实验	61
4.4	本章小结	63
5	总结与展望	65
5.1	全文总结	65
5.2	未来研究展望	65

参考文献	67
------------	----

图 目 录

2-1	雾凇算法流程图	10
2-1	Flowchart of RIME Algorithm	10
2-2	雾凇算法软雾凇搜索和硬雾凇穿刺示意图	13
2-2	Soft-rime search and hard-rime puncture of RIME	13
2-3	HHO 各阶段示意图	14
2-3	All stages of HHO	14
2-4	在硬围攻情况下的矢量示意图	15
2-4	Example of overall vectors in the case of hard besiege	15
3-1	IRIME 工作流程图	22
3-1	Flowchart of IRIME	22
3-2	12 个基准函数上的收敛曲线 (30 维)	24
3-2	Convergence curves on the 12 benchmark functions (30D)	24
3-3	12 个基准函数上的收敛曲线 (50 维)	25
3-3	Convergence curves on the 12 benchmark functions (50D)	25
3-4	12 个基准函数上的箱线图 (30 维)	27
3-4	Boxplots on the 12 benchmark functions (30D)	27
3-5	12 个基准函数上的箱线图 (50 维)	28
3-5	Boxplots on the 12 benchmark functions (50D)	28
3-6	九种算法的弗里德曼检验结果	29
3-6	Friedman test results for the nine algorithms	29
3-7	12 个数据集上的适应度值收敛曲线	34
3-7	Convergence curves of fitness values on 12 datasets	34
3-8	12 个数据集上的对比准确率直方图	35
3-8	Histogram of comparison accuracy on 12 datasets	35
3-9	12 个数据集上的对比特征数量直方图	37
3-9	Histogram of the number of contrasting features on the 12 datasets	37
3-10	IRIME 及其变体的弗里德曼检验结果	38
3-10	Friedman test results for IRIME and its variants	38
4-1	能量自适应柯西-高斯扰动策略示意图	45
4-1	Schematic diagram of the energy adaptive Cauchy-Gaussian perturbation strategy	45
4-2	精英方差引导开发策略示意图	46

4-2	Schematic of the elite variance guided development strategy	46
4-3	CEC 2020 对比实验收敛曲线图 (10 维)	50
4-3	Convergence curve of CEC 2020 comparative experiments (10D)	50
4-4	CEC 2020 对比实验收敛曲线图 (30 维)	50
4-4	Convergence curve of CEC 2020 comparative experiments (30D)	50
4-5	IHHO 与其他 5 种算法在 CEC 2020 测试集上的平均排名 (10 维)	54
4-5	Average ranking of IHHO with other five algorithms on the CEC 2020 test set(10D)	54
4-6	IHHO 与其他 5 种算法在 CEC 2020 测试集上的平均排名 (30 维)	55
4-6	Average ranking of IHHO with other five algorithms on the CEC 2020 test set (30D).....	55
4-7	IHHO 特征选择实验适应度收敛曲线图.....	57
4-7	Fitness convergence curve of IHHO feature selection experiment	57
4-8	IHHO 特征选择实验精确度直方图	58
4-8	Histogram of accuracy for IHHO versus feature selection experiments	58
4-9	IHHO 特征选择实验特征子集大小直方图	59
4-9	Histogram of feature subset size for IHHO feature selection experiment	59

表 目 录

3-1	CEC 2017 测试函数的详细信息	26
3-1	Details of CEC 2017 test suite functions	26
3-2	基准测试中对比算法的参数配置	29
3-2	Parameter configuration of the compared algorithms in the benchmark	29
3-3	九种算法在 CEC 2017 函数上的对比结果 (30 维)	30
3-3	Comparison results of nine algorithms on CEC 2017 function (30D)	30
3-4	九种算法在 CEC 2017 函数上的对比结果 (50 维)	31
3-4	Comparison results of nine algorithms on CEC 2017 function (50D)	31
3-5	IRIME 消融实验结果 (50 维)	32
3-5	Results of IRIME ablation experiments (50D)	32
3-6	特征选择中的算法参数设置	33
3-6	Parameters setting for algorithms used in FS	33
3-7	Overview of the datasets	33
3-8	12 个数据集上的适应度值结果	36
3-8	Results of fitness values on 12 datasets	36
3-9	12 个数据集上的准确率结果	36
3-9	Accuracy results on 12 datasets	36
3-10	IRIME 消融实验各策略使用详情	39
3-10	Details of each strategy used in the IRIME ablation experiment	39
3-11	IRIME 及其变体在 CEC 2017 函数上的比较结果 (30 维)	39
3-11	Comparative results of IRIME and its variants on CEC 2017 functions (30D) ...	39
3-12	IRIME 及其变体在 CEC 2017 函数上的比较结果 (50 维)	40
3-12	Comparative results of IRIME and its variants on CEC 2017 functions (50D) ...	40
4-1	IHHO 对比实验中各算法参数设置表	49
4-1	Parameter settings for each algorithm in the IHHO comparison experiment	49
4-2	CEC 2020 基准函数表	49
4-2	CEC 2020 Benchmark Functions Table	49
4-3	各算法在 CEC 2020 的对比实验结果 (10 维)	52
4-3	Comparative experimental results of each algorithm in CEC 2020 (10D)	52
4-4	各算法在 CEC 2020 的对比实验结果 (30 维)	53
4-4	Comparative experimental results of each algorithm in CEC 2020 (30D)	53
4-5	各算法弗里德曼排名结果 (10 维)	54

4-5	Friedman ranking results for each algorithm (10D).....	54
4-6	各算法弗里德曼排名结果 (30 维)	55
4-6	Friedman ranking results for each algorithm (30D).....	55
4-7	数据集信息汇总	56
4-7	Summary of datasets	56
4-8	IHHO 与其他五种算法适应度值统计结果及 Friedman 排名	60
4-8	Friedman ranking of fitness statistical results between IHHO and other five algorithms	60
4-9	IHHO 与其他五种算法准确率统计结果及 Friedman 排名	61
4-9	Friedman ranking of accuracy statistical results between IHHO and other five algorithms	61
4-10	IHHO 消融实验结果表	62
4-10	Table of results from IHHO ablation experiments	62
4-11	IHHO 算法参数敏感度正交实验方案表 ($L_9(3^4)$)	63
4-11	Orthogonal experiments on parameter sensitivity of IHHO ($L_9(3^4)$)	63
4-12	IHHO 参数敏感度实验结果表	64
4-12	Table of experimental results of IHHO parameter sensitivity	64

1 绪论

1.1 研究背景

生物信息学的快速发展推动病理数据维度呈指数级增长，高维医疗数据已成为医学研究与临床实践的核心数据基础，其丰富信息为精准医疗诊断、个性化治疗提供了重要支撑。但高维医疗数据的分析处理面临显著挑战：特征冗余引发维度灾难，致使计算复杂度剧增、模型性能劣化、数据分析难度提升，且需消耗大量计算资源；同时数据过拟合风险显著升高^[1]。

高维医学特征的有效解析，已成为医学研究与临床实践的关键技术问题。特征选择作为高维数据处理的核心技术，通过筛选原始数据中最具相关性与代表性的特征，在生物信息学及医学研究中可实现疾病生物标志物、基因识别、诊断辅助、治疗结局预测及新型治疗靶点挖掘^[2]。特征选择对于提高机器学习模型性能至关重要^[3]，元启发算法作为一种有效手段曾被广泛用于特征选择。但是朴素启发式算法面临着诸多问题，诸如开发与探索的平衡问题，早熟收敛问题，和参数敏感性等。本论文直接利用这些高维医学数据进行疾病诊断、预后预测等任务时，不仅会产生高昂的计算成本，还会因特征空间的维数灾难导致数据稀疏性加剧，严重影响模型的泛化能力与诊断可靠性^[4]。

特征选择旨在从海量数据中提取有效信息，并且近年来迅速发展的人工智能为医学数据分析提供了强大工具。但在医学数据的模型训练过程中，原始高维特征集中不仅包含与疾病诊断、病理分析相关的关键信息，还混杂着大量冗余特征，如高度相关的临床指标、无生物学意义的噪声特征和无关特征^[5]。这些冗余与无关特征不仅会大幅增加计算开销、延长模型训练周期，更会干扰模型对核心医学规律的学习，导致诊断准确率下降、假阳性率升高，这在医学场景中可能引发严重医疗事故^[6]。因此，高维医学数据的特征选择已成为机器学习在医学领域落地应用的关键预处理技术，其核心目标是在剔除冗余与无关特征的同时，保留最具医学诊断价值、最能反映病理生理机制的核心特征子集^[7]。

特征选择方法可分为过滤式(Filter)^[8]、嵌入式(Embedded)^[9]、包裹式三类(Wrapper)^[10]，三类方法的差异体现在分类器与特征选择流程的融合方式上。过滤式方法^[11]采用相关性、互信息等统计准则完成特征筛选^[12]，该类方法简单高效，能够有效缩减特征子集，但灵活性不足，通常无法解决医学高维数据中特征间复杂的非线性冗余问题。嵌入式方法将特征选择嵌入分类器训练过程，提升了算法交互性，但也增加了模型训练与参数调优的复杂度，在医学数据的小样本场景下易出现过拟合^[13]。包裹式方法^[14]将特征选择转化为搜索问题，通过模型性能指标评估特征子集的优劣。

元启发算法凭借其天然的全局优化特性，与特征选择任务的核心需求高度适配^[15]。元启发算法能够通过模拟自然群体行为高效筛选出低冗余、高判别力的特征子集。为实现复杂高维数据的有效处理，科研人员围绕优化算法的搜索策略展开了大量改进研究，通过融合多策略、增强种群多样性、动态平衡探索与开发过程等方式提升算法优化性能，进而提出了一系列基于元启发算法的特征选择方法^[16-18]。

针对医学高维数据集的特征选择任务，现有元启发算法面临的挑战更为突出^[19]。医学数据的高维性使得搜索空间呈指数级爆炸式增长，加剧了数据稀疏性与基于距离的求解难题；同时，医学特征往往具有强相关性、非线性耦合等特点，导致算法更易陷入局

部最优，难以挖掘到真正具有临床意义的核心特征子集^[20]。具体而言，元启发算法在医学高维特征选择中面临双重核心挑战：一是迭代过程中解的多样性持续衰减，削弱全局优化能力，无法突破医学特征空间中的局部最优陷阱；二是算法性能对人工调优的参数高度敏感，导致性能波动较大，而医学数据的异质性进一步放大了参数依赖性带来的负面影响，降低了算法在不同医学场景下的泛化能力^[21]。

更值得注意的是，在医学数据集的特征选择任务中，启发式算法普遍面临的四大核心难题表现得更为尖锐^[22-24]：(1) 早熟收敛与局部最优：医学高维特征空间的复杂性使得算法更易收敛至次优解，筛选出的特征子集可能包含大量冗余信息，无法准确反映疾病的病理生理机制，影响临床应用价值。(2) 稳定性差：算法结果对初始种群配置、随机种子高度敏感，重复实验的结果波动显著，而医学诊断对模型的稳定性与可靠性要求极高，波动过大的特征选择结果会严重影响诊断一致性。(3) 参数依赖性：算法依赖大量超参数调优，不仅引入主观偏差，还因医学数据的特异性导致最优参数难以迁移，降低了算法在不同疾病数据集、不同医疗机构数据集中的泛化能力。(4) 可扩展性受限：医学超高维场景下搜索空间呈爆炸式增长，算法无法在合理时间内完成收敛，难以满足临床实时诊断的需求。

尽管不少启发式方法在通用数据集上取得良好效果，但在医学高维数据场景中仍存在诸多不足：例如参数设置复杂、泛化能力弱、鲁棒性差，且难以平衡特征降维幅度与临床诊断精度，过度降维可能丢失关键医学特征，导致诊断漏诊，而降维不足则无法解决维数灾难问题。并且无免费午餐定理^[25]从理论上证明：不存在可最优求解所有特征选择问题的通用算法。这一结论在医学数据领域尤为显著，不同疾病的病理机制差异、数据采集技术的多样性，使得单一算法难以适配所有医学高维特征选择场景，亟需针对医学数据的特殊性设计专用优化算法。

1.2 国内外研究现状

近年来，启发式算法已成为机器学习领域的核心优化工具，尤其适用于求解具备大解空间与非确定性多项式困难问题 (NP-hard problem) 特性的复杂优化问题^[26]。这类算法依托创新搜索策略生成近似最优解，在求解效率与场景适应性上普遍优于传统优化方法。按照算法的启发来源划分，启发式算法可归为四大类别^[27]：进化算法^[28]、群智能算法^[29]、物理启发算法与人类行为启发算法^[30]。进化算法受生物进化规律启发，通过交叉、变异、选择、淘汰等操作迭代优化候选解种群，迭代过程中剔除低适应度个体、保留并进化高适应度个体，进而持续提升种群整体适应性。遗传算法^[31]是最具代表性的进化计算方法，同类算法还包括差分进化算法^[32]。群智能算法通过模拟简单个体间的局部交互与自组织行为求解复杂问题，实现群体层面的涌现智能，经典算法包含蚁群优化算法^[33]、粒子群优化算法^[34]，以及近年来提出的麻雀搜索算法^[35]、秃鹰搜索算法^[36]与海鸥优化算法^[37]。物理启发优化算法以能量最小化、力学平衡、热力学过程等基础物理原理构建计算框架，典型算法包括模拟退火算法 SA^[38]、正弦余弦算法 SCA^[39]与水循环算法 WCA^[40]。人类启发算法将人类个体与群体的社会行为、认知过程与决策机制抽象为数学规则，用于求解优化问题，涵盖帝国主义竞争算法^[41]、基于状态的优化算法 SBO^[42]与文化算法 CA^[43]。尽管启发式算法在求解复杂实际问题时面临早熟收敛、高维适应性不足等挑战，但研究者通过多策略融合、参数自适应调整等方式提出了大量改进

变体,显著提升了其在特征选择等任务中的性能。例如, Hu 等人提出自适应粒子群优化算法 (APSO),通过动态调整参数强化算法鲁棒性,为高维特征选择提供了更稳定的求解工具。Tiwarei 等人在传统差分进化算法 (DE) 中融入自适应交叉机制与改进选择策略,有效避免算法早熟收敛,其改进算法在复杂非线性工程优化与高维特征选择任务中均表现优异^[44]。Dhar 等利用斯皮尔曼秩相关系数确定狼群参与对抗学习的权重,加速灰狼优化算法 (GWO) 收敛并提升求解精度,为医学高维特征的冗余剔除提供了新思路^[45]。Peng 提出改进型哈里斯鹰优化算法 (EHHO),针对性解决原算法处理高维复杂任务时的性能缺陷,实验结果验证了其在高维特征选择任务中的有效性^[46]。^[47] 提出改进灰狼算法 (VGWO-AWLO),通过引入速度参数引导搜索并结合自适应权重优化,进一步平衡了算法的探索与开发能力,其性能在高维特征选择实验中优于原始 GWO 及其变体。Deep 等人提出融入分散因子的改进灰狼优化算法 (RWGWO),强化局部搜索能力并优化特征选择的探索开发平衡,在慢性病预测等医学高维数据处理任务中,该算法在特征降维幅度与分类精度上均优于其他自然启发算法^[48]。

此外,Pham 将对抗学习与轮盘赌选择策略融入正弦余弦算法 (SCA),在保留原算法探索 - 开发能力的基础上,显著提升了算法在高维优化问题中的稳定性,为医学高维特征选择提供了更可靠的求解方案^[49]。Zhang 等人提出基于混合数学启发式的自学习迭代贪心算法 (MSIG),融合数学规划、问题专属启发式与自适应学习策略,其在调度优化问题中的高效搜索机制为高维特征空间的寻优提供了借鉴^[50]。Mejiadedios 等人提出基于代理模型的双层进化算法,通过分层优化策略高效逼近复杂问题最优解,其处理高维决策空间的思路对医学高维特征选择具有重要参考价值^[51]。shaheen 等人提出融合局部逃逸策略 (LES) 的改进分数阶开普勒优化器 (FOKO),并在 CEC 2017 测试集与实际工程问题中均展现出优异的高维优化性能,为医学超高维特征选择的效率提升提供了新方向^[52]。Liu 等人提出克里金辅助双种群差分进化算法 (KDPDE),通过融合多样性维持与局部搜索策略求解高计算成本的混合整数约束优化问题,其处理高维约束问题的机制对医学特征选择中的临床约束,如特征临床可解释性方面适配具有启发意义^[53]。Yu 等提出基于团队协作的粒子群优化算法,结合自适应参数调整提升全局搜索与收敛性能,有效克服传统 PSO 在高维空间中的性能衰减问题^[54]。Ozdemir 对海洋捕食者算法进行改进 (STPMPA),其在基准测试与实际应用中展现的高维优化精度与效率,为医学高维特征选择算法的改进提供了参考^[55]。Su 等提出离散自适应灰狼优化算法 (DAGWO),通过改进路径规划与多目标优化策略提升求解性能,其离散化处理与自适应机制对二进制编码的特征选择任务具有直接借鉴价值^[56]。

1.2.1 雾凇算法国内外研究现状

雾凇算法 (RIME) 是 Su 等人近期提出的元启发算法,该算法模拟不同风力条件下软霜与硬霜的生长过程,通过模拟雾凇的凝结、生长与升华机制实现优化搜索^[57]。与蚁群优化算法^[58] 等经典元启发算法相比, RIME 算法具有参数设置简单、流程简洁的优势,同时具备优异的全局优化性能,在多个领域的优化问题中展现出潜力。凭借其出色的基础性能, RIME 算法已获得广泛研究关注,并成功应用于图像处理与工程优化领域。例如, Zhong 将 RIME 算法融合拉丁超立方抽样提出增强型 RIME 算法 (SRIME),显著提升了算法在工程优化任务中的求解精度^[59]。Guo 等人采用改进版 RIME 算法实

现肺癌图像分割，验证了其在医学图像处理中的有效性^[60]。Hosney 将 RIME 与正交学习策略结合，应用于膀胱癌诊断中的特征筛选与模型优化，为医学诊断提供了更精准的支持^[61]。Chen 等提出改进型 RIME 算法 (TERIME)，通过策略融合实现光伏模型的鲁棒参数提取^[62]。Wang 等在 RIME 中嵌入协作与竞争机制，提出 CGWRIME 算法并验证其在工程优化中的优异效果^[63]。Gu 通过多策略改进 RIME 算法，将其成功应用于三维无人水面艇 (USV) 路径规划^[64]。Zheng 提出 RIME 与生物地理学算法的混合模型，显著提升了高精度图像分割的效率与精度^[65]。医学高维特征选择场景，Abu 等通过软硬搜索策略与改进贪心机制提升全局寻优能力、规避局部最优，针对特征选择的二元搜索空间特性，设计二进制改进版 mRIME 并选用四类传递函数，经 CEC 标准测试集与疾病诊断特征选择任务验证，该算法性能优于十种主流优化算法，为多领域复杂优化与特征选择问题提供了高效解决方案^[66]。Wang 提出融合混沌局部搜索、交互机制与改进硬霜冰穿刺机制的多策略 RIME 算法 (MRIME)，经三大公开入侵检测数据集与九个 UCI 数据集验证，该算法在各项评价指标、运行效率及数据适应性上均优于现有方法，在入侵检测特征选择领域具备良好应用潜力^[67]。为解决高维数据下进化特征选择面临的“维数灾难”，Wu 等人提出增强型 RIME 算法 (ERIME)，融合特征信息熵剪枝、DBSCAN 空间聚类粒子进化、粒子删除策略及马尔可夫链蒙特卡洛粒子生成策略，既降低高维计算负担、提升搜索效率，又保障种群粒子质量；经 26 个基准数据集（含 14 个高维数据集）与 7 种主流智能算法对比验证，该算法在收敛精度（较 RIME 提升 79.54%）、分类误差率（较 RIME 降低 98.54%）及特征筛选量（较 RIME 减少 85%）上表现优异，高效破解了高维特征选择难题^[68]。

上述研究充分验证了 RIME 算法在实际场景中的通用求解能力，但现有研究仍存在明显短板：一方面，RIME 算法在特征选择领域的研究较为匮乏，尤其缺乏针对医学高维特征选择场景的专项研究与改进；另一方面，RIME 算法自身存在固有缺陷，包括收敛速度慢、探索与开发能力失衡、局部搜索易陷入早熟收敛等问题，这些缺陷在高维特征空间中会被进一步放大，严重限制了其在医学高维特征选择中的应用潜力。为克服上述缺陷、填补研究空白，本文对 RIME 算法展开深入全面的改进研究，通过融合多策略弥补其性能短板，提升其在医学高维特征选择任务中的优化性能。

1.2.2 哈里斯鹰算法国内外研究现状

哈里斯鹰优化算法 (Harris Hawk Optimization, HHO)，是一种模仿哈里斯鹰 (Harris's hawks) 合作狩猎行为的自然启发式元启发优化技术，该算法在 2019 年由 Heidari 等人于提出^[69]。该算法属于群体智能方法范畴，通过模拟哈里斯鹰的猎物包围、突袭及动态协作策略，构建了自适应的搜索机制，其核心优势在于能够动态平衡全局探索与局部开发过程，有效应对传统基于导数的优化器易陷入局部最优的问题，在复杂优化任务中展现出显著优越性。在实际应用领域，HHO 算法及其变体已取得多项突破：在通信领域，HHO-PAP 变体通过联合功率分配和布局优化，显著提升了无人机辅助可见光通信系统的总速率，成功解决了无线通信中的非凸优化难题^[70]。在医疗领域，HHO + 算法通过优化全 Elman 神经网络 (FENN) 的结构与参数，在心力衰竭监测任务中实现了 79% 的敏感性、78% 的准确率和 76% 的特异性，其增强的搜索空间探索能力超越了传统优化方法，充分展现了自适应优化在医学诊断中的应用潜力^[71]。在医学影像处理领域，自

适应 HHO (AHHO) 算法通过动态调整探索开发平衡策略, 在脑部 MRI 分割任务中树立了新标准, 分割精度与效率均优于传统方法; 此外, HHO 算法的优化能力还扩展到电磁应用领域, 为无线网络中的智能反射表面优化提供了高效解决方案^[72]。在方法学层面, HHO 算法的改进研究也持续推进, 包括结合仿生算法微调预训练模型、利用群体智能进行参数调优, 以及通过 LLaMEA 等框架实现自动元启发演化等, 这些研究不仅增强了 HHO 算法的理论基础, 更拓宽了其在通信、医疗、计算社会科学等多领域的应用场景, 充分验证了其应对复杂优化挑战的能力^[73-75]。

尽管 HHO 算法具备显著优势, 但仍面临多项限制其在医学高维特征选择中广泛应用挑战: 首先是计算复杂度问题, 尤其在处理基因测序、多模态临床数据等超高维任务时, 群体智能算法的迭代搜索过程需要消耗大量计算资源, 严重影响处理效率; 其次, 在 HHOSA^[76] 等混合改进方法中, 多种技术的整合进一步增加了算法的处理时间与实现复杂度; 此外, 在离散化实现 (如 DHHO) 中, 动态网络结构与离散搜索空间的适配性不足, 可能导致算法性能衰减^[77]。在高维任务中, 算法的搜索效率与稳定性仍有较大提升空间。这些问题的解决对于提升 HHO 算法在医学高维特征选择等实际场景中的适用性至关重要, 也是本文展开改进研究的核心出发点。

针对数据分析中冗余无关属性影响预测模型性能的问题, 本文融合粒子群优化 (PSO) 与哈里斯鹰优化 (HHO) 算法, 提出混合 PSO-HHO 包裹式特征选择方法, 以欧氏距离 KNN 分类器筛选最优特征集; 经 UCI 四个标准数据集验证, 该混合算法分类准确率显著优于传统 PSO 与 HHO 算法^[78]。

针对假新闻检测存在的特征冗余、特征选择不佳、分类模型低效等问题, 本文提出数据预处理、语言特征提取、基于哈里斯鹰优化 (HHO) 的特征选择与 CNN-BiLSTM 混合模型分类的四阶段检测方法, 在四个公开数据集上取得优异准确率, 检测性能优于现有主流方法^[79]。

针对 NASA MDP 软件缺陷数据集存在的类别高度失衡、特征冗余等难题, 本文构建了融合高级预处理、二元哈里斯鹰优化 (BHHO) 特征选择与集成学习的分类框架: 通过标准化、鲁棒缩放及 ADASYN 算法处理数据异常与类别不平衡问题, 以 KNN 为评估器完成特征筛选, 并对比测试了随机森林、支持向量机与 Stacking 集成模型; 实验显示 Stacking 模型在部分数据集上性能最优, 但统计检验表明其提升效果并非全部显著, 该集成框架有效提升了软件缺陷预测性能, 同时也为后续研究指明了方向^[80]。

1.3 本文组织结构

本文通过提出两种融合多种策略改进的群智能算法改善特征选择方法, 探讨在医学数据集上的应用。首先, 概述了研究背景与群智能算法对特征选择方法的改进意义, 随后详细介绍了两种所提出的改进算法应用于特征选择的实践。本文的组织结构如下:

(1) 第一章, 绪论: 介绍研究的背景和意义, 概述目前演化算法和特征选择研究进展, 以及雾凇算法和哈里斯鹰算法的研究现状。

(2) 第二章, 相关背景知识介绍: 本章首先介绍特征选择问题, 之后深入介绍原始雾凇算法和原始哈里斯鹰算法的算法原理。

(3) 第三章, 详细介绍多策略融合改进的雾凇算法, 并与多种先进算法在基准函数上做对比实验, 最后通过医学特征选择实验验证其应用价值。

(4) 第四章，本章介绍基于经验交流策略的改进哈里斯鹰优化算法，并设计多个实验验证其性能和在医学特征选择上的应用价值。

(5) 第五章，本章节对全文进行总结，探讨本文提出的两种算法的不足，及对未来研究方向展望。

2 相关背景知识介绍

2.1 特征选择方法

通常，特征选择方法的关键研究内容可归纳为四点：子集生成、子集评估、停止准则及多指标验证。子集生成：由子集生成器在特征空间中遍历生成候选特征子集，其核心是设计高效的搜索策略以降低遍历复杂度，尤其在医学高维场景下，需避免搜索空间爆炸；子集评估：由评估器基于预设指标评估候选子集的优劣，其合理性直接决定特征选择结果的有效性；停止准则：明确算法终止搜索的条件，常见准则包括：候选子集性能达到预设阈值、特征维度满足需求、新增和剔除特征对评估结果无显著影响等；多指标验证：从分类精度、特征降维幅度、计算效率、鲁棒性等多维度验证特征选择方法的性能，全面体现其优越性与适用性。

在特征选择的四大核心环节中，子集生成是决定算法性能的关键，尤其在医学高维特征选择任务中，高效的子集生成策略能有效缓解搜索空间爆炸问题，提升算法的全局寻优能力与收敛效率。因此，本文将重点研究特征选择中的子集生成步骤，旨在通过改进元启发算法，设计适配医学高维场景的高效子集生成策略。

特征选择的核心目的在于，从原始完整特征集合中遴选出符合特定任务要求的最优特征子集，在剔除无关特征与冗余特征的同时，尽可能保留高判别性、具有重要临床意义的关键特征。本质而言，特征选择问题是一类典型的组合优化问题，其搜索空间随特征维度呈指数级增长，在医学超高维数据场景下这一挑战尤为突出。根据特征选择与学习算法的融合机制，现有方法主要分为过滤式、包裹式和嵌入式三大类，三者在原理、性能及适用场景上各有不同^[81]。

2.1.1 过滤式方法

过滤式方法的核心特征是特征子集评估过程独立于具体学习算法^[82]。该类方法通常依赖数据本身的固有特性，如特征间的距离度量、相似度、信息增益、互信息等对特征进行排序筛选，无需调用后续学习器参与评估，因此计算开销小、执行速度快，相较于包裹式和嵌入式方法更具效率优势。在完成特征子集筛选后，再利用该子集训练具体学习器。由于整个特征选择过程与学习器无关，筛选出的特征子集具有较强的通用性和泛化能力，但受限于统计指标的单调性与独立性假设，其对特征间复杂非线性关系的捕捉能力较弱，筛选出的子集在特定学习器上的性能往往低于包裹式和嵌入式方法，尤其在医学高维数据的复杂特征交互场景下，易丢失关键关联信息^[83]。

最新研究方面，Gong 针对现有特征选择算法仅采用单一线性或非线性关联指标评估变量关系、缺乏多样性的缺陷，融合皮尔逊相关系数与归一化互信息构建了新型评估函数 CONMI，并提出算法以筛选与类别变量高相关、特征间低冗余的最优子集；经 20 个数据集、多分类器及多指标验证，该算法最高降维率达 80.04%，在 KNN 与 SVM 上取得最优分类精度，表现出良好的竞争力^[84]。Masood 等人以肝炎患者生存预测为研究目标，采用 Relief、Step Disc、Fisher 三种过滤式特征选择算法搭配 15 种分类器开展实验，通过误差率与准确率评估算法性能，并对比了特征选择算法独立使用及与分类器结合的效果，结果表明该组合方案在患者生存预测上取得了理想的准确率与误差率表现^[85]。

2.1.2 包裹式方法

包裹式方法的核心逻辑是以特定学习器的性能作为特征子集的评估准则^[86]。该方法首先明确后续用于任务建模的学习器，如分类任务中的 K 近邻、逻辑回归等，然后将特征子集在该学习器上的性能表现作为评估指标，通过搜索算法遍历特征空间，最终筛选出使学习器性能最优的特征子集^[87]。由于评估过程与目标学习器深度绑定，包裹式方法总能得到最适配该学习器的特征子集，因此分类精度通常更高，尤其在医学高维特征选择中，能更精准地捕捉与疾病诊断相关的核心特征组合。但该方法需反复调用学习器进行性能评估，计算开销大、时间复杂度高，且对训练数据的依赖性较强，在小样本医学数据场景下易出现过拟合，泛化能力相对较弱^[88]。相关研究中，Liu 针对高维数据隐含复杂关联给特征选择带来的挑战，本文提出关系感知包裹式特征选择方法 ERASE，通过样本图与特征树联合学习样本及特征间的潜在关联，并结合新型关系序列浮动选择策略筛选最优特征子集，在多领域九个数据集上的实验表明该方法性能优于现有主流特征选择方法。Chen 等提出包裹式方法 CSMSVM，将余弦距离引入 SVM，通过优化各向异性 RBF 核形状联合实现特征选择、参数学习与低相关特征剔除，依托贝叶斯理论与迭代算法最大化后验概率，实验表明其用更少特征实现更优模式识别精度^[89]。

2.1.3 嵌入式方法

是将特征选择与学习器训练过程同步进行，两者相互融合、协同优化。该方法在构建学习器的同时完成特征评估与筛选，通过学习器自身的参数学习机制自动识别并保留重要特征，剔除无关特征^[90]。当学习器训练完成时，其对应的特征子集即为最优特征子集。该方法既具备包裹式方法的高精度优势，又兼顾了过滤式方法的效率优势，且对结果的解释性较强。但嵌入式方法的设计与特定学习器深度耦合，通用性较差，泛化能力有限，且在医学超高维数据场景下，其模型训练与参数调优的复杂度会显著增加^[91]。针对不同数据难题，学者们相继提出改进的嵌入式特征选择方案。Liu 等人面向不平衡数据的少数类识别问题，提出加权基尼指数 (WGI) 嵌入式特征选择法，实验证实少量特征筛选时卡方检验、F 统计量性能更优，特征数量增加后该方法表现最佳，且 ROC AUC 对特征数量敏感度较低，F 值需选取 20% 以上特征方可达到优异效果，为实际应用的方法选型提供了参考^[92]。Wang 等人提出无监督特征选择算法 EUFS，该算法无需标签转换，通过稀疏学习直接将特征选择嵌入聚类流程，采用交替方向乘子法求解优化问题，经多组基准数据集实验验证了算法有效性^[93]。Maldonado 等人针对机器学习中类别不平衡与高维性两大核心问题，提出新型嵌入式特征选择方法，该策略结合尺度因子惩罚特征集基数，并适配两种面向不平衡数据的 SVM 模型，通过拟牛顿法与 Armijo 线搜索完成求解，在 12 个高不平衡微阵列数据集上实现了优于主流方法的平均预测性能^[94]。

2.1.4 解的表达

对于每个解，维数等于特征数，每个维度表示对应特征的指数。举个例子，当数据中有 100 个特征时，一个解有 100 个维度。在每个解中，维度被限制在 $[0,1]$ 的范围内。

来确定一个特征是否会被选中，并使用 0.5 的静态阈值，如下式所示：

$$\begin{cases} X_i^d > 0.5 & \text{选择} \\ X_i^d \leq 0.5 & \text{不选择} \end{cases} \quad (\text{公式 2-1})$$

其中 X_i^d 是第 i 个个体的 d 维度。

2.1.5 适应度函数

为验证本文提出的算法在特征选择过程中的优化效果，本文使用使用分类错误率作为目标函数来评价解所选择的特征的性能。目标函数的计算方法如下：

$$Fitness = CEE = \frac{\text{错误的分类数}}{\text{样本总数}} \quad (\text{公式 2-2})$$

其中 CEE 是指 K 最近邻 (k-Nearest Neighbor, KNN) 算法的分类错误率, k 设为 5。KNN 中几个邻居之间的距离使用欧几里德距离计算，定义如下：

$$DE(Y, X) = \sqrt{\sum_{j=1}^{dim} (X^j - Y^j)^2} \quad (\text{公式 2-3})$$

其中 X 和 Y 是指给定实例中的特定特征, dim 是使用的特征总数。对于每个数据集，实例被分为训练样本和测试样本，其中训练样本占比 70%，测试样本占比 30%。训练样本用于 FS 评估，而测试样本在测试阶段被隐藏。为了减少过度拟合问题，我们在文本中采用了 $K = 10$ 的分层交叉验证。交叉验证方法首先将训练样本划分为十倍相同大小。然后用 9 ($K-1$) 个数据集来训练 KNN 分类器，而剩余的 1 个折叠作为验证集。通过替换验证集和训练集，重复 10 次评估过程，记录不同数据轮的结果。

2.2 雾凇算法

2.2.1 算法概述

雾凇算法受雾凇形成这一自然现象的启发^[57]。该算法模拟了不同环境条件下水汽的凝结过程。RIME 框架由四个关键阶段组成：(1) 种群初始化，(2) 软雾凇搜索，(3) 硬雾凇穿刺，以及 (4) 正向贪婪选择。这些阶段共同使算法能够有效地探索和利用解空间。图 2-1 提供了 RIME 工作流程的可视化表示，而相应的算法步骤在算法 2.1 中进行了概述。

figures/Flowchart/RIME-Flowcahrt.png

图 2-1 雾凇算法流程图
Fig. 2-1 Flowcahrt of RIME Algorithm

Algorithm 2.1: Pseudo-code of RIME

```

1 Initialization the population  $R$ ;
2 Get the current optimal agent and its corresponding fitness value;
3 while  $t \leq T$  do
4   Calculate Coefficient of adherence  $E$  by Equation; if  $r_2 < E$  then
5     Update agent location using Algorithm 2.3;
6   if  $r_3 \leq \text{Normalize fitness of } S_i$  then
7     Cross updating between agents using Algorithm 2.2;
8   if  $F(R_i^{\text{new}}) < F(R_i)$  then
9     Update the optimal solution through the positive greedy selection;
10   $t = t + 1$ ;

```

Algorithm 2.2: Hard-rime puncture

Input: Initial parameters t, T, N, Dim

```

1 while  $t \leq T$  do
2   for  $i = 1$  to  $N$  do
3     for  $j = 1$  to  $\text{Dim}$  do
4       Calculate the normalized fitness value of the  $i$ -th agent  $F^{\text{norm}}(R_i)$  ;
5       if  $r_4 < F^{\text{norm}}(R_i)$  then
6         Update the value of the corresponding rime particle by 公式 2-10 ;
7       end
8     end
9   end
10  Refresh the best-performing agent and its fitness ;
11   $t = t + 1$  ;
12 end

```

Algorithm 2.3: Soft-rime search

```

1 Begin with the population initialization ;
2 Select the optimal agent and its corresponding fitness ;
3 while  $t \leq T$  do
4   Calculate the coefficient of adherence  $E$  by Equation 6 ;
5   for  $i = 1$  to  $N$  agents do
6     for  $j = 1$  to  $\text{Dim}$  do
7       if  $x < E$  then
8         Update the value of the corresponding rime particle by 公式 2-6;
9       end
10    end
11  end
12  Refresh the best-performing agent and its fitness ;
13   $t = t + 1$  ;
14 end

```

2.2.2 种群初始化

种群由 n 个代理 S_i 组成，每个代理包含 d 个雾凇粒子 x_{ij} ，如公式 2-4 所定义。因此，种群 R 可以由粒子矩阵完全表征，如公式 2-5 所示。

$$R = \begin{bmatrix} S_1 \\ S_2 \\ \vdots \\ S_i \end{bmatrix}; S_i = \begin{bmatrix} x_{i1} & x_{i2} & \cdots & x_{ij} \end{bmatrix} \quad (\text{公式 2-4})$$

$$R = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1j} \\ x_{21} & x_{22} & \cdots & x_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ x_{i1} & x_{i2} & \cdots & x_{ij} \end{bmatrix} \quad (\text{公式 2-5})$$

2.2.3 软雾凇搜索

有风环境下软雾凇的生长过程随机性较强，雾凇颗粒可在附着物体表面大范围自由分布，并沿固定方向缓慢持续生长。软雾凇搜索阶段示意图如图 2-2 所示。在软雾凇阶段，雾凇粒子的位置由公式 2-6 确定。

$$R_{ij}^{new} = R_{best,j} + r_1 \cdot \cos \theta \cdot \beta \cdot (h \cdot (Ub_{ij} - Lb_{ij}) + Lb_{ij}), r_2 < E \quad (\text{公式 2-6})$$

其中， R_{ij}^{new} 是第 i 个雾凇代理中第 j 个粒子的更新位置， $R_{best,j}$ 表示种群 R 中最佳雾凇代理的第 j 个粒子。方向参数 r_1 ($(-1,1)$ 中的随机值) 和 $\cos \theta$ (公式 2-7) 共同引导粒子运动，并在迭代过程中自适应调整。环境因子 β (公式 2-8) 通过模拟外部影响确保算法收敛，而粘附系数 $h \in (0,1)$ 调节粒子间的距离。

$$\theta = \pi \cdot \frac{t}{10 \cdot T} \quad (\text{公式 2-7})$$

其中 t 表示当前迭代次数， T 是允许的最大迭代次数。

$$\beta = 1 - \left\lceil \frac{w \cdot t}{T} \right\rceil / w \quad (\text{公式 2-8})$$

其中 β 遵循阶梯函数模型， $\lceil \cdot \rceil$ 表示取整。参数 $w = 5$ 控制阶梯分段的数量。控制个体凝聚概率的附着系数 E 随迭代次数增加。

其中 $r_2 \in (0,1)$ 是一个均匀分布的随机变量，它与 E 共同控制粒子的位置更新。完整的软雾搜索方法详见算法 2.3。

$$E = \sqrt{\left(\frac{t}{T}\right)} \quad (\text{公式 2-9})$$

figures/RIME/RIMESoftandhard.png

图 2-2 雾凇算法软雾凇搜索和硬雾凇穿刺示意图
Fig. 2-2 Soft-rime search and hard-rime puncture of RIME

2.2.4 硬雾凇穿刺

在强风条件下，硬雾凇生长比软雾凇呈现出更简单、更规则的模式，具有三个关键特征：(1) 强风使外部影响最小化，导致连贯的单向生长。(2) 均匀的生长方向促进粒子重叠。(3) 与软雾凇一样，硬雾凇粒子在生长过程中会膨胀，增加穿刺概率。RIME 算法吸收了这种穿刺机制，增强了收敛性和跳出局部最优的能力。硬雾凇穿刺阶段示意图如图 2-2 所示。具体实现见算法 2.2，粒子替换公式见公式 2-10。

$$R_{ij}^{new} = R_{best,j}, \quad r_3 < F_{normr}(S_i) \quad (\text{公式 2-10})$$

其中 R_{ij}^{new} 表示更新后粒子的位置，而 $R_{best,j}$ 表示雾凇种群 R 中最优粒子的第 j 个分量。第 i 个智能体的选择概率由其归一化适应度值 $F^{normr}(S_i)$ 给出，并且 r_3 是在 $[-1, 1]$ 内均匀分布的随机变量。

2.2.5 积极的贪婪选择机制

在 RIME 算法中，作者提出了一种新的贪婪选择机制，这种新的侵略性贪婪选择机制参与种群更新，并且能够提高算法的全局探索效率。通常情况，元启发优化算法具有一种贪婪选择机制，在每次更新后都会替换并记录最佳适应度值和最佳个体。其典型思路是将个体的更新适应度值与全局最优解进行比较；如果更新后的值优于当前的全局最优解，则替换最优适应度值，并将该个体记录为最优解。这种操作的优点在于简单且快速，但它对种群的探索 (exploration) 和开发 (exploitation) 并无实质帮助，仅仅起到记录的作用。新机制的具体思路是将更新后个体的适应度值与该个体更新前的适应度值进行比较：如果更新后的适应度值优于更新前的值，则发生替换，同时这两个个体的解也会被替换。一方面，这种机制通过活跃的个体替换，使种群能够持续保有优秀的个体，从而提高全局解的质量。另一方面，由于种群中个体的具体位置在每次迭代中都会发生

显著变化，不可避免地会出现一些比更新前更差的个体，这会对下一次迭代产生负面影响。因此，通过这种操作可以确保种群在每次迭代中都朝着更优的方向进化。

2.3 哈里斯鹰算法

2.3.1 算法概述

哈里斯鹰优化算法 (Harris Hawks Optimization, HHO) 是 Heidari 等人提出的一种新的群智能优化方，它的理论依据来自于自然界中哈里斯鹰群体捕猎行为的复杂过程^[69]。实际捕猎，它会表现出侦察、围捕、追踪、攻击等各种层次的合作模式，依靠不断改变的捕食行为一步步逼近目标。HHO 把这一自然现象用数学建模的方式表达出，在鹰群追逐猎物的时，用互动博弈的方式来引导种群个体在搜索空间里找到最优解并达到精准搜寻的目的。HHO 算法的整体流程如图 2-3 所示。



图 2-3 HHO 各阶段示意图

Fig. 2-3 All stages of HHO

2.3.2 种群初始化

初始化会随机在目标空间中生成 N 个初始化的哈里斯鹰个体。每个个体包含 D 个维度。初始化公式如下：

$$X_{N \times D} = \text{rand}(N, D) \times (UB - LB) + LB \quad (\text{公式 2-11})$$

其中， N 表示哈里斯鹰个体数量， D 表示目标空间的维数， UB 和 LB 分别表示空间的上界和下界， rand 为 $[0,1]$ 之间的随机数。

2.3.3 探索阶段

在 HHO 中，哈里斯鹰在搜索空间内随机寻找猎物。哈里斯鹰的位置更新取决于猎物的位置和其它鹰的位置。根据随机概率 q ，算法采用以下两种等概率策略更新鹰的位置：

$$X(t+1) = \begin{cases} X_{rand}(t) - r_1|X_{rand}(t) - 2r_2X(t)|, & q \geq 0.5 \\ (X_{rabbit}(t) - X_m(t)) - r_3(LB + r_4(UB - LB)), & q < 0.5 \end{cases} \quad (\text{公式 2-12})$$

其中， $X(t+1)$ 为第 $t+1$ 次迭代时鹰的位置， $X_{rabbit}(t)$ 为当前猎物（最优解）的位置， $X_{rand}(t)$ 是当前种群中随机选择的鹰的位置， $X_m(t)$ 是当前鹰群的平均位置。 r_1, r_2, r_3, r_4 和 q 是 $(0,1)$ 范围内的随机数。 LB 和 UB 分别表示搜索空间的上下界。




图 2-4 在硬围攻情况下的矢量示意图

Fig. 2-4 Example of overall vectors in the case of hard besiege

2.3.4 从探索到开发的过渡阶段

HHO 算法通过猎物的逃逸能量 E 实现从全局勘探到局部开发的动态转换。随着迭代次数的增加，猎物的能量逐渐消耗。逃逸能量的数学模型定义为：

$$E = 2E_0 \left(1 - \frac{t}{T}\right) \quad (\text{公式 2-13})$$

其中， E_0 是介于 $(-1,1)$ 之间的初始能量因子。当 $|E| \geq 1$ 时，算法执行勘探阶段，哈里斯鹰在不同区域搜索猎物；当 $|E| < 1$ 时，算法进入局部开发阶段，哈里斯鹰开始包围并攻击猎物。

2.3.5 开发阶段

根据猎物的逃逸行为和鹰的包围策略，开发阶段分为以下四种模式：

- 1) 软包围 (Soft Besiege)：当 $r \geq 0.5$ 且 $|E| \geq 0.5$ 时。此时猎物能量较充沛，试图通过跳跃逃脱，鹰采用缓慢包围策略，消耗猎物能量。

- 2) 硬围攻 (Hard Besiege) : 当 $r \geq 0.5$ 且 $|E| < 0.5$ 时。猎物极度疲劳, 能量很低, 鹰直接进行猛烈突袭。
- 3) 渐进式快速俯冲软包围: 当 $r < 0.5$ 且 $|E| \geq 0.5$ 时。此时猎物还有一定能量, 鹰采用更智能的包围策略。引入莱维飞行 (Lévy flight, LF) 模拟猎物的不规则逃扑路径:

$$Y = X_{rabbit}(t) - E|JX_{rabbit}(t) - X(t)| \quad (\text{公式 2-14})$$

$$Z = Y + S \times LF(D) \quad (\text{公式 2-15})$$

其中 $J = 2(1 - r_5)$ 表示猎物的跳跃强度。若 $F(Y) < F(X(t))$, 则更新位置为 Y ; 否则若 $F(Z) < F(X(t))$, 则更新位置为 Z 。

- 4) 渐进式快速俯冲硬围攻: 当 $r < 0.5$ 且 $|E| < 0.5$ 时。在猎物能量极低时, 鹰群通过减小与猎物平均位置的距离来实施攻击, 同样结合莱维飞行策略来更新位置。

2.3.6 HHO 算法伪代码

HHO 的算法伪代码如算法 2.4 所示。

Algorithm 2.4: Harris Hawks Optimization (HHO)

Input: Population size N , Max iterations T

Output: The best location of rabbit (X_{rabbit})

```

1 Initialize the random population  $X_i(i = 1, 2, \dots, N)$ ;
2 while  $t < T$  do
3   Calculate the fitness of each hawk;
4   Set  $X_{rabbit}$  as the best location;
5   for each hawk ( $X_i$ ) do
6     Update the initial energy  $E_0$  and jump strength  $J$ ;
7     Update the escape energy  $E$  using Eq. (207);
8     if  $|E| \geq 1$  then
9       Update location using Exploration Phase (Eq. 200);
10    else if  $|E| < 1$  then
11      if  $r \geq 0.5$  and  $|E| \geq 0.5$  then
12        Soft Besiege;
13      else if  $r \geq 0.5$  and  $|E| < 0.5$  then
14        Hard Besiege;
15      else if  $r < 0.5$  and  $|E| \geq 0.5$  then
16        Soft Besiege with progressive rapid dives;
17      else if  $r < 0.5$  and  $|E| < 0.5$  then
18        Hard Besiege with progressive rapid dives;
19     $t = t + 1$ ;
20 return  $X_{rabbit}$ 

```

2.4 本章小结

本章围绕特征选择方法与相关优化算法展开背景知识介绍，为后续研究奠定理论基础。在特征选择方法部分，首先明确其核心目标是从原始特征集中筛选最优子集，剔除无关与冗余特征并保留高判别力核心特征，且该问题本质为组合优化问题，在医学超高维数据场景下面临搜索空间爆炸的挑战。随后，介绍了两种基础算法：雾凇算法模拟雾凇形成过程，通过种群初始化、软雾凇搜索、硬雾凇穿刺及正向贪婪选择四阶段平衡探索与开发能力；哈里斯鹰算法模拟鹰群捕猎行为，经勘探阶段、动态过渡及四种开发模式实现精准寻优。两类算法为改进特征选择子集生成策略提供了重要基础。

3 基于经验互益与自适应扰动的改进哈里斯鹰特征选择方法

3.1 引言

在实际工程优化领域，医学特征选择是一类典型的复杂优化问题，其核心在于从高维医学数据中筛选出最具判别力的特征子集，在降低计算复杂度的同时，提升疾病诊断与分类的准确率。这类问题往往具有维度高、特征冗余度大、数据分布复杂等特点，对优化算法的探索能力、收敛速度及稳定性提出了更高要求。现有元启发算法应用于医学特征选择时，常出现特征筛选效率低、分类精度不稳定、难以适配高维医学数据集等问题，亟需一种性能更优的改进型优化算法加以解决。针对原始雾凇算法的不足，结合复杂优化问题与实际医学应用的需求，本章提出一种多策略融合改进的雾凇算法 (IRIME)，通过引入多种改进策略弥补原始算法的缺陷，提升其综合优化性能。为验证 IRIME 算法的有效性与优越性，本章设计了系统性的实验验证方案，涵盖理论函数优化与实际医学特征选择两大场景，并通过消融实验明确各改进策略的单独贡献与协同效应。

本章后续内容将按以下逻辑展开：首先，详细阐述 IRIME 算法的核心改进策略与整体实现流程，明确各策略的作用机制及算法时间复杂度；其次，通过 CEC 2017 基准函数实验，将 IRIME 与多种先进元启发算法进行对比，从收敛速度、解质量、稳定性等维度验证其理论优化性能；再次，将 IRIME 应用于 12 个不同维度的医学数据集特征选择问题，验证其在实际工程场景中的应用价值；最后，通过消融实验剖析各改进策略的作用的重要性，并对本章研究内容进行总结，为后续算法的进一步优化与拓展奠定基础。

3.2 算法介绍

3.2.1 信息熵评估策略

信息熵评估策略是信息论中用于衡量数据不确定性的基本概念。其实质是通过概率分布量化系统中的不确定性或随机性：熵值越高，系统的不确定性越大；反之，熵值越低，系统的确定性越强。在优化问题中，信息熵可动态评估种群多样性，从而在优化过程中实现探索与利用之间的自适应平衡。该策略的具体流程如算法 3.1 进行详情展示。

3.2.1.1 信息熵的数学定义

设离散随机变量 $\mathcal{X}$ 的概率质量函数为 $P(\mathcal{X} = x_k) = p_k$ ，其中 $k = 1, 2, \dots, K$ 。 $\mathcal{X}$ 的信息熵 $H(\mathcal{X})$ 定义为：

$$H(\mathcal{X}) = - \sum_{k=1}^K p_k \log_2 p_k \quad (\text{公式 3-1})$$

其中 $\log$ 表示以 2 为底的对数（熵的单位为比特）或以 e 为底的自然对数（熵的单位为奈特）。

3.2.1.2 评估流程

本文设计了一种名为信息熵评估策略的信息熵驱动动态权重分配策略。该策略可以有效提高启发式算法的收敛效率，其具体步骤如下：

Algorithm 3.1: Information Entropy Evaluation Strategy

Input: Population $X = \{x_1, x_2, \dots, x_n\}$ (population size n , dimension m)
Output: Entropy-optimized population $X^{\text{IE}} = \{x_1^{\text{IE}}, x_2^{\text{IE}}, \dots, x_n^{\text{IE}}\}$

```

1 Initialize weight vector  $w \leftarrow [0]^m$ ;
2 for dimension  $j = 1$  to  $m$  do
3   Compute sum of the  $j$ -th dimension:  $\text{sum}_j = \sum_{i=1}^n x_{ij}$ ;
4   if  $\text{sum}_j = 0$  then
5     ; // Avoid division by zero
6      $p_{ij} \leftarrow 0, \forall i \in [1, n]$ ;
7   end
8   else
9     Compute normalized probability:  $p_{ij} = x_{ij} / \text{sum}_j, \forall i \in [1, n]$ ;
10  end
11  Compute entropy  $E_j$  by Equation 10;
12 end
13 for dimension  $j = 1$  to  $m$  do
14   Compute the weight  $w_j$  by Equation 11;
15 end
16 for individual  $i = 1$  to  $n$  do
17   Update position  $X^{\text{IE}}$  through Equation 12;
18 end
19 return  $X^{\text{IE}}$ 

```

步骤 1：位置概率归一化：对种群中第 j 维特征的位置值进行归一化，并计算该维度上第 i 个个体的变异概率：

$$p_{ij} = \frac{x_{ij}}{\sum_{i=1}^n x_{ij}} \quad (\text{公式 3-2})$$

其中 x_{ij} 表示第 i 个个体在第 j 维的位置， n 是种群大小。

步骤 2：维度熵计算：基于归一化结果，计算第 j 维的信息熵 E_j ：

$$E_j = \begin{cases} 0 & \text{if } \sum_{i=1}^n x_{ij} = 0, \\ -\frac{1}{\ln n} \sum_{i=1}^n p_{ij} \ln p_{ij} & \text{otherwise.} \end{cases} \quad (\text{公式 3-3})$$

其中 $\ln n$ 是确保 $E_j \in [0, 1]$ 的归一化因子。

步骤 3：特征权重分配：基于第 j 维的熵 E_j 计算其权重 w_j ，其中熵越低代表确定性越高，对应越大的权重。

$$w_j = \frac{1 - E_j}{\sum_{k=1}^m (1 - E_k)} \quad (\text{公式 3-4})$$

其中 m 表示特征维度的总数。

步骤 4：更新智能体位置：使用权重 w_j 调整个体位置，生成新的熵优化位置 x_i^{IE} ：

$$x_i^{\text{IE}} = x_i \times w \quad (\text{公式 3-5})$$

其中 $\times$ 表示逐元素相乘, $\mathbf{w} = [w_1, w_2, \dots, w_m]^T$ 是权重向量。

3.2.2 拉格朗日插值法

拉格朗日插值法利用预定义的节点构建目标函数的多项式近似。采用多项式对目标函数进行近似拟合, 通过该插值多项式所求得的最优解, 能够作为原始目标函数最优解的近似替代。当插值节点之间的间距不断缩小时, 多项式对应的最优解将逐步收敛于原函数的最优解。

拉格朗日插值公式表示为:

$$P_n(x) = \sum_{j=1}^n y_j \left(\prod_{\substack{i=1 \\ i \neq j}}^n \frac{x - x_i}{x_j - x_i} \right) \quad (\text{公式 3-6})$$

其中 (x_i, y_i) 表示第 i 个节点的坐标, n 对应所选节点的数量, j 表示一个与 i 不同的索引。当 $n=1$ 时, 得到的表达式是一个常数函数; 当 $n=2$ 时, 得到的多项式是一个线性函数, 对于解决复杂问题, 它与目标函数的相似度不足; 当 $n>4$ 时, 得到的多项式至少是一个三次函数, 其最优解需要大量的计算成本和导数信息, 不适合用于优化。因此, 本文选择 $n=3$, 得到一个多项式。

$$P_3(x) = y_0 \times \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} + y_1 \times \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} + y_2 \times \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} \quad (\text{公式 3-7})$$

设,

$$a_0 = \frac{y_0}{(x_0 - x_1)(x_0 - x_2)}, \quad a_1 = \frac{y_1}{(x_1 - x_0)(x_1 - x_2)}, \quad a_2 = \frac{y_2}{(x_2 - x_0)(x_2 - x_1)} \quad (\text{公式 3-8})$$

$P_3(x)$ 的最优解可轻松得到为

$$x^* = \frac{a_0(x_1 + x_2) + a_1(x_0 + x_2) + a_2(x_0 + x_1)}{2(a_0 + a_1 + a_2)} \quad (\text{公式 3-9})$$

$$X_L = \frac{a_0(X_{(r,t)}(t) + \text{Best}(t)) + a_1(X_{(r,s)}(t) + \text{Best}(t)) + a_2(X_{(r,s)}(t) + X_{(r,t)}(t))}{2(a_0 + a_1 + a_2)} \quad (\text{公式 3-10})$$

$$\begin{cases} a_0 = \frac{f(X_{r3}(t))}{(X_{r3}(t) - X_{r4}(t))(X_{r3}(t) - \text{Best}(t))} \\ a_1 = \frac{f(X_{r4}(t))}{(X_{r4}(t) - X_{r3}(t))(X_{r4}(t) - \text{Best}(t))} \\ a_2 = \frac{f(\text{Best}(t))}{(\text{Best}(t) - X_{r3}(t))(\text{Best}(t) - X_{r4}(t))} \end{cases} \quad (\text{公式 3-11})$$

其中 X_L 表示通过拉格朗日插值得到的新位置, $X_{(r3)}(t)$ 和 $X_{(r4)}(t)$ 表示两个随机选择的个体的位置, $\text{Best}(t)$ 表示当前最优个体的位置。该策略的伪代码如算法 3.2 所示。

Algorithm 3.2: Lagrange Interpolation Method**Input:** Population $P(t) = \{X_1(t), X_2(t), \dots, X_N(t)\}$; current best individual $Best(t)$ **Output:** New position X_L

- 1 Randomly select two distinct individuals $X_{(r3)}(t)$ and $X_{(r4)}(t)$ from $P(t)$;
- 2 Compute coefficients a_0, a_1, a_2 according to Equation 17 and Equation 20 ;
- 3 Update new position X_L through Equation 19 ;

3.2.3 随机重启机制

传统的重启策略通常在预定的迭代次数后触发，无法及时重启表现不佳的个体。这会干扰表现良好个体的搜索过程，同时让过多表现不佳的解使算法陷入次优解。为克服这一局限，我们提出一种更具随机性的重启策略。当迭代次数超过 T_{rand} 时，算法重启按适应度值排名靠后的一半个体。这种方法在保留高质量个体的同时确保刷新表现不佳的解，从而保持收敛精度和速度。此外，随机化的迭代阈值显著增强了种群多样性，有效减轻了次优解的负面影响。随机重启策略正式定义如下：

$$T_{\text{rand}} = T \times \sin(\pi \cdot \text{rand}) \quad (\text{公式 3-12})$$

$$X_i^{\text{inferior}} = \text{lb} \times \text{rand} + (\text{ub} - \text{lb}) \times \text{rand} \times \text{randi}(-1, 1) \quad (\text{公式 3-13})$$

其中 T_{rand} 表示随机化的迭代阈值， X_i^{inferior} 表示第 i 个次优智能体的位置， lb 和 ub 分别表示搜索域的下界和上界。 $\text{randi}(-1, 1)$ 是在 $[-1, 1]$ 内均匀分布的随机变量。

3.2.4 时间复杂度分析

IRIME 算法的整体流程在图 3-1 中进行展示。其伪代码则在算法 3.3 中进行描述。本文设定 N 是种群大小， D 是问题维度， C 是评估函数计算时间。IRIME 算法的时间复杂度包括：参数定义 $O(1)$ 、种群初始化 $O(ND)$ 、信息熵评估 $O(TND)$ 、随机重启机制 $O(TND)$ 、拉格朗日插值 $O(TND)$ 、评估函数计算 $O(TNC)$ 和种群更新 $O(TND)$ 。总体复杂度为 $O(1) + O(ND) + O(TNC) + 3O(TND)$ 。

figures//Flowchart/IRIME 流程图 _ 横板 _2.png

图 3-1 IRIME 工作流程图
Fig. 3-1 Flowchart of IRIME

Algorithm 3.3: Pseudo-code of IRIME

```

1 Initialization the rime population ;
2 Get the current optimal agent and optimal fitness ;
3 while  $t \leq T$  do
4   Using the random restart mechanism for those who cannot find a better
     solution ;
5   Calculate coefficient of adherence  $E$  by Equation 6 ;
6   if  $r_2 < E$  then
7     | Update rime agent location using Algorithm 2 ;
8   end
9   if  $r_3 < S_i$  then
10    | Cross updating between agents using Algorithm 3 ;
11  end
12  if  $F(R_i^{new}) < F(R_i)$  then
13    | Select the optimal solution and replace suboptimal solution using the positive
       greedy selection ;
14  end
15  Run the Algorithm 6 ;
16  Run the Algorithm 5 ;
17   $t = t + 1$  ;
18 end

```

3.3 实验设计

本节介绍所设计了三个实验：CEC 2017 基准函数对比实验、医学数据集下的特征选择应用实验、和消融实验。分别对 IRIME 的理论性能和应用价值进行验证，并通过消融实验验证所引入策略的合理性与必要性。我们的实验框架采用了严格的评估指标，包括 30 次独立运行的最佳适应度值 (Best)、平均性能 (Mean) 和标准差 (Std)。CEC 2017 测试套件的定义和详细信息见表 3-1。所有实验均在配备英特尔酷睿 i5 - 12600KF 2.50GHz 处理器、16GB 内存、运行 Windows 11 (64 位) 的工作站上进行，使用 MATLAB R2021a。为保证统计可靠性，每个算法独立运行 30 次，每次运行的终止条件为 10000 次函数评估。为确保公平比较，我们保持一致的实验条件：所有算法的种群规模固定为 30，并严格遵循其最初公布的参数设置。

3.3.1 基准函数对比实验

本节基于 CEC 2017 标准测试函数集开展全面对比实验，将本文提出的 IRIME 算法与八种主流先进优化算法进行综合性能评估。由于 F2 函数已被证实存在测试不稳定性，因此将其排除在本次实验之外。具有所有对比算法的参数配置列于表 3-2。研究涵盖三个关键分析维度：(1) 通过迭代曲线进行收敛行为分析。(2) 通过箱线图可视化进行解的稳定性评估。(3) 使用弗里德曼检验进行非参数统计验证。所有实验均在严格控制条件下进行。

3.3.1.1 实验准备

本实验所选取的算法及算法参数设置如表 3-2 所示。本实验所涉及的 CEC 2017 数据集的相关信息在表 3-1 中详细展示。实验的软、硬件环境在 3.3 节进行了详细介绍。

3.3.1.2 收敛曲线分析

根据 30 维上的收敛曲线图 (图 3-2) 和 50 维度上的收敛曲线图 (图 3-3) 得出，在多个函数 (如 F1、F10、F13、F15、F19 和 F22) 上，IRIME 在收敛速度和最优适应度值方面优于其他八种算法。半对数图揭示了三种不同的收敛模式：(1) 初始阶段快速收敛。对于单峰函数 (F1、F5)，与 RIME 和 LSHADE 相比，IRIME 在前 20% 的函数评估次数 (FEs) 内 (例如，F1 在 3000 次 FEs 时) 实现了更低的适应度值，显示出卓越的初始收敛速度。(2) 中后期持续优化。在多峰函数 (F6、F15) 中，IRIME 保持单调改进，而竞争对手则出现振荡或过早停滞。在 5000 - 10000 次 FEs 期间，其平均梯度比 PDO 更陡峭。(3) 在解的质量和稳定性方面，复合函数 (F22、F30) 展示了 IRIME 卓越的持续优化能力，在实现更好的最终解方面始终优于竞争算法。此外，对比实验 (表 3-3 和表 3-4) 的详细数据表明，IRIME 在三个关键指标：最佳适应度 (Best)、平均适应度 (Mean) 和标准差 (Std) 上始终优于 RIME、LSHADE、BDA、BWO、RSA、SCA、STOA 和 PDO。例如，在 30 维的 F1 函数上，IRIME 实现了 3.95×10^2 的最佳适应度值，远低于其他算法获得的值。同样，对于 50 维的 F4 函数，IRIME 达到了 5.14×10^2 的最佳值，再次证明了其卓越的优化能力。值得注意的是，IRIME 在大多数基准函数上保持始终较低的平均值，这不仅表明其平均性能更好，而且解的稳定性更高。其较小的标准差进一步支持了这一结论，表明结果的离散度显著降低，从而提高了算法的可靠性。




图 3-2 12 个基准函数上的收敛曲线 (30 维)
Fig. 3-2 Convergence curves on the 12 benchmark functions (30D)




图 3-3 12 个基准函数上的收敛曲线 (50 维)
Fig. 3-3 Convergence curves on the 12 benchmark functions (50D)

表 3-1 CEC 2017 测试函数的详细信息
Table 3-1 Details of CEC 2017 test suite functions

序号	函数方程	函数类别	最优值
F1	Shifted and Rotated Bent Cigar Function	Unimodal	100
F3	Shifted and Rotated Zakhov Function	Unimodal	300
F4	Shifted and Rotated Rosenbrock's Function	Multimodal	400
F5	Shifted and Rotated Rastrin's Function	Multimodal	500
F6	Shifted and Rotated Expanded Scaffer's F6 Function	Multimodal	600
F7	Shifted and Rotated Lunacek Bi-Rastrigin Function	Multimodal	700
F8	Shifted and Rotated Non-Continuous Rastrigin's Function	Multimodal	800
F9	Shifted and Rotated Lévy Function	Multimodal	900
F10	Shifted and Rotated Schwefel's Function	Multimodal	1000
F11	Hybrid Function 1 (N=3)	Hybrid	1100
F12	Hybrid Function 2 (N=3)	Hybrid	1200
F13	Hybrid Function 3 (N=3)	Hybrid	1300
F14	Hybrid Function 4 (N = 4)	Hybrid	1400
F15	Hybrid Function 5 (N=4)	Hybrid	1500
F16	Hybrid Function 6 (N=6)	Hybrid	1600
F17	Hybrid Function 7 (N = 5)	Hybrid	1700
F18	Hybrid Function 8 (N=5)	Hybrid	1800
F19	Hybrid Function 9 (N=6)	Hybrid	1900
F20	Hybrid Function 10 (N=6)	Hybrid	2000
F21	Composition Function 1 (N=3)	Composition	2100
F22	Composition Function 2 (N=3)	Composition	2200
F23	Composition Function 3 (N=3)	Composition	2300
F24	Composition Function 4 (N=3)	Composition	2400
F25	Composition Function 5 (N=3)	Composition	2500
F26	Composition Function 6 (N=3)	Composition	2600
F27	Composition Function 7 (N=3)	Composition	2700
F28	Composition Function 8 (N=3)	Composition	2800
F29	Composition Function 9 (N=3)	Composition	2900
F30	Composition Function 10 (N=3)	Composition	3000

3.3.1.3 箱线图分析

图 3-4 和图 3-5 分别展示了 30 维和 50 维的箱线图。在大多数基准函数中，IRIME 的箱线图始终显示出较低的中位数和较窄的四分位距，表明其性能更好且更稳定。例如，在 F1 函数中，IRIME 的中位数结果远低于 RIME 和 LSHADE 等竞争算法，这表明 IRIME 能更稳定地收敛到更优解。此外，其较小的四分位距表明结果的离散度较低，反映出高稳定性。在高维的 F4 函数中，IRIME 也表现出色，其箱线图的整体位置低于大多数其他算法，进一步证明了其在复杂高维环境中进行高效优化的能力。此外，在不同的基准函数中，IRIME 的箱线图始终表现出类似的优势特征，而一些算法（如 BDA 和 RIME）在多个函数中表现不佳，表现为中位数较高或离散度较大。总体而言，IRIME 在 CEC 2017 基准测试集上表现出强大的优化性能和稳健的稳定性，在低维和高维情况下均表现出色。这些结果凸显了其与其他竞争算法相比的明显优势。

3.3.1.4 弗里德曼统计检验

CEC 2017 的弗里德曼统计结果表明，所提出的算法具有明显优势。在 30 维测试中，IRIME 在大多数函数（如 F1、F3、F5）上获得了顶级排名，最终总排名为 1.31，如图




图 3-4 12 个基准函数上的箱线图 (30 维)
Fig. 3-4 Boxplots on the 12 benchmark functions (30D)




图 3-5 12 个基准函数上的箱线图 (50 维)
Fig. 3-5 Boxplots on the 12 benchmark functions (50D)

表 3-2 基准测试中对比算法的参数配置

Table 3-2 Parameter configuration of the compared algorithms in the benchmark

算法	参数设定
IRIME	$w = 5$
RIME	$w = 5$
LSHADE	$p_best_rate = 0.11$; $arc_rate = 2.6$; $memory_size = 6$; $NP_min = 4$
BDA	$w \in [0.5, 0.9]$
BWO	$W_f \in [0.1, 0.5]$
RSA	$\alpha = 0.1$; $\beta = 0.005$
SCA	$C_1 \in [0, 2]$; $C_2 \in [0, 2]$; $C_3 \in [0, 2]$
STOA	$S_a \in [0, 2]$; $b = 1$
PDO	$\rho = 0.005$; $epsPD = 0.1$

3-6 所示，显著优于 BDA（排名：9.00）等算法。同样，在 50 维测试中，它在多个函数（如 F1、F4、F11）上表现出色，总排名为 1.21，超过了大多数竞争对手。值得注意的是，IRIME 在不同维度上始终保持高性能，而像 BDA 这样的算法在大多数情况下排名较差。这些结果强调了我们的算法在 CEC 2017 测试集上具有卓越的优化能力，能够提供更稳定、更准确的解，并具有显著的性能优势。

figures/Ftest/Ftest-dim30-dim50.pdf

图 3-6 九种算法的弗里德曼检验结果

Fig. 3-6 Friedman test results for the nine algorithms

3.3.2 特征选择应用

本节旨在通过选择医学特征选择（FS）问题作为案例，提升 IRIME 在工程问题中的清晰度和有效性，以评估其优化性能。为确保全面评估，我们将所提方法与七种先进的元启发算法进行比较：RIME、AOA、BWO、WOA、ROA、SCA 和 COA。

3.3.2.1 实验准备

所有参与算法的参数设置均统一，种群规模为 $N=30$ ，每次运行的最大计算预算为 3000 次迭代。算法的参数设置详情严格按照表 3-6 中所列的进行实验。本研究所用的所有实验数据集均来自医学领域，一共包括 8 个中低维度和 4 个高维度数据集，涵盖多样

表 3-3 九种算法在 CEC 2017 函数上的对比结果 (30 维)

Table 3-3 Comparison results of nine algorithms on CEC 2017 function (30D)

Function	Metric	IRIME	RIME	LSHADE	BDA	BWO	RSA	SCA	STOA	PDO
F1	best	3.9536E+02	5.2647E+06	5.4242E+07	8.3562E+10	3.7651E+10	4.2848E+10	1.7636E+10	4.5851E+09	3.7472E+10
	mean	1.2630E+04	1.1814E+07	1.4184E+08	8.3562E+10	5.3274E+10	5.1575E+10	2.1336E+10	9.9804E+09	5.1169E+10
	std	1.8998E+04	8.0266E+06	5.1258E+07	1.2458E+06	6.8511E+09	5.6243E+09	2.5245E+09	4.8163E+09	8.7213E+09
F3	best	8.2299E+03	3.6361E+04	2.6980E+04	2.0708E+08	8.1210E+04	7.8591E+04	6.6386E+04	5.3102E+04	7.2520E+04
	mean	2.1615E+04	8.3219E+04	5.3301E+04	2.0711E+08	8.5214E+04	8.4359E+04	9.6629E+04	8.6975E+04	9.3874E+04
	std	9.4119E+03	2.5552E+04	3.0814E+04	7.1537E+04	3.5034E+03	4.3231E+03	1.7633E+04	1.6677E+04	9.5676E+03
F4	best	4.7010E+02	4.5622E+02	5.1476E+02	3.3625E+04	8.5256E+03	7.0539E+03	1.9858E+03	7.1457E+02	1.2573E+04
	mean	5.1668E+02	5.2012E+02	5.3046E+02	3.3626E+04	1.3771E+04	1.2903E+04	3.4697E+03	1.0213E+03	1.7112E+04
	std	4.1599E+01	2.8219E+01	1.2024E+01	3.0273E+00	2.3685E+03	4.6584E+03	1.5641E+03	2.0769E+02	3.2391E+03
F5	best	5.3285E+02	5.8377E+02	6.6955E+02	1.0973E+03	9.0328E+02	8.5311E+02	7.8762E+02	6.8542E+02	8.2716E+02
	mean	5.9967E+02	6.4155E+02	6.9952E+02	1.0974E+03	9.4670E+02	9.3248E+02	8.2124E+02	7.3588E+02	8.8312E+02
	std	3.6243E+01	3.7195E+01	2.0194E+01	1.9435E-01	1.8460E+01	3.5877E+01	1.9560E+01	3.1438E+01	4.8352E+01
F6	best	6.0493E+02	6.0643E+02	6.0761E+02	7.2477E+02	6.8612E+02	6.8537E+02	6.5310E+02	6.3957E+02	6.7747E+02
	mean	6.1517E+02	6.1974E+02	6.1173E+02	7.2479E+02	6.9374E+02	6.9430E+02	6.6231E+02	6.4952E+02	6.9153E+02
	std	7.8417E+00	1.0925E+01	2.5890E+00	6.6924E-02	4.9400E+00	6.0931E+00	7.3655E+00	6.7059E+00	9.4765E+00
F7	best	7.8787E+02	8.4285E+02	9.2850E+02	1.5434E+03	1.3857E+03	1.2815E+03	1.1524E+03	1.0123E+03	1.2566E+03
	mean	8.5071E+02	8.9660E+02	9.5193E+02	1.5443E+03	1.4315E+03	1.3797E+03	1.2656E+03	1.1486E+03	1.3793E+03
	std	2.5417E+01	4.9745E+01	1.4056E+01	1.5374E+00	2.8622E+01	4.2492E+01	8.1489E+01	7.0323E+01	9.7185E+01
F8	best	8.4677E+02	8.9139E+02	9.6323E+02	1.2873E+03	1.1246E+03	1.1000E+03	1.0598E+03	9.3904E+02	1.0749E+03
	mean	8.8877E+02	9.1929E+02	1.0021E+03	1.2873E+03	1.1437E+03	1.1420E+03	1.0979E+03	9.8960E+02	1.1274E+03
	std	2.9069E+01	2.8160E+01	1.6297E+01	0.0000E+00	1.2953E+01	2.8423E+01	2.1894E+01	2.8649E+01	2.2616E+01
F9	best	1.0263E+03	2.3289E+03	1.1155E+03	1.4602E+04	1.0199E+04	1.0589E+04	5.5744E+03	3.5410E+03	7.0386E+03
	mean	1.8441E+03	3.3495E+03	1.2633E+03	1.5113E+04	1.1876E+04	1.1840E+04	8.6730E+03	6.3974E+03	9.0529E+03
	std	5.2798E+02	8.3314E+02	1.0928E+02	4.9105E+02	8.4573E+02	8.0193E+02	3.6398E+03	1.7711E+03	1.5880E+03
F10	best	4.0571E+03	3.5667E+03	6.7934E+03	1.0152E+04	8.1524E+03	7.8404E+03	8.2932E+03	7.0094E+03	7.0747E+03
	mean	4.9052E+03	5.0016E+03	7.6695E+03	1.0152E+04	8.8377E+03	8.5623E+03	9.0177E+03	7.8949E+03	8.4293E+03
	std	5.0523E+02	8.1336E+02	5.7198E+02	1.9174E-12	3.3010E+02	4.0894E+02	3.5919E+02	4.9143E+02	6.6900E+02
F11	best	1.1582E+03	1.3192E+03	1.3250E+03	6.0091E+08	7.0103E+03	7.9034E+03	3.3435E+03	1.8927E+03	8.4164E+03
	mean	1.2125E+03	1.4018E+03	1.4180E+03	6.0091E+08	8.5338E+03	1.2531E+04	4.5446E+03	3.1640E+03	1.5386E+04
	std	4.5204E+01	8.5198E+01	4.3547E+01	0.0000E+00	1.0129E+03	4.7695E+03	1.0827E+03	1.0173E+03	5.5635E+03
F12	best	4.7278E+05	5.4646E+06	7.5373E+06	2.8660E+10	8.3002E+09	6.9339E+09	2.4024E+09	2.1009E+08	5.6626E+09
	mean	2.6792E+06	1.8208E+07	1.3654E+07	2.8660E+10	1.2638E+10	1.6219E+10	2.9259E+09	3.9737E+08	1.3528E+10
	std	2.2870E+06	1.1207E+07	4.9606E+06	0.0000E+00	2.1516E+09	4.3572E+09	4.3408E+08	2.4760E+08	3.2527E+09
F13	best	2.3495E+03	4.4526E+04	3.8525E+05	4.2961E+10	6.0762E+09	4.9334E+09	5.1236E+08	1.6425E+07	8.7037E+09
	mean	1.5537E+04	3.6796E+05	8.9004E+05	4.2961E+10	8.8544E+09	1.1954E+10	1.5684E+09	1.7393E+08	1.2576E+10
	std	1.4965E+04	5.1697E+05	4.3333E+05	3.9480E+00	2.3263E+09	4.1107E+09	7.8094E+08	1.3380E+08	1.9560E+09
F14	best	5.5721E+03	5.4723E+04	2.2293E+03	1.2163E+09	1.5717E+06	1.6764E+06	2.1133E+05	1.0611E+05	2.2498E+06
	mean	6.2927E+04	2.5410E+05	3.5509E+03	1.2163E+09	5.3556E+06	2.2099E+07	1.4880E+06	8.5560E+05	6.7811E+06
	std	4.9805E+04	1.7104E+05	1.6444E+03	2.9930E-01	3.9970E+06	2.2221E+07	1.6016E+06	1.0907E+06	4.6329E+06
F15	best	1.5589E+03	3.9840E+03	4.2351E+04	6.1107E+09	8.1003E+07	2.8528E+08	8.9639E+06	3.4223E+05	5.5119E+07
	mean	2.5856E+03	3.2942E+04	7.6706E+04	6.1107E+09	3.9529E+08	8.2459E+08	6.2716E+07	4.1439E+07	4.9713E+08
	std	1.3341E+03	2.4738E+04	3.5047E+04	4.6460E-01	1.8894E+08	6.1038E+08	6.6251E+07	7.0899E+07	7.4038E+08
F16	best	2.2792E+03	2.3688E+03	2.9531E+03	2.7095E+04	4.8615E+03	5.2683E+03	4.0189E+03	2.7343E+03	5.0818E+03
	mean	2.6996E+03	2.9473E+03	3.3655E+03	2.7099E+04	5.7998E+03	7.3134E+03	4.2636E+03	3.5017E+03	5.8756E+03
	std	2.7782E+02	3.0953E+02	2.9499E+02	8.3447E+00	4.6480E+02	1.8497E+03	2.1955E+02	5.3859E+02	5.6978E+02
F17	best	1.9059E+03	1.9943E+03	2.1478E+03	2.5735E+05	3.3809E+03	3.3196E+03	2.7286E+03	2.0041E+03	3.2055E+03
	mean	2.2705E+03	2.3762E+03	2.2743E+03	2.5735E+05	4.4576E+03	7.4361E+03	2.9306E+03	2.5984E+03	3.9384E+03
	std	2.5405E+02	2.2414E+02	9.7950E+01	1.1148E-01	1.0298E+03	7.1610E+03	1.5843E+02	3.6943E+02	8.8913E+02
F18	best	7.3706E+04	2.4634E+05	4.2999E+04	4.5513E+09	2.2342E+07	2.2292E+07	2.4640E+06	5.9727E+05	7.4076E+06
	mean	3.5254E+05	1.4304E+06	1.6788E+05	4.5513E+09	5.7045E+07	3.9039E+07	1.2933E+07	7.7296E+06	8.0185E+07
	std	2.7251E+05	1.0249E+06	1.5027E+05	1.9006E-01	3.0557E+07	1.7305E+07	6.9026E+06	8.5404E+06	3.3883E+07
F19	best	2.0139E+03	5.6696E+03	2.7170E+04	6.1916E+09	2.9951E+08	5.4513E+07	2.2061E+07	1.3964E+06	1.5606E+08
	mean	5.5603E+03	2.3595E+04	1.5142E+05	6.1916E+09	6.8647E+08	1.0441E+09	8.5210E+07	2.3373E+07	9.8916E+08
	std	4.3718E+03	1.9609E+04	1.4250E+05	6.5380E-03	2.5981E+08	7.8274E+08	3.6661E+07	3.7532E+07	7.6626E+08
F20	best	2.0928E+03	2.1530E+03	2.3982E+03	5.3274E+03	2.7345E+03	2.7641E+03	2.8366E+03	2.4092E+03	2.8669E+03
	mean	2.3991E+03	2.4809E+03	2.6705E+03	5.3275E+03	3.0333E+03	3.0854E+03	3.0902E+03	2.6749E+03	3.1003E+03
	std	1.7677E+02	2.7066E+02	1.4397E+02	8.7280E-02	1.6374E+02	1.4282E+02	1.6193E+02	2.2667E+02	1.5793E+02
F21	best	2.3704E+03	2.3847E+03	2.4806E+03	3.2013E+03	2.6696E+03	2.6626E+03	2.5719E+03	2.4608E+03	2.6607E+03
	mean	2.4030E+03	2.4283E+03	2.5001E+03	3.2013E+03	2.7484E+03	2.7502E+03	2.6080E+03	2.5164E+03	2.7550E+03
	std	2.2668E+01	2.5260E+01	1.3602E+01	1.8691E-01	4.1840E+01	6.0794E+01	2.4541E+01	4.7112E+01	6.8934E+01
F22	best	2.3009E+03	2.3177E+03	2.3812E+03	1.2789E+04	8.0190E+03	7.9175E+03	6.1866E+03	7.6339E+03	8.6573E+03
	mean	3.6567E+03	5.4805E+03	2.4620E+03	1.2791E+04	9.0084E+03	9.2024E+03	9.6361E+03	8.9770E+03	9.3485E+03
	std	2.2711E+03	1.8543E+03	6.6110E+01	3.9844E+00	5.6438E+02	7.4884E+02	1.4420E+03	8.2169E+02	4.5780E+02
F23	best	2.7246E+03	2.7375E+03	2.8165E+03	7.5955E+03	3.3117E+03	3.3101E+03	3.0542E+03	2.8866E+03	3.2617E+03
	mean	2.7835E+03	2.8074E+03	2.8554E+03	7.5961E+03	3.3930E+03	3.4945E+03	3.1276E+03	2.9209E+03	3.4440E+03
	std	4.8066E+01	3.6137E+01	2.0531E+01	1.8148E+00	4.0506E+01	1.2365E+02	5.6796E+01	2.2123E+01	1.0477E+02
F24	best	2.9100E+03	2.9113E+03	3.0001E+03	5.1709E+03	3.4920E+03	3.3682E+03	3.2090E+03	2.9751E+03	3.4606E+03
	mean	2.9598E+03	2.9525E+03	3.0146E+03	5.1709E+03	3.6051E+03	3.4941E+03	3.2927E+03	3.0640E+03	3.5859E+03
	std	4.2834E+01	3.3667E+01	1.1914E+01	0.0000E+00	7.9428E+01	2.0480E+02	5.2799E+01	4.6949E+01	6.9128E+01
F25	best	2.8842E+03	2.8951E+03	2.9153E+03	8.8568E+03	3.9943E+03	3.9952E+03	3.3416E+03	3.1052E+03	4.4591E+03
	mean	2.9061E+03	2.9244E+03	2.9291E+03	8.8568E+03	4.5475E+03	5.1617E+03	3.6886E+03	3.3605E+03	5.4060E+03
	std	1.6977E+01	1.8229E+01	8.0990E+00	0.0000E+00	2.1479E+02	9.9781E+02	2.3845E+02	2.4501E+02	7.2065E+02
F26	best	2.8017E+03	3.0893E+03	5.2748E+03	1.5815E+04	9.8403E+03	9.7578E+03	7.3179E+03	5.4749E+03	7.1594E1

表 3-4 九种算法在 CEC 2017 函数上的对比结果 (50 维)
Table 3-4 Comparison results of nine algorithms on CEC 2017 function (50D)

Function	Metric	IRIME	RIME	LSHADE	BDA	BWO	RSA	SCA	STOA	PDO
F1	best	1.0691E+06	7.0209E+07	1.7939E+09	1.3310E+11	9.3568E+10	9.3426E+10	6.6574E+10	3.3902E+10	8.3500E+10
	mean	3.7896E+06	1.3534E+08	3.0660E+09	1.3312E+11	1.0469E+11	1.0258E+11	7.2896E+10	4.5260E+10	9.8016E+10
	std	2.5627E+06	4.1820E+07	7.9391E+08	3.5421E+07	5.2054E+09	5.5773E+09	4.2155E+09	1.1854E+10	1.1316E+10
F3	best	8.1504E+04	1.5415E+05	1.5463E+05	1.1337E+14	1.9621E+05	1.5080E+05	1.2626E+05	1.7230E+05	1.5875E+05
	mean	1.1528E+05	2.3760E+05	2.3649E+05	1.1402E+14	2.6586E+05	1.7791E+05	2.4532E+05	2.4771E+05	3.3167E+05
	std	2.7783E+04	6.5187E+04	3.8693E+04	8.1588E+11	5.4486E+04	1.5015E+04	5.7273E+04	6.9239E+04	1.1482E+05
F4	best	5.1351E+02	6.0919E+02	9.6473E+02	5.5485E+04	3.0396E+04	2.2080E+04	1.0766E+04	2.9997E+03	1.9107E+04
	mean	6.0503E+02	6.9111E+02	1.0271E+03	5.5490E+04	3.5960E+04	2.9995E+04	1.6409E+04	5.6863E+03	3.1651E+04
	std	5.4918E+01	7.2518E+01	4.9687E+01	9.7642E+00	2.9024E+03	5.4016E+03	3.1440E+03	2.9058E+03	9.1791E+03
F5	best	6.5057E+02	7.3356E+02	8.9618E+02	1.3176E+03	1.1823E+03	1.1367E+03	1.0897E+03	8.9976E+02	1.0527E+03
	mean	7.1885E+02	8.1232E+02	9.5481E+02	1.3179E+03	1.2133E+03	1.1731E+03	1.1299E+03	9.9871E+02	1.1474E+03
	std	4.1558E+01	6.1879E+01	2.8539E+01	3.2010E-01	1.7411E+01	2.4492E+01	2.7689E+01	7.0792E+01	8.2469E+01
F6	best	6.2316E+02	6.2863E+02	6.2215E+02	7.2688E+02	6.9387E+02	7.0183E+02	6.7925E+02	6.5456E+02	6.9557E+02
	mean	6.3082E+02	6.4062E+02	6.2792E+02	7.2709E+02	7.0422E+02	7.0601E+02	6.8967E+02	6.7221E+02	7.0374E+02
	std	4.2653E+00	8.1752E+00	3.2057E+00	2.5284E-01	4.0892E+00	3.9490E+00	8.2910E+00	1.1823E+01	1.0732E+01
F7	best	9.4624E+02	1.1191E+03	1.2373E+03	2.0428E+03	1.9632E+03	1.8690E+03	1.7714E+03	1.5362E+03	1.7645E+03
	mean	1.0398E+03	1.2167E+03	1.2598E+03	2.0502E+03	2.0188E+03	1.9536E+03	1.9835E+03	1.6690E+03	1.9163E+03
	std	5.0633E+01	6.6627E+01	2.2252E+01	8.2925E+00	2.9282E+01	4.6852E+01	1.1934E+02	8.3999E+01	7.9946E+01
F8	best	9.6623E+02	1.0128E+03	1.1858E+03	1.6562E+03	1.5027E+03	1.4783E+03	1.4188E+03	1.2738E+03	1.4291E+03
	mean	1.0316E+03	1.1042E+03	1.2347E+03	1.6568E+03	1.5163E+03	1.5228E+03	1.4621E+03	1.3219E+03	1.5099E+03
	std	3.2404E+01	5.1094E+01	2.1155E+01	8.4976E-01	1.5220E+01	2.4091E+01	3.5070E+01	4.4158E+01	6.3472E+01
F9	best	5.2689E+03	6.0983E+03	3.7263E+03	3.0368E+04	3.6990E+04	3.3792E+04	2.5850E+04	2.3112E+04	2.3112E+04
	mean	8.7957E+03	1.3850E+04	5.4243E+03	3.1597E+04	4.0093E+04	3.9597E+04	3.4740E+04	3.0892E+04	2.8752E+04
	std	2.5553E+03	5.7197E+03	1.3597E+03	8.2133E+02	2.0289E+03	3.5045E+03	4.3759E+03	1.0958E+04	3.5625E+03
F10	best	5.9107E+03	7.6418E+03	1.2669E+04	2.0046E+04	1.4858E+04	1.4041E+04	1.4627E+04	1.3190E+04	1.2910E+04
	mean	7.4497E+03	8.9524E+03	1.4572E+04	2.0053E+04	1.5285E+04	1.5218E+04	1.5438E+04	1.4032E+04	1.4436E+04
	std	1.1693E+03	1.3600E+03	8.6711E+02	7.3582E+00	3.0659E+02	6.3202E+02	4.7278E+02	5.5553E+02	1.0822E+03
F11	best	1.2776E+03	1.6181E+03	3.6719E+03	6.2860E+05	1.7539E+04	1.6004E+04	1.0134E+04	6.0625E+03	2.0892E+04
	mean	1.3670E+03	1.8562E+03	4.7877E+03	6.2860E+05	2.3298E+04	2.2101E+04	1.4626E+04	9.2187E+03	2.3647E+04
	std	6.2215E+01	2.2582E+02	8.0507E+02	3.2321E+00	2.2785E+03	2.8293E+03	3.2483E+03	2.1825E+03	2.2617E+03
F12	best	4.1624E+06	7.1606E+07	4.4398E+08	1.4022E+11	5.4394E+10	6.5970E+10	1.6229E+10	2.7788E+09	5.4956E+10
	mean	1.6306E+07	1.9869E+08	7.4613E+08	1.4022E+11	6.6187E+10	8.6446E+10	2.3316E+10	1.0492E+10	8.2055E+10
	std	8.7407E+06	1.2716E+08	2.1038E+08	1.6760E+06	8.5937E+09	1.4246E+10	3.6468E+09	5.3320E+09	1.6512E+10
F13	best	1.2591E+04	3.7586E+05	6.2353E+07	1.1189E+11	3.0731E+10	3.2292E+10	6.3195E+09	2.4215E+08	2.7850E+10
	mean	3.6348E+04	1.2794E+06	1.4018E+08	1.1189E+11	4.2631E+10	5.1700E+10	8.7748E+09	2.0774E+09	4.0538E+10
	std	2.7330E+04	1.6978E+06	6.6574E+07	2.4194E+01	6.5087E+09	1.0804E+10	2.6919E+09	2.5698E+09	1.1706E+10
F14	best	3.8775E+04	1.5111E+05	7.0863E+04	1.4245E+09	2.7266E+07	3.3341E+07	4.7838E+06	6.0054E+05	3.6280E+07
	mean	7.1541E+05	7.5054E+05	4.4543E+05	1.4245E+09	9.3210E+07	1.1839E+08	1.1640E+07	2.3742E+06	7.1612E+07
	std	5.5055E+05	4.9732E+05	2.9044E+05	3.5313E-01	4.8676E+07	6.6821E+07	5.4696E+06	1.7395E+06	2.7755E+07
F15	best	4.5296E+03	5.1118E+04	1.6187E+07	2.3430E+10	4.2412E+09	3.2132E+09	6.5788E+08	5.5666E+07	1.7878E+09
	mean	1.7249E+04	2.0221E+05	3.2465E+07	2.3430E+10	6.4069E+09	1.0938E+10	1.4596E+09	4.6492E+08	4.6103E+09
	std	8.6897E+03	1.0236E+05	1.4891E+07	1.9777E+00	1.8540E+09	4.4522E+09	5.7588E+08	4.3559E+08	1.7489E+09
F16	best	3.0614E+03	3.3825E+03	5.0915E+03	2.3738E+04	7.9355E+03	7.3364E+03	5.4876E+03	3.8951E+03	7.2278E+03
	mean	3.4641E+03	4.0014E+03	5.3946E+03	2.3738E+04	8.8340E+03	9.3915E+03	6.5102E+03	4.5764E+03	9.9827E+03
	std	3.2733E+02	4.2908E+02	2.1848E+02	4.0852E-02	6.8052E+02	1.6058E+03	5.5177E+02	5.4657E+02	1.9506E+03
F17	best	2.6072E+03	2.8021E+03	4.0404E+03	1.5328E+05	6.0079E+03	1.0375E+04	4.2256E+03	3.2995E+03	5.8799E+03
	mean	3.0995E+03	3.3620E+03	4.5240E+03	1.5328E+05	7.8456E+03	1.7495E+04	5.2295E+03	3.8242E+03	1.0232E+04
	std	3.3123E+02	4.0965E+02	2.5111E+02	2.2243E+00	1.4099E+03	5.2968E+03	4.8431E+02	3.3774E+02	3.0350E+03
F18	best	2.5792E+05	4.4735E+05	3.4255E+06	1.8753E+09	8.2892E+07	1.1474E+08	3.4562E+07	3.0318E+06	1.2032E+07
	mean	3.3641E+06	6.8193E+06	4.9379E+06	1.8753E+09	1.6527E+08	2.1578E+08	7.7578E+07	1.3844E+07	1.6247E+08
	std	1.9348E+06	5.2215E+06	1.9576E+06	5.9077E-01	8.0753E+07	9.6967E+07	3.3730E+07	5.9502E+06	1.0528E+08
F19	best	2.4415E+03	2.5819E+05	7.1966E+06	1.3538E+10	1.8025E+09	2.1731E+09	2.2417E+08	1.5160E+07	1.9660E+09
	mean	3.2373E+04	9.8873E+05	1.5367E+07	1.3538E+10	3.8207E+09	5.3860E+09	6.6868E+08	2.4474E+08	4.4275E+09
	std	4.8123E+04	7.3223E+05	7.3114E+06	1.7727E-01	1.1376E+09	1.7197E+09	5.6016E+08	3.1849E+08	2.0039E+09
F20	best	2.6058E+03	2.6641E+03	3.9212E+03	5.1950E+03	3.8830E+03	3.9877E+03	3.9319E+03	3.4232E+03	3.8686E+03
	mean	3.0486E+03	3.3672E+03	4.2035E+03	5.1954E+03	4.1625E+03	4.3529E+03	4.4437E+03	3.9352E+03	4.2575E+03
	std	3.5169E+02	3.6933E+02	1.4016E+02	7.6268E-01	1.4017E+02	2.2009E+02	2.1738E+02	5.0285E+02	2.5798E+02
F21	best	2.4674E+03	2.4444E+03	2.7157E+03	4.2536E+03	3.1072E+03	3.1478E+03	2.9152E+03	2.7127E+03	3.0901E+03
	mean	2.5142E+03	2.5541E+03	2.7511E+03	4.2544E+03	3.1937E+03	3.2164E+03	2.9703E+03	2.7790E+03	3.2815E+03
	std	3.9734E+01	6.6851E+01	2.4684E+01	9.6510E-01	6.3720E+01	5.0154E+01	4.1425E+01	4.8678E+01	1.2574E+02
F22	best	8.0382E+03	9.1894E+03	1.5032E+04	2.0250E+04	1.6035E+04	1.6995E+04	1.5981E+04	1.3521E+04	1.5872E+04
	mean	9.7523E+03	1.0399E+04	1.6353E+04	2.0263E+04	1.7107E+04	1.7733E+04	1.7045E+04	1.5764E+04	1.7178E+04
	std	1.0454E+03	6.7695E+02	8.9527E+02	1.9183E+01	5.3832E+02	4.3774E+02	4.8354E+02	1.0861E+03	8.5727E+02
F23	best	2.9749E+03	2.9328E+03	3.1170E+03	9.2813E+03	4.0620E+03	3.8752E+03	3.6071E+03	3.2999E+03	4.1547E+03
	mean	3.1119E+03	3.0832E+03	3.1988E+03	9.2880E+03	4.1996E+03	4.1291E+03	3.7893E+03	3.3477E+03	4.3535E+03
	std	1.7867E+02	7.9930E+01	4.0448E+01	7.5731E+00	1.0113E+02	2.0252E+02	7.4469E+01	3.4988E+01	1.4280E+02
F24	best	3.0755E+03	3.1269E+03	3.3075E+03	6.8116E+03	4.5449E+03	3.9679E+03	3.7666E+03	3.3748E+03	4.0807E+03
	mean	3.1535E+03	3.1880E+03	3.3447E+03	6.8122E+03	4.6738E+03	4.5650E+03	3.8869E+03	3.4300E+03	4.4039E+03
	std	7.1586E+01	7.0526E+01	2.1153E+01	6.7437E-01	1.0371E+02	6.5066E+02	8.2544E+01	3.4013E+01	1.3780E+02
F25	best	3.0760E+03	3.1123E+03	3.2768E+03	1.9370E+04	1.3577E+04	1.2501E+04	7.6537E+03	4.4418E+03	9.4219E+03
	mean	3.1743E+03	3.2301E+03	3.4093E+03	1.9375E+04	1.4979E+04	1.4150E+04	1.0718E+04	5.8045E+03	1.3733E+04
	std	5.3584E+01	7.6209E+01	8.7698E+01	6.0016E+00	6.4198E+02	8.0843E+02	1.9121E+03	7.6621E+02	2.3643E+03
F26	best	5.6950E+03	6.3495E+03	8.0279E+03	1.9968E+04	1.6540E+04	1.4984E+04	1.3122E+04	8.3382E+03	1.4007E+04
	mean	7.3894E+03	7.5289E+03	8.4988E+03	1.9977E+04	1.7088E+04	1.6354E+04	1.4363E+04	9.7141E+03	1.6419E+04
	std	1.3248E+03	9.1770E+02	2.4906E+02	1.1451E+01	3.8790E+02	6.4469E+02	5.6200E+02	6.1312E+02	1.38

表 3-5 IRIME 消融实验结果 (50 维)
Table 3-5 Results of IRIME ablation experiments (50D)

函数	指标	IRIME	IRIME1	IRIME2	IRIME3	函数	指标	IRIME	IRIME1	IRIME2	IRIME3
F1	best	2.5998E+02	5.9359E+03	3.6513E+03	6.1747E+06	F16	best	2.0612E+03	2.2352E+03	2.3037E+03	2.4056E+03
	mean	1.2240E+04	8.7933E+04	5.9362E+04	1.5117E+07		mean	2.5143E+03	2.6624E+03	2.6860E+03	2.8684E+03
	std	1.2329E+04	1.5915E+05	1.2319E+05	6.5201E+06		std	3.1687E+02	3.7234E+02	3.0646E+02	2.1176E+02
F3	best	9.5810E+03	9.7098E+03	3.1455E+04	4.9309E+04	F17	best	1.8934E+03	1.9971E+03	1.7874E+03	1.9529E+03
	mean	1.7915E+04	2.2766E+04	5.2002E+04	8.8347E+04		mean	2.1250E+03	2.2332E+03	2.2590E+03	2.4153E+03
	std	6.1508E+03	1.0279E+04	1.4393E+04	3.3042E+04		std	1.7876E+02	1.4418E+02	3.3531E+02	2.9336E+02
F4	best	4.9131E+02	4.7255E+02	4.8922E+02	4.9517E+02	F18	best	6.2076E+04	1.1554E+05	1.3702E+05	6.8856E+05
	mean	5.2050E+02	5.1220E+02	5.2519E+02	5.5451E+02		mean	2.0004E+05	6.8201E+05	6.1285E+05	3.2597E+06
	std	1.9003E+01	3.3957E+01	2.8305E+01	5.7395E+01		std	1.5082E+05	7.8357E+05	5.5404E+05	2.2131E+06
F5	best	5.5523E+02	5.7164E+02	5.7568E+02	5.7474E+02	F19	best	1.9298E+03	2.0242E+03	2.8178E+03	6.4475E+03
	mean	5.9252E+02	6.1633E+02	6.1639E+02	6.3291E+02		mean	5.1041E+03	6.8860E+03	1.1113E+04	4.5022E+04
	std	2.5654E+01	3.3403E+01	3.5628E+01	4.0341E+01		std	3.4372E+03	7.2220E+03	9.4846E+03	2.6286E+04
F6	best	6.0387E+02	6.0694E+02	6.0488E+02	6.1395E+02	F20	best	2.2122E+03	2.2747E+03	2.3102E+03	2.2497E+03
	mean	6.1289E+02	6.1590E+02	6.1429E+02	6.2083E+02		mean	2.4204E+03	2.5478E+03	2.4929E+03	2.6686E+03
	std	5.5505E+00	8.8969E+00	9.7850E+00	5.5502E+00		std	1.7590E+02	2.3265E+02	1.3098E+02	2.3658E+02
F7	best	7.8913E+02	8.1756E+02	8.0850E+02	8.5502E+02	F21	best	2.3475E+03	2.3915E+03	2.3628E+03	2.3574E+03
	mean	8.2926E+02	8.6384E+02	8.6664E+02	9.1457E+02		mean	2.3813E+03	2.4202E+03	2.4129E+03	2.4233E+03
	std	2.9010E+01	3.7531E+01	4.2853E+01	4.2540E+01		std	1.5661E+01	2.4905E+01	3.2042E+01	3.2712E+01
F8	best	8.4826E+02	8.6965E+02	8.8757E+02	8.7963E+02	F22	best	2.3001E+03	2.3005E+03	2.3005E+03	2.3203E+03
	mean	8.8384E+02	8.9294E+02	9.1092E+02	9.2603E+02		mean	3.5893E+03	4.1098E+03	4.3869E+03	5.2847E+03
	std	1.9496E+01	1.6764E+01	2.1601E+01	2.0284E+01		std	2.0741E+03	1.9953E+03	2.2460E+03	2.0595E+03
F9	best	1.0200E+03	1.2668E+03	1.3602E+03	1.8368E+03	F23	best	2.7263E+03	2.7240E+03	2.7510E+03	2.7515E+03
	mean	1.9680E+03	2.1161E+03	2.2500E+03	4.3246E+03		mean	2.7653E+03	2.7908E+03	2.7996E+03	2.8487E+03
	std	5.8933E+02	7.0572E+02	1.0722E+03	2.0715E+03		std	3.3792E+01	5.0344E+01	3.5553E+01	6.2152E+01
F10	best	2.9567E+03	4.2917E+03	3.0702E+03	3.9096E+03	F24	best	2.9211E+03	2.9132E+03	2.9098E+03	2.9190E+03
	mean	4.7099E+03	4.9652E+03	5.4430E+03	4.9123E+03		mean	2.9580E+03	2.9626E+03	2.9953E+03	2.9702E+03
	std	8.8189E+02	7.2594E+02	1.2159E+03	7.0890E+02		std	3.1118E+01	3.4165E+01	6.7378E+01	4.8109E+01
F11	best	1.1606E+03	1.1748E+03	1.1610E+03	1.3083E+03	F25	best	2.8846E+03	2.8878E+03	2.8907E+03	2.9044E+03
	mean	1.2157E+03	1.2506E+03	1.2395E+03	1.3629E+03		mean	2.8989E+03	2.9188E+03	2.9215E+03	2.9400E+03
	std	3.3957E+01	4.1306E+01	5.4949E+01	5.4884E+01		std	1.3576E+01	2.3211E+01	2.3212E+01	3.2306E+01
F12	best	2.1978E+05	6.3148E+05	3.2419E+05	5.5903E+06	F26	best	2.9025E+03	2.8020E+03	2.9017E+03	3.0406E+03
	mean	1.4591E+06	2.2720E+06	2.6815E+06	3.4095E+07		mean	4.7586E+03	4.5739E+03	4.7496E+03	5.0770E+03
	std	8.4120E+05	1.4251E+06	1.7985E+06	3.0242E+07		std	7.6348E+02	1.2681E+03	1.0878E+03	8.4666E+02
F13	best	3.1439E+03	4.8273E+03	2.8014E+03	5.3486E+04	F27	best	3.2193E+03	3.2313E+03	3.2256E+03	3.2183E+03
	mean	2.0404E+04	2.7173E+04	4.5430E+04	4.2677E+05		mean	3.2400E+03	3.2487E+03	3.2575E+03	3.2560E+03
	std	1.2822E+04	1.6328E+04	1.0150E+05	7.1392E+05		std	1.7103E+01	2.1350E+01	2.9144E+01	2.9582E+01
F14	best	4.9574E+03	1.8471E+04	5.0773E+04	9.5993E+04	F28	best	3.2174E+03	3.2150E+03	3.2233E+03	3.2670E+03
	mean	4.3815E+04	5.8290E+04	1.2434E+05	4.0737E+05		mean	3.2482E+03	3.2691E+03	3.2721E+03	3.3337E+03
	std	3.0140E+04	3.0478E+04	7.5137E+04	2.8950E+05		std	2.3235E+01	3.6993E+01	3.1277E+01	6.0449E+01
F15	best	1.5950E+03	2.1364E+03	1.7994E+03	9.7005E+03	F29	best	3.7722E+03	3.6556E+03	3.8282E+03	3.8825E+03
	mean	2.9020E+03	8.1641E+03	1.1872E+04	3.4115E+04		mean	3.8853E+03	3.8999E+03	4.0335E+03	4.1437E+03
	std	1.5170E+03	7.6321E+03	1.2820E+04	2.2163E+04		std	8.9678E+01	1.9425E+02	1.4719E+02	2.7717E+02
						F30	best	6.3440E+03	1.2215E+04	1.2309E+04	3.6967E+05
							mean	6.7820E+04	5.7947E+04	1.2775E+05	7.6501E+05
							std	1.1844E+05	5.5463E+04	1.3526E+05	3.6199E+05

的数据特性，以严格测试算法的可扩展性和鲁棒性。这些数据集的详细规格（如样本量、特征维度和类别分布）见表 3-7。此分层数据设计旨在验证 IRIME 在不同问题复杂度下的表现，同时保持其在医学应用中的实际相关性。实验的软、硬件则与前文一直，严格按照 3.3 节中的软硬件环境进行实验。

表 3-6 特征选择中的算法参数设置
Table 3-6 Parameters setting for algorithms used in FS

算法	参数设定
IRIME	$w = 5$
RIME	$w = 5$
AOA	$c_1 = 0.2; C_3 = 3; \mu = 25; \sigma = 3$
BWO	$W_f \in [0.1, 0.5]$
WOA	$A = 1; C \in [-1, 1]; b = 0.75; l \in [-1, 1]$
ROA	$C = 0.1$
SCA	$C_1 \in [0, 2]; C_2 \in [0, 2]; C_3 \in [0, 2]$
COA	$C_3 = 3; \mu = 25; \sigma = 3; PCr = 0.8; F = 0.85$

表 3-7 Overview of the datasets

数据集名称	样本数	特征数	类别数
Breast_cancer	699	9	2
Cleveland_heart	303	14	2
Dermatology	358	35	6
Diabetes	768	8	2
Lung_cancer_3class	32	57	3
Parkinson	195	23	2
Spect	267	23	2
wdbc	198	33	2
ALLAML	72	7129	2
Lymphoma	96	4026	9
nci9	60	9712	9
TOX-171	171	5748	4

3.3.2.2 实验结果与分析

在医学特征选择的评估中，IRIME 在适应度值和准确率指标方面都表现出显著优势。就适应度值而言，IRIME 在多个数据集上始终表现良好。具体而言，在乳腺癌数据集上，其最佳适应度值为 0.0044，与 WOA 并列第二，略高于 BWO 和 ROA。在皮肤科数据集上，IRIME 实现了最佳适应度值 0.0018，仅次于 SCA，且明显优于其他对比算法，彰显其强大的优化能力。在肺癌三分类和 wdbc 数据集上，IRIME 分别取得了 0.0003 和 0.0275 的最佳适应度值，在所有比较算法中排名第一。此外，IRIME 在不同数据集上的标准差保持适中，例如乳腺癌数据集的标准差为 0.0111，表明其具有稳定且高性能的表现。在平均适应度值方面，IRIME 在皮肤科数据集上的平均值为 0.0043，远低于 AOA 和 BWO，且仅次于 SCA。在分类准确率方面，IRIME 在多个五个数据集上获得了最高和平均的准确率。例如，在乳腺癌数据集上的最佳准确率与其他领先算法相当，平均准确率达 98.49%，位居前列。这些结果表明，IRIME 不仅能有效选择相关特征，还能保




图 3-7 12 个数据集上的适应度值收敛曲线

Fig. 3-7 Convergence curves of fitness values on 12 datasets



图 3-8 12 个数据集上的对比准确率直方图
Fig. 3-8 Histogram of comparison accuracy on 12 datasets

表 3-8 12 个数据集上的适应度值结果
Table 3-8 Results of fitness values on 12 datasets

数据集	指标	IRIME	RIME	AOA	BWO	WOA	ROA	SCA	COA
Breast-cancer	best	4.4444E-03	1.7578E-02	1.4900E-02	3.3333E-03	4.4444E-03	3.3333E-03	1.1567E-02	3.3333E-03
	mean	1.9624E-02	2.3028E-02	2.6478E-02	2.0336E-02	1.9689E-02	2.5877E-02	2.5432E-02	2.1159E-02
	std	1.1108E-02	5.5461E-03	1.1300E-02	1.1041E-02	1.1334E-02	1.0368E-02	1.1200E-02	1.2029E-02
Cleveland-heart	best	6.9846E-02	6.9846E-02	8.7115E-02	5.3346E-02	8.8654E-02	3.8385E-02	6.9846E-02	5.5654E-02
	mean	1.0826E-01	1.1486E-01	1.2253E-01	1.2161E-01	1.2223E-01	1.0903E-01	1.1401E-01	1.1509E-01
	std	1.9192E-02	3.6574E-02	3.3669E-02	3.3271E-02	2.3424E-02	4.4835E-02	3.0825E-02	3.3782E-02
Dermatology	best	1.7647E-03	2.3529E-03	4.1176E-03	5.0000E-03	3.8235E-03	3.8235E-03	1.4706E-03	3.2353E-03
	mean	4.2767E-03	7.3007E-03	1.3031E-02	1.5643E-02	1.1589E-02	1.4807E-02	1.1043E-02	6.6417E-03
	std	4.3719E-03	6.5224E-03	1.0056E-02	1.2877E-02	6.9351E-03	7.6337E-03	7.2608E-03	5.7978E-03
Diabetes	best	1.6676E-01	1.7574E-01	1.6404E-01	1.8743E-01	1.8618E-01	2.0037E-01	1.9140E-01	2.0162E-01
	mean	2.0427E-01	2.1890E-01	2.2082E-01	2.1164E-01	2.1644E-01	2.3310E-01	2.1957E-01	2.1669E-01
	std	1.9885E-02	2.0106E-02	2.8935E-02	1.9926E-02	2.3074E-02	2.6184E-02	2.1388E-02	1.0460E-02
lungcancer-3class	best	3.5714E-04	7.1429E-04	4.4643E-03	1.2500E-03	5.3571E-04	8.9286E-04	3.5714E-04	2.3214E-03
	mean	1.7214E-02	3.3964E-02	1.0418E-01	8.4339E-02	8.3839E-02	1.5043E-01	8.3143E-02	3.6054E-02
	std	5.2117E-02	6.9439E-02	1.3867E-01	1.1565E-01	1.1644E-01	1.2116E-01	8.7001E-02	6.9281E-02
Parkinson	best	9.0909E-04	9.0909E-04	2.7657E-02	3.1818E-03	2.6748E-02	2.9476E-02	1.8182E-03	2.2727E-03
	mean	4.6692E-02	7.4570E-02	5.9892E-02	4.2115E-02	6.9902E-02	8.5678E-02	5.9703E-02	7.0266E-02
	std	2.6093E-02	4.8458E-02	3.3682E-02	2.0709E-02	2.7134E-02	3.5320E-02	3.1505E-02	3.7616E-02
SPECT	best	7.8353E-02	5.9220E-02	9.9760E-02	6.2856E-02	8.3353E-02	7.9717E-02	7.7444E-02	4.3268E-02
	mean	1.0815E-01	1.1913E-01	1.2637E-01	1.4036E-01	1.2318E-01	1.2086E-01	1.1548E-01	1.0737E-01
	std	2.1731E-02	3.3873E-02	3.0181E-02	4.0193E-02	2.7183E-02	2.9275E-02	2.5141E-02	3.8726E-02
wpbc	best	2.7506E-02	7.7972E-02	1.0730E-01	8.1608E-02	7.7366E-02	1.0366E-01	7.7063E-02	5.5315E-02
	mean	8.8429E-02	1.1161E-01	1.4347E-01	1.2696E-01	1.4672E-01	1.4056E-01	1.1064E-01	1.1811E-01
	std	3.6329E-02	2.3809E-02	3.3643E-02	2.4154E-02	3.1608E-02	2.6510E-02	2.4200E-02	5.0897E-02
ALLAML	best	1.4027E-06	8.4163E-06	7.5650E-02	2.8054E-06	1.4027E-06	2.8054E-06	7.1539E-05	7.5319E-02
	mean	3.6471E-06	1.4210E-02	1.5397E-01	2.1221E-02	2.8295E-02	7.7909E-02	1.4248E-02	1.3198E-01
	std	1.5079E-06	2.9868E-02	5.2247E-02	3.4156E-02	3.6511E-02	7.0353E-02	2.9826E-02	6.4967E-02
Lymphoma	best	2.4839E-06	4.9677E-06	4.7889E-03	2.4839E-06	4.9677E-06	7.4516E-06	7.4516E-06	7.6006E-04
	mean	4.7193E-06	7.2032E-06	4.8530E-03	2.9806E-06	8.9419E-06	1.7139E-05	1.5152E-05	4.1381E-03
	std	1.4100E-06	2.1749E-06	5.3077E-05	1.0473E-06	3.9186E-06	1.4024E-05	9.0281E-06	1.1887E-03
nci9	best	1.6501E-01	2.4767E-01	4.1957E-01	2.4751E-01	2.4753E-01	3.3009E-01	2.4761E-01	4.1726E-01
	mean	2.7228E-01	3.4662E-01	5.5840E-01	3.6318E-01	3.6310E-01	4.5414E-01	3.4668E-01	5.5754E-01
	std	1.1034E-01	7.5740E-02	8.6980E-02	9.6622E-02	8.8655E-02	7.9960E-02	6.5048E-02	1.2324E-01
TOX-171	best	1.6875E-04	3.2026E-02	1.5065E-01	8.7480E-02	3.1633E-02	6.4942E-02	2.9420E-02	6.3251E-02
	mean	3.5686E-02	9.5800E-02	2.2457E-01	1.5284E-01	1.3361E-01	1.5890E-01	7.6619E-02	1.3883E-01
	std	3.8437E-02	4.2697E-02	6.4879E-02	4.9116E-02	5.6303E-02	4.6560E-02	2.8391E-02	3.9287E-02

表 3-9 12 个数据集上的准确率结果
Table 3-9 Accuracy results on 12 datasets

数据集	指标	IRIME	RIME	AOA	BWO	WOA	ROA	SCA	COA
Breast-cancer	best	9.6403E-01	9.7122E-01	9.4964E-01	9.6403E-01	9.6403E-01	9.6403E-01	9.5683E-01	9.6403E-01
	mean	9.8489E-01	9.8201E-01	9.7842E-01	9.8417E-01	9.8561E-01	9.7914E-01	9.7914E-01	9.8345E-01
	std	1.0963E-02	5.0871E-03	1.2228E-02	1.0617E-02	1.1248E-02	9.8584E-03	1.1476E-02	1.1773E-02
Cleveland-heart	best	8.6667E-01	8.1667E-01	8.3333E-01	8.3333E-01	8.5000E-01	8.5000E-01	8.1667E-01	8.5000E-01
	mean	8.9500E-01	8.8833E-01	8.8167E-01	8.8167E-01	8.8167E-01	8.9500E-01	8.8833E-01	8.8833E-01
	std	1.9325E-02	3.6893E-02	3.4650E-02	3.3747E-02	2.4152E-02	4.5168E-02	3.1476E-02	3.4292E-02
Dermatology	best	9.8592E-01	9.8592E-01	9.7183E-01	9.5775E-01	9.8592E-01	9.8592E-01	9.8592E-01	9.8592E-01
	mean	9.9859E-01	9.9577E-01	9.9296E-01	9.9014E-01	9.9296E-01	9.9155E-01	9.9155E-01	9.9718E-01
	std	4.4539E-03	6.8035E-03	9.9593E-03	1.3362E-02	7.4232E-03	7.2732E-03	7.2732E-03	5.9385E-03
Diabetes	best	7.5817E-01	7.5817E-01	7.4510E-01	7.5163E-01	7.5163E-01	7.5163E-01	7.4510E-01	7.7124E-01
	mean	7.8824E-01	7.8431E-01	7.8301E-01	7.9216E-01	7.8693E-01	7.8497E-01	7.8301E-01	7.8693E-01
	std	1.8538E-02	2.0897E-02	3.0314E-02	2.0391E-02	2.1830E-02	2.3756E-02	2.1743E-02	1.1610E-02
lungcancer-3class	best	8.3333E-01	1.0000E+00	6.6667E-01	6.6667E-01	6.6667E-01	6.6667E-01	8.3333E-01	8.3333E-01
	mean	9.8333E-01	1.0000E+00	9.0000E-01	9.1667E-01	9.1667E-01	8.5000E-01	9.1667E-01	9.6667E-01
	std	5.2705E-02	0.0000E+00	1.4055E-01	1.1785E-01	1.1785E-01	1.2298E-01	8.7841E-02	7.0273E-02
Parkinson	best	9.2308E-01	8.4615E-01	8.9744E-01	9.2308E-01	8.9744E-01	8.4615E-01	8.9744E-01	8.7179E-01
	mean	9.5385E-01	9.2564E-01	9.4359E-01	9.5897E-01	9.3077E-01	9.1538E-01	9.4103E-01	9.3077E-01
	std	2.6482E-02	4.9024E-02	3.3758E-02	2.1622E-02	2.7163E-02	3.6362E-02	3.2094E-02	3.8319E-02
SPECT	best	8.6792E-01	8.1132E-01	8.3019E-01	7.9245E-01	8.3019E-01	8.3019E-01	8.4906E-01	8.3019E-01
	mean	8.9434E-01	8.8302E-01	8.7925E-01	8.6226E-01	8.8113E-01	8.8302E-01	8.8679E-01	8.9623E-01
	std	2.2147E-02	3.4218E-02	3.1067E-02	4.1766E-02	2.8197E-02	2.9230E-02	2.5157E-02	4.0025E-02
wpbc	best	8.7179E-01	8.4615E-01	7.9487E-01	8.4615E-01	8.2051E-01	8.2051E-01	8.7179E-01	7.9487E-01
	mean	9.1282E-01	8.8974E-01	8.6154E-01	8.7436E-01	8.5385E-01	8.6154E-01	8.8974E-01	8.8462E-01
	std	3.6663E-02	2.4325E-02	3.4613E-02	2.5498E-02	3.2094E-02	2.7563E-02	2.4325E-02	5.1637E-02
ALLAML	best	1.0000E+00	9.2857E-01	7.8571E-01	9.2857E-01	9.2857E-01	7.8571E-01	1.0000E+00	7.1429E-01
	mean	1.0000E+00	9.8571E-01	8.5000E-01	9.7857E-01	9.7143E-01	9.2143E-01	1.0000E+00	8.7143E-01
	std	0.0000E+00	3.0117E-02	5.2705E-02	3.4503E-02	3.6886E-02	7.1031E-02	0.0000E+00	0.0000E+00
Lymphoma	best	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00
	mean	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00	1.0000E+00
	std	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00
nci9	best	5.0000E-01	5.0000E-01	3.3333E-01	5.0000E-01	5.0000E-01	4.1667E-01	5.8333E-01	1.6667E-01
	mean	7.2500E-01	6.5000E-01	4.7500E-01	6.3333E-01	6.3333E-01	5.4167E-01	6.5000E-01	4.4167E-01
	std	1.1146E-01	7.6578E-02	9.6625E-02	9.7816E-02	8.9581E-02	8.0985E-02	6.5734E-02	1.2454E-01
TOX-171	best	8.8235E-01	8.8235E-01	7.0588E-01	7.9412E-01	7.9412E-01	7.9412E-01	8.8235E-01	8.2353E-01
	mean	9.6471E-01	9.4412E-01	8.0294E-01	8.4706E-01	8.6765E-01	8.4412E-01	9.2353E-01	8.6471E-01
	std	3.8722E-02	2.9248E-02	6.0515E-02	4.9604E-02	5.7585E-02	4.8129E-02	2.8414E-02	3.9703E-02



图 3-9 12 个数据集上的对比特征数量直方图
Fig. 3-9 Histogram of the number of contrasting features on the 12 datasets

持稳健的分类准确性。在高维数据集 ALLAML 和 TOX-171 上, IRIME 分别以 100% 和 88.24% 的分类准确率夺得第一, 且在其他高维数据集上表现具有竞争力。此外, IRIME 在所有高维数据集上的适应度值表现出压倒性的优势。

3.3.3 消融实验

为了验证所引入策略的有效性, 本实验对 IRIME 所引入的三种改进策略进行系统性地消融研究, 以评估 IRIME 中三项关键策略的单独贡献: 信息熵评估策略、随机重启机制和拉格朗日插值法。在 CEC 2017 上的实验结果显示, 不同策略组合具有明显的性能模式。我们将表 3-10 中的四个算法用于消融实验, 四中算法具体的策略使用与否一并在标准列出。对比结果显示, 性能差异显著: 完整的 IRIME 取得了优异的表现, 最终排名得分优于所有部分变体。详细排名结果如图 3-10 所示, 结合表 3-11 和表 3-12 的分析实验的详细结果, 我们可以得出以下结论: 拉格朗日插值法: 最具影响力的组成部分, 特别是在 43% 的单模态函数 (平均提升 62.3%) 和组合函数 (58.1%) 中。其多项式逼近能力显著加快了收敛速度。随机重启机制: 维持种群多样性、防止早熟收敛的关键, 在 87% 的多模态情况下发挥作用。典型例子包括 F18 (1.4 对 4.0 的得分差异)。信息熵评估策略: 在特定函数类别中提供了选择性优势, 特别增强了可分离函数的开发能力 (F1-F3 表现出 18.7% 的性能提升)。

这些结果充分印证了 IRIME 中三项改进策略各自的独特价值与不可替代性, 其中拉格朗日插值法凭借在单模态函数和组合函数中显著的收敛加速效果, 成为对算法整体性能影响最核心的核心组成部分; 随机重启机制通过有效维持种群多样性、抑制早熟收敛, 在多模态函数场景中发挥重要作用, 其影响力紧随其后; 信息熵评估策略则在可分离函数等特定类别中展现出针对性优势, 为算法开发能力提供补充增强, 三者对 IRIME 性能的贡献程度呈依次递减趋势。

figures/Ftest/Ftest-ablation.pdf

图 3-10 IRIME 及其变体的弗里德曼检验结果
Fig. 3-10 Friedman test results for IRIME and its variants

表 3-10 IRIME 消融实验各策略使用详情

Table 3-10 Details of each strategy used in the IRIME ablation experiment

	RIME	RIME1	RIME2	RIME3
信息熵评估策略	Y	N	Y	Y
拉格朗日插值法	Y	Y	N	Y
随机重启机制	Y	Y	Y	N

Note: Y = 使用策略, N = 未使用

表 3-11 IRIME 及其变体在 CEC 2017 函数上的比较结果 (30 维)

Table 3-11 Comparative results of IRIME and its variants on CEC 2017 functions (30D)

函数	指标	IRIME	IRIME1	IRIME2	IRIME3	函数	指标	IRIME	IRIME1	IRIME2	IRIME3
F1	best	1.2558E+06	1.0045E+06	5.4544E+06	1.1318E+08	F16	best	2.8688E+03	2.6826E+03	2.7336E+03	3.2032E+03
	mean	3.3987E+06	4.1328E+06	2.5161E+07	1.5456E+08		mean	3.3552E+03	3.3840E+03	3.4238E+03	3.7122E+03
	std	1.5194E+06	3.1143E+06	2.0054E+07	4.1785E+07		std	2.3006E+02	3.8652E+02	5.0485E+02	3.9866E+02
F3	best	8.8890E+04	8.8439E+04	1.3138E+05	2.0558E+05	F17	best	2.3092E+03	2.8608E+03	2.3864E+03	3.0366E+03
	mean	1.1081E+05	1.2990E+05	2.1286E+05	2.6118E+05		mean	2.8937E+03	3.1601E+03	3.0277E+03	3.5248E+03
	std	1.5636E+04	4.0473E+04	7.1786E+04	5.3141E+04		std	3.8377E+02	2.0263E+02	4.1320E+02	2.7300E+02
F4	best	5.3447E+02	5.7805E+02	5.9908E+02	6.7640E+02	F18	best	8.6352E+04	6.3864E+05	2.2840E+05	1.5852E+06
	mean	6.2916E+02	6.4728E+02	6.7860E+02	7.6329E+02		mean	1.7940E+06	3.0928E+06	2.4147E+06	8.5198E+06
	std	5.3123E+01	5.6742E+01	4.7260E+01	1.0628E+02		std	1.2771E+06	3.4844E+06	3.3472E+06	7.2520E+06
F5	best	6.5655E+02	6.9636E+02	6.6096E+02	7.2954E+02	F19	best	3.6404E+03	6.6142E+03	5.7974E+03	3.2805E+04
	mean	7.2421E+02	7.3021E+02	7.4534E+02	7.7363E+02		mean	1.7049E+04	1.3720E+04	2.4292E+04	3.1884E+05
	std	4.2345E+01	2.7674E+01	4.8586E+01	3.3015E+01		std	9.5224E+03	1.1057E+04	1.8061E+04	3.7235E+05
F6	best	6.1576E+02	6.1740E+02	6.1846E+02	6.2366E+02	F20	best	2.7498E+03	2.9101E+03	2.8053E+03	2.5443E+03
	mean	6.3197E+02	6.3293E+02	6.3077E+02	6.3286E+02		mean	3.0999E+03	3.1275E+03	3.1106E+03	3.2433E+03
	std	7.4473E+00	8.9955E+00	6.9216E+00	6.7160E+00		std	2.5323E+02	1.4604E+02	3.0619E+02	3.9186E+02
F7	best	9.5459E+02	9.8948E+02	9.6774E+02	1.1428E+03	F21	best	2.4299E+03	2.4479E+03	2.4368E+03	2.5153E+03
	mean	1.1008E+03	1.0640E+03	1.0954E+03	1.2453E+03		mean	2.5065E+03	2.5578E+03	2.5449E+03	2.5840E+03
	std	9.8027E+01	5.7950E+01	9.3540E+01	8.6098E+01		std	4.1664E+01	7.5127E+01	9.1912E+01	5.3123E+01
F8	best	9.2777E+02	9.5503E+02	9.7841E+02	1.0158E+03	F22	best	7.4094E+03	2.3304E+03	8.7135E+03	8.8509E+03
	mean	1.0087E+03	1.0273E+03	1.0229E+03	1.1100E+03		mean	9.6458E+03	9.1099E+03	1.0306E+04	1.0598E+04
	std	4.9127E+01	4.9284E+01	4.6605E+01	4.1735E+01		std	1.2940E+03	2.4798E+03	1.2841E+03	1.3328E+03
F9	best	3.5472E+03	3.3174E+03	4.9401E+03	9.3991E+03	F23	best	2.8953E+03	2.9228E+03	2.9394E+03	2.9344E+03
	mean	7.9460E+03	7.9757E+03	1.0689E+04	1.7675E+04		mean	3.0492E+03	3.0892E+03	3.0640E+03	3.0986E+03
	std	2.4182E+03	3.8489E+03	4.0951E+03	6.6864E+03		std	8.3674E+01	1.1143E+02	8.8297E+01	1.0629E+02
F10	best	6.3768E+03	5.8878E+03	6.4308E+03	8.0581E+03	F24	best	3.0940E+03	3.0579E+03	3.0980E+03	3.1650E+03
	mean	7.4203E+03	7.3403E+03	8.2466E+03	9.0423E+03		mean	3.1802E+03	3.1754E+03	3.2256E+03	3.2429E+03
	std	7.1909E+02	1.1524E+03	1.3674E+03	8.3056E+02		std	6.2427E+01	7.8666E+01	8.9514E+01	7.7414E+01
F11	best	1.2258E+03	1.2349E+03	1.3181E+03	1.7616E+03	F25	best	3.0434E+03	3.0605E+03	3.1037E+03	3.1552E+03
	mean	1.3608E+03	1.3953E+03	1.4195E+03	1.9363E+03		mean	3.1581E+03	3.1627E+03	3.1690E+03	3.2325E+03
	std	6.1395E+01	1.1507E+02	6.4794E+01	1.9610E+02		std	4.7245E+01	5.1392E+01	4.0386E+01	5.8210E+01
F12	best	7.4913E+06	9.9780E+06	1.0632E+07	5.0445E+07	F26	best	3.1656E+03	3.2680E+03	6.0113E+03	6.4070E+03
	mean	1.6960E+07	1.6688E+07	3.6390E+07	2.2399E+08		mean	6.3738E+03	7.2080E+03	7.1323E+03	7.5735E+03
	std	7.9006E+06	7.1739E+06	1.8680E+07	2.0914E+08		std	1.7048E+03	1.7518E+03	9.0307E+02	9.3845E+02
F13	best	6.4121E+03	8.7112E+03	9.1452E+03	4.5488E+05	F27	best	3.5057E+03	3.4621E+03	3.4143E+03	3.5315E+03
	mean	3.5114E+04	3.7325E+04	2.7901E+04	1.0457E+06		mean	3.5764E+03	3.5869E+03	3.5750E+03	3.6327E+03
	std	4.7804E+04	6.3660E+04	2.5519E+04	3.4769E+05		std	7.1227E+01	1.2291E+02	1.1911E+02	6.2420E+01
F14	best	5.7083E+04	2.4241E+05	4.5955E+05	3.0298E+05	F28	best	3.3713E+03	3.4005E+03	3.4054E+03	3.4249E+03
	mean	8.1234E+05	8.2842E+05	1.0787E+06	1.7145E+06		mean	3.4341E+03	3.4606E+03	3.4694E+03	3.5636E+03
	std	4.0241E+05	7.5862E+05	4.2126E+05	1.7989E+06		std	4.3014E+01	5.3152E+01	5.7289E+01	9.3363E+01
F15	best	4.1770E+03	5.5266E+03	7.3184E+03	1.0944E+05	F29	best	4.2879E+03	3.8221E+03	3.7370E+03	4.5630E+03
	mean	1.2366E+04	1.5678E+04	1.4110E+04	1.6534E+05		mean	4.5100E+03	4.7316E+03	4.3861E+03	5.1734E+03
	std	8.2541E+03	8.0991E+03	7.7415E+03	5.6155E+04		std	2.0332E+02	4.4696E+02	4.7439E+02	3.5449E+02
F30	best	2.7873E+06	2.2049E+06	2.6670E+06	2.0144E+07	F30	best	4.0230E+06	4.4672E+06	1.2267E+07	4.4791E+07
	mean	4.0230E+06	4.4672E+06	1.2267E+07	4.4791E+07		mean	4.0230E+06	4.4672E+06	1.2267E+07	4.4791E+07
	std	9.8195E+05	1.8589E+06	9.8045E+06	2.3794E+07		std	9.8195E+05	1.8589E+06	9.8045E+06	2.3794E+07

表 3-12 IRIME 及其变体在 CEC 2017 函数上的比较结果 (50 维)

Table 3-12 Comparative results of IRIME and its variants on CEC 2017 functions (50D)

函数	指标	IRIME	IRIME1	IRIME2	IRIME3	函数	指标	IRIME	IRIME1	IRIME2	IRIME3
F1	best	2.5998E+02	5.9359E+03	3.6513E+03	6.1747E+06	F16	best	2.0612E+03	2.2352E+03	2.3037E+03	2.4056E+03
	mean	1.2240E+04	8.7933E+04	5.9362E+04	1.5117E+07		mean	2.5143E+03	2.6624E+03	2.6860E+03	2.8684E+03
	std	1.2329E+04	1.5915E+05	1.2319E+05	6.5201E+06		std	3.1687E+02	3.7234E+02	3.0646E+02	2.1176E+02
F3	best	9.5810E+03	9.7098E+03	3.1455E+04	4.9309E+04	F17	best	1.8934E+03	1.9971E+03	1.7874E+03	1.9529E+03
	mean	1.7915E+04	2.2766E+04	5.2002E+04	8.8347E+04		mean	2.1250E+03	2.2332E+03	2.2590E+03	2.4153E+03
	std	6.1508E+03	1.0279E+04	1.4393E+04	3.3042E+04		std	1.7876E+02	1.4418E+02	3.3531E+02	2.9336E+02
F4	best	4.9131E+02	4.7255E+02	4.8922E+02	4.9517E+02	F18	best	6.2076E+04	1.1554E+05	1.3702E+05	6.8856E+05
	mean	5.2050E+02	5.1220E+02	5.2519E+02	5.5451E+02		mean	2.0004E+05	6.8201E+05	6.1285E+05	3.2597E+06
	std	1.9003E+01	3.3957E+01	2.8305E+01	5.7395E+01		std	1.5082E+05	7.8357E+05	5.5404E+05	2.2131E+06
F5	best	5.5523E+02	5.7164E+02	5.7568E+02	5.7474E+02	F19	best	1.9298E+03	2.0242E+03	2.8178E+03	6.4475E+03
	mean	5.9252E+02	6.1633E+02	6.1639E+02	6.3291E+02		mean	5.1041E+03	6.8860E+03	1.1113E+04	4.5022E+04
	std	2.5654E+01	3.3403E+01	3.5628E+01	4.0341E+01		std	3.4372E+03	7.2220E+03	9.4846E+03	2.6286E+04
F6	best	6.0387E+02	6.0694E+02	6.0488E+02	6.1395E+02	F20	best	2.2122E+03	2.2747E+03	2.3102E+03	2.2497E+03
	mean	6.1289E+02	6.1590E+02	6.1429E+02	6.2083E+02		mean	2.4204E+03	2.5478E+03	2.4929E+03	2.6686E+03
	std	5.5505E+00	8.8969E+00	9.7850E+00	5.5502E+00		std	1.7590E+02	2.3265E+02	1.3098E+02	2.3658E+02
F7	best	7.8913E+02	8.1756E+02	8.0850E+02	8.5502E+02	F21	best	2.3475E+03	2.3915E+03	2.3628E+03	2.3574E+03
	mean	8.2926E+02	8.6384E+02	8.6664E+02	9.1457E+02		mean	2.3813E+03	2.4202E+03	2.4129E+03	2.4233E+03
	std	2.9010E+01	3.7531E+01	4.2853E+01	4.2540E+01		std	1.5661E+01	2.4905E+01	3.2042E+01	3.2712E+01
F8	best	8.4826E+02	8.6965E+02	8.8757E+02	8.7963E+02	F22	best	2.3001E+03	2.3005E+03	2.3005E+03	2.3203E+03
	mean	8.8384E+02	8.9294E+02	9.1092E+02	9.2603E+02		mean	3.5893E+03	4.1098E+03	4.3869E+03	5.2847E+03
	std	1.9496E+01	1.6764E+01	2.1601E+01	2.0284E+01		std	2.0741E+03	1.9953E+03	2.2460E+03	2.0595E+03
F9	best	1.0200E+03	1.2668E+03	1.3602E+03	1.8368E+03	F23	best	2.7263E+03	2.7240E+03	2.7510E+03	2.7515E+03
	mean	1.9680E+03	2.1161E+03	2.2500E+03	4.3246E+03		mean	2.7653E+03	2.7908E+03	2.7996E+03	2.8487E+03
	std	5.8933E+02	7.0572E+02	1.0722E+03	2.0715E+03		std	3.3792E+01	5.0344E+01	3.5553E+01	6.2152E+01
F10	best	2.9567E+03	4.2917E+03	3.0702E+03	3.9096E+03	F24	best	2.9211E+03	2.9132E+03	2.9098E+03	2.9190E+03
	mean	4.7099E+03	4.9652E+03	5.4430E+03	4.9123E+03		mean	2.9580E+03	2.9626E+03	2.9953E+03	2.9702E+03
	std	8.8189E+02	7.2594E+02	1.2159E+03	7.0890E+02		std	3.1118E+01	3.4165E+01	6.7378E+01	4.8109E+01
F11	best	1.1606E+03	1.1748E+03	1.1610E+03	1.3083E+03	F25	best	2.8846E+03	2.8878E+03	2.8907E+03	2.9044E+03
	mean	1.2157E+03	1.2506E+03	1.2395E+03	1.3629E+03		mean	2.8989E+03	2.9188E+03	2.9215E+03	2.9400E+03
	std	3.3957E+01	4.1306E+01	5.4949E+01	5.4884E+01		std	1.3576E+01	2.3211E+01	2.3212E+01	3.2306E+01
F12	best	2.1978E+05	6.3148E+05	3.2419E+05	5.5903E+06	F26	best	2.9025E+03	2.8020E+03	2.9017E+03	3.0406E+03
	mean	1.4591E+06	2.2720E+06	2.6815E+06	3.4095E+07		mean	4.7586E+03	4.5739E+03	4.7496E+03	5.0770E+03
	std	8.4120E+05	1.4251E+06	1.7985E+06	3.0242E+07		std	7.6348E+02	1.2681E+03	1.0878E+03	8.4666E+02
F13	best	3.1439E+03	4.8273E+03	2.8014E+03	5.3486E+04	F27	best	3.2193E+03	3.2313E+03	3.2256E+03	3.2183E+03
	mean	2.0404E+04	2.7173E+04	4.5430E+04	4.2677E+05		mean	3.2400E+03	3.2487E+03	3.2575E+03	3.2560E+03
	std	1.2822E+04	1.6328E+04	1.0150E+05	7.1392E+05		std	1.7103E+01	2.1350E+01	2.9144E+01	2.9582E+01
F14	best	4.9574E+03	1.8471E+04	5.0773E+04	9.5993E+04	F28	best	3.2174E+03	3.2150E+03	3.2233E+03	3.2670E+03
	mean	4.3815E+04	5.8290E+04	1.2434E+05	4.0737E+05		mean	3.2482E+03	3.2691E+03	3.2721E+03	3.3337E+03
	std	3.0140E+04	3.0478E+04	7.5137E+04	2.8950E+05		std	2.3235E+01	3.6993E+01	3.1277E+01	6.0449E+01
F15	best	1.5950E+03	2.1364E+03	1.7994E+03	9.7005E+03	F29	best	3.7722E+03	3.6556E+03	3.8282E+03	3.8825E+03
	mean	2.9020E+03	8.1641E+03	1.1872E+04	3.4115E+04		mean	3.8853E+03	3.8999E+03	4.0335E+03	4.1437E+03
	std	1.5170E+03	7.6321E+03	1.2820E+04	2.2163E+04		std	8.9678E+01	1.9425E+02	1.4719E+02	2.7717E+02
						F30	best	6.3440E+03	1.2215E+04	1.2309E+04	3.6967E+05
							mean	6.7820E+04	5.7947E+04	1.2775E+05	7.6501E+05
							std	1.1844E+05	5.5463E+04	1.3526E+05	3.6199E+05

3.4 本章小结

本章围绕多策略融合改进的雾凇算法 (IRIME) 展开研究, 通过算法设计、实验验证与策略有效性分析完成系统性探索。算法层面, 提出三项核心改进策略: 信息熵评估策略通过量化各维度不确定性分配动态权重, 平衡优化过程中的探索与利用; 拉格朗日插值法基于三维节点构建多项式近似, 快速逼近最优解, 提升局部搜索精度; 随机重启机制通过随机化迭代阈值, 刷新适应度靠后的个体, 维持种群多样性并避免早熟收敛。三者与原始雾凇算法融合, 形成完整的 IRIME 优化框架, 其时间复杂度主要由种群规模、问题维度、迭代次数及评估函数计算成本决定。实验设计包含三类验证场景: CEC 2017 基准函数对比实验中, IRIME 与八种先进算法在 30 维及 50 维环境下进行测试, 通过收敛曲线、箱线图及弗里德曼统计检验, 证实其在单模态、多模态、混合及组合函数上均具备更优的收敛速度、解质量与稳定性; 医学数据集特征选择实验中, 针对 12 个不同维度的医学数据集, IRIME 在分类准确率、适应度值及特征筛选效率上表现突出, 尤其在高维数据集上展现出强大的特征降维与分类性能; 消融实验通过系统性移除三项改进策略, 明确了拉格朗日插值法对收敛速度的关键提升作用、随机重启机制在维持多样性中的核心价值, 以及信息熵评估策略对特定函数类别的优化增益, 验证了各策略的必要性与协同效应。整体而言, IRIME 通过多策略的合理融合与协同, 有效提升了优化算法的综合性能, 在理论优化与实际医学特征选择问题中均展现出显著优势。

4 基于多策略改进的哈里斯鹰算法

4.1 引言

尽管原始 HHO 算法具备诸多优势，但在实际应用过程中仍暴露出显著缺陷：其一，算法个体位置更新仅依赖当前种群状态与最优个体信息，缺乏对历史搜索经验的有效利用，导致迭代中期种群多样性下降，易陷入局部最优解；其二，逃逸能量控制下的扰动模式固定，无法根据搜索过程的动态变化自适应平衡全局探索与局部开发的关系，难以兼顾早期广域搜索与后期精确优化的需求；其三，算法后期搜索中，优势个体集中于最优解附近，传统更新策略易引发局部振荡，导致收敛精度不足、优化效率降低。这些缺陷限制了 HHO 算法在高维复杂优化问题中的应用效果，因此，对 HHO 算法进行改进与性能提升具有重要的理论意义与实际应用价值。针对原始 HHO 算法的上述不足，本章提出一种多策略改进的哈里斯鹰优化算法 (Improved Harris Hawks Optimization, IHHO)，通过融合多种优化策略实现算法性能的全方位提升。首先，引入经验互益策略，利用历史种群的搜索经验构造引导向量，增强个体跳出局部最优的能力，改善种群中期协同搜索效果；其次，设计能量自适应 Cauchy-Gaussian 扰动策略，基于逃逸能量动态调节 Cauchy 分布与 Gaussian 分布的扰动比例，实现全局探索与局部开发的动态平衡；最后，提出精英方差引导开发策略，通过分析精英个体的空间分布特征，自适应调整局部搜索步长，提升算法后期收敛精度与稳定性。

为验证 IHHO 算法的有效性与优越性，本章设计了多组对比实验与应用验证：以 CEC 2020 基准测试函数为对象，将 IHHO 与原始 HHO 及其他先进元启发算法（白鲸优化算法 BWO、算术优化算法 AOA、正余弦优化算法 SCA、爬行动物搜索算法 RSA）进行对比，从最优值、平均值、标准差及收敛曲线等维度评估算法的优化性能；通过消融实验验证所提三种改进策略的独立作用与协同效果；采用正交实验分析算法关键参数对优化性能的影响，确定最优参数组合；进一步将 IHHO 算法应用于高维生物学数据集的特征选择问题，验证其在实际复杂问题中的应用价值。本章的研究成果旨在克服原始 HHO 算法的固有缺陷，为连续优化与高维特征选择等相关领域提供更高效、更稳定的优化解决方案，同时丰富元启发算法的改进思路与应用场景。

4.2 算法介绍

4.2.1 经验互益策略

HHO 算法个体位置更新的主要依据是种群当前的状态以及最优个体的位置信息。该方法在初探时能很好地保持搜索范围的宽与深。随着进化轮次的增多，由于种群个体间信息交流的单一化，群体多样性变小，从而导致算法很快会陷入局部最优解中。尤其是到了中期阶段，仅仅依靠代内交互不能很好地利用历史经验积累的有效信息，导致持续优化的效果不好。由此本文引入经验互益策略，它加强了种群对于过去搜索过程中的重要经验，提高了个体之间的合作水平。该策略的关键之处就在于把历史种群所拥有的经验数据转化成引导向量加入到当下的个体状态更新当中，从而提升个体跳出局部最优的潜能以及拓展解空间的探寻幅度。由于算法早期需要具有较高的随机性才能找到潜在的全局最优解，在探索 and 开发阶段的过渡区间里才使用该种经验互益策略。为了描述历

史经验对当前个体的作用，首先保存上一代种群的位置矩阵 H 。对于当前个体 X_i ，随机选取 3 个历史个体索引 r_1 、 r_2 和 r_3 ，并逐维构造 3 个经验向量 E_1^h 、 E_2^h 和 E_3^h 。其第 d 维可表示为：

$$E_{1,d}^h = \begin{cases} H_{r_1,d}, & \text{rand} < p_h \\ X_{i,d}, & \text{其他} \end{cases} \quad (\text{公式 4-1})$$

$$E_{2,d}^h = \begin{cases} H_{r_2,d}, & \text{rand} < p_h \\ X_{i,d}, & \text{其他} \end{cases} \quad (\text{公式 4-2})$$

$$E_{3,d}^h = \begin{cases} H_{r_3,d}, & \text{rand} < p_h \\ X_{i,d}, & \text{其他} \end{cases} \quad (\text{公式 4-3})$$

其， p_h 为历史经验继承概率。根据上述公式可，个体按照一定概率继承历史种群的经验信，否则保持现状。既可以使个体不偏离当前搜索路，又可以很好地将以前的经验加以整合。为了保证经验共享策略在优化中起到主导作，采用权重因子 w_t 的方式进行计，其计算公式为：

$$w_t = 1 - \frac{|2 \times \frac{t}{T} - 1|}{0.4} \quad (\text{公式 4-4})$$

其， t 为当前评估次， T 为最大评估次数。

当 $w_t < 0$ ，令 $w_t = 0$ 。权重值在搜索初期慢慢提，在后期却慢慢地降，以此来达到经验协同策略在某些时期的有效控制目的。在此基础，构造经验互益候选解如下公式所示。

$$X_{\text{embs}} = X_i + w_t \times (\alpha \times R \times (E_1^h - X_i) + \beta \times (1 - R) \times (E_2^h - E_3^h)) \quad (\text{公式 4-5})$$

其， R 为 $[0, 1]$ 上的随机向， α 和 β 分别为经验受益项与经验互补项的权重系数。

为了使经验互益策略与传统的 HHO 算法的位置更新机制互相配合工作，需要把经验互益策略产生出的候选解同 HHO 算法得到的初始候选解 X_H 进行融，从而得到改进后的经验互益候选解。融合过程可以使用如下数学式子来表示。

$$X_{\text{embs}}^{\text{final}} = X_H + w_t (X_{\text{embs}} - X_i) \quad (\text{公式 4-6})$$

4.2.1.1 策略设计背景与动机

元启发算法 (Meta-heuristic Algorithms, MAs) 在搜索过程中，种群位置的频繁迭代更新往往导致算法迅速转向新的搜索区域。这种机制虽然保证了探索范围，但容易导致对原始高质量区域的挖掘深度不足，且个体与种群之间的“搜索经验”传递效率较低。

受人类社会“群体学习与经验总结”模式的启发，本章引入一种名为经验交流策略 (Experience Exchange Strategy, EES) 的进化算子。EES 的核心逻辑是将算法在演化过程中获取的位置视为“学习经验”，通过加强个体与种群间的联系，将搜索过程动态划分为三个阶段，旨在通过经验的积累与交换来平衡算法的全局勘探 (Exploration) 与局部开发 (Exploitation) 能力。

4.2.1.2 EES 数学模型与阶段划分

EES 策略将整个进化过程（最大迭代次数为 T ）分为三个逻辑阶段：经验匮乏阶段（ESC）、经验交叉阶段（ECR）和经验共享阶段（ESH）。

经验匮乏阶段（Experience Scarcity Stage, ESC） 在算法搜索初期（ $t < T/3$ ），种群积累的经验较少。此时策略的重点是保持原算法的探索特性，同时引入初步的经验干扰以避免早期停滞。其更新公式如下：

$$X_{new}(t) = X_{orig}(t) + r_1 \cdot (X_{exp1} - X_{exp2}) \quad (\text{公式 4-7})$$

其中：

- $X_{orig}(t)$ 表示由基础元启发算法生成的原始位置。
- X_{exp1} 和 X_{exp2} 是从当前经验池中随机选择的两个经验个体。
- r_1 为 $[0, 1]$ 之间的随机数。

经验交叉阶段（Experience Crossover Stage, ECR） 当算法进入中期（ $T/3 \leq t < 2T/3$ ），种群已探索了多个区域并积累了一定经验。此时为了跳出局部最优，EES 引入更多个体的经验交换：

$$X_{new}(t) = X_{exp_best} + r_2 \cdot (X_{exp1} - X_{exp2}) + r_3 \cdot (X_{exp3} - X_i(t)) \quad (\text{公式 4-8})$$

在此阶段，个体通过与三个随机经验个体（ $X_{exp1}, X_{exp2}, X_{exp3}$ ）以及当前个体 X_i 的交叉更新，增强了信息流动的多样性，提高了搜索空间的覆盖精度。

经验共享阶段（Experience Sharing Stage, ESH） 在搜索后期（ $t \geq 2T/3$ ），种群已经识别出潜在的最优区域。此时 EES 切换至高强度的信息共享模式，通过聚合群体智慧进行精细化搜索：

$$X_{new}(t) = \frac{X_{best} + X_{exp1} + X_{exp2} + X_{exp3}}{4} \quad (\text{公式 4-9})$$

通过计算当前全局最优个体 X_{best} 与多个经验个体的平均位置，算法能够显著增强局部开发强度，提高最终解的收敛精度。

- (1) ESC 阶段：侧重于全局探索，利用少量经验差值保持种群活力。
 - (2) ECR 阶段：通过中等强度的经验交叉，辅助算法在复杂的解空间中跳出局部极值点。
 - (3) ESH 阶段：利用群体经验的聚合效应，引导所有个体向全局最优解快速收敛。
- 这种阶梯式的经验交换机制不仅增强了算法的稳健性，也为不同类型的元启发算法提供了一个通用的性能增强框架。

4.2.2 能量自适应柯西-高斯扰动策略

在原始 HHO，算法通过逃逸能量 E 控制探索阶段与开发阶段的切换。虽然逃逸能量可以反映当前的搜索状，但是它的位置扰动方式比较固，缺少根据动态变化的搜索情

景来调节扰动模式的功能。为了提高全局搜索的效，在开始的时候就要扩大搜索范，在后期逐渐减小搜索步长来加强局部优化精度。单一种类的干扰方式很难达到早期广域探索和后期精确局部开垦两个目的。本文提出一种能量自适应调节的 **Cauchy-Gaussian** 混合扰动策略。此方法用 **Cauchy** 分布的重尾性提高远距离随机跳跃的能，用 **Gaussian** 分布的正态化平稳性达到高精度局部搜索的效果。利用实时观测到的逃逸能量变化情，自主地对两种扰动分量所占比例予以改，进而改善算法在全局搜索同局部改进两者之间所取得的结果表现状况。如图 4-1 所示。



图 4-1 能量自适应柯西-高斯扰动策略示意图

Fig. 4-1 Schematic diagram of the energy adaptive Cauchy-Gaussian perturbation strategy

首先，根据逃逸能量构造归一化权重如下公式所示：

$$\omega = \min \left(1, \frac{|E|}{2} \right) \quad (\text{公式 4-10})$$

其， E 为当前个体对应的逃逸能量。当 $|E|$ 较大， ω 较，说明当前个体更倾向于执行全局探索，当 $|E|$ 较小， ω 较，说明当前个体更倾向于局部开发。随，从当前种群中随机选取一个个体 X_r ，并分别生成 **Cauchy** 随机向量 C 与 **Gaussian** 随机向量 G 。为了使 **Gaussian** 扰动在搜索后期逐渐减，其扰动尺度设置如下公式所示。

$$\sigma_t = \sigma_0 \times \left(1 - \frac{t}{T} \right) \quad (\text{公式 4-11})$$

其中， σ 为 **Gaussian** 扰动的初始尺度参数。随着算法的迭代，使用公式 4-11 构造能量自适应 **Cauchy-Gaussian** 扰动候选解。

$$X_{cg} = X_i + \omega \times C \times (X_i - X_r) + (1 - \omega) \times G \times (X_{\text{rabbit}} - X_i) \quad (\text{公式 4-12})$$

其， X_i 表示当前个， X_{rabbit} 表示全局最优个体。

4.2.3 精英方差引导开发策略

HHO 算法后期搜索过程中，由于优势个体集中在较好的解附近，如果再使用同样的位置更新策略去迭代，很容易使个体陷入局部振，从而大大降低算法的优化效率。因此必须研究精英个体的空间分布特，从而设计出一种新的区域开发方式。本文提出了一个用逐维方差来引导的精英方，用部分取代传统的完整协方差矩阵的方，保留了精英群体的统计性，又减少了由于高维空间导致的计算，给算法性能的提高提供新的技术支持。该策略的示意图在图 4-2 中进行呈现。



图 4-2 精英方差引导开发策略示意图

Fig. 4-2 Schematic of the elite variance guided development strategy

首，根据当前种群适应度值进行升序排，选取前 M 个个体构成精英子，如下公式所示。

$$M = \max(2, \lceil \rho N \rceil) \quad (\text{公式 4-13})$$

其， ρ 为精英比， N 为种群规模。设精英子集为 $\varepsilon = \{X_1, X_2, \dots, X_M\}$ ，之，进一步计算统计特征。对第 d 维而言，精英个体的样本方差定义为：

$$\text{var}_d = \text{Var}(X_{1,d}, X_{2,d}, \dots, X_{M,d}), d = 1, 2, \dots, D \quad (\text{公式 4-14})$$

之后，得到精英子集的逐维标准差向量如下公式所示。

$$\text{std}_e = \sqrt{\text{var} + \varepsilon} \quad (\text{公式 4-15})$$

其， ε 为防止数值不稳定的微小常数。由此可， std_e 能够反映精英个体在各维度上的离散程，并可作为局部搜索步长的重要依据。该策略主要作用于后期开发过，当搜索进程进入后，连续 L 次更新未获得更优解，启用精英方差引导开发策略。定义随迭代逐渐减小的步长因子为：

$$\eta_t = \eta_0 \times \left(1 - \frac{t}{T}\right) \quad (\text{公式 4-16})$$

其中, η_0 为初始步长参数。以当前全局最优个体 X_{rabbit} 为基准, 结合标准高斯随机向量 z 与精英逐维标准差向量 std_e , 构造局部开发候选解。如以下公式所示:

$$X_{\text{cov}} = X_{\text{rabbit}} + \eta_t \times (z \times \text{std}_e) \quad (\text{公式 4-17})$$

4.2.4 时间复杂度分析

算法的时间复杂度是评估其运行效率的关键指标。在时间复杂度方面, 设种群规模为 N , 问题维数为 D , 最大函数评价次数为 T 。对于所提出的改进 Harris 鹰优化算法 IHHO, 初始化种群所需时间复杂度为 $O(ND)$ 。在迭代过程, 原始 HHO 位置更新、经验互益策略、能量自适应 Cauchy-Gaussian 扰动策略以及精英方差引导开发策略均以向量逐维运算为, 其单次更新复杂度可视为 $O(D)$, 因此累计复杂度约为 $O(TD)$ 。此, 为构造精英子, 算法在每轮迭代中需对种群适应度进行排, 该部分复杂度为 $O(N \log N)$ 。在整个优化过程中累计可表示为 $O(TN \log N)$ 。综合而, IHHO 算法的总体时间复杂度可表示为 $O(TD + TN \log N)$ 。考虑到连续优化问题中目标函数计算与位置更新通常占据主要计算成本, 因此在实际应用, 算法的总体时间复杂度通常可近似看作 $O(TD)$ 。

与 HHO 相比, IHHO 的额外计算开销主要来自三部分: 一是每轮迭代的种群排序, 为算法引入 $O(TN \log N)$ 的固定开销; 二是经验互益与自适应扰动两项策略, 共带来约 2 倍于原始位置更新的逐维计算量; 三是精英方差统计带来的 $O(TND)$ 增量开销。在典型实验参数 ($N=30$ 、 $D=10 \sim 1000$) 下, IHHO 相较于原始 HHO 的额外计算量占比约为 20% 30%, 在可接受范围内, 并未显著提升算法复杂度量级, 却有效改善了原始 HHO 易陷入局部最优、后期收敛精度不足等缺陷, 在计算开销与优化性能间取得良好平衡。

4.2.5 算法实现

该算法的操作流程可以总结为如下几步:

步骤 1: 初始化种, 计算种群适应度, 确定全局最优个, 同时保存初始历史经验信息并初始化个体停滞次数。

步骤 2: 用原始 HHO 的位置更新规则产生初始解集。

步骤 3: 当搜索进程处于探索与开发衔接区间时, 采用经验互益策略对历史有益经验进行继承与重组, 生成经验互益候选解。

步骤 4: 根据实时得到的逃逸能量, 用动态调整的 Cauchy-Gaussian 扰动机制产生候选解集来达到全局搜索和局部优化。

步骤 5: 当算法进入后期阶段或个体出现连续停滞时, 采用精英方差引导开发策略生成局部开发候选解。

步骤 6: 对各候选解执行竞争选择并更新种群位置, 随后更新历史经验库与停滞计数。若达到最大评价次, 则输出全局最优, 否则继续迭代。

Algorithm 4.1: Pseudo-code of IHHO

```

1 Initialize: Population  $X$ , params  $(ph, \alpha, \beta, \sigma_0, \eta_0, L)$ , and  $t = 0$  ;
2 while  $t < T$  do
3   for  $i = 1$  to  $N$  do
4     Evaluate  $fit(i) = fobj(X_i)$  and update  $t \leftarrow t + 1$  ;
5     if  $fit(i) < Rabbit\_Energy$  then
6       | Update Best Agent:  $Rabbit\_Location \leftarrow X_i, Rabbit\_Energy \leftarrow fit(i)$  ;
7     end
8     if  $t \geq T$  then
9       | break
10    end
11  end
12   $E_1 \leftarrow 2(1 - t/T), progress \leftarrow t/T$  ;
13  for  $i = 1$  to  $N$  do
14    Generate  $X_{hho}$  via HHO rules ;
15    if  $progress \in [0.3, 0.7]$  then
16      |  $X_{embs} \leftarrow$  Experience Mutual-Benefit Strategy ;
17    else
18      |  $X_{embs} \leftarrow X_{hho}$  ;
19    end
20     $X_{cg} \leftarrow$  Energy-Adaptive Cauchy-Gaussian Perturbation ;
21    if  $progress > 0.7$  or  $stagnation(i) \geq L$  then
22      |  $X_{cov} \leftarrow$  Elite Covariance-Guided Exploitation ;
23    else
24      |  $X_{cov} \leftarrow X_{hho}$  ;
25    end
26     $X_i \leftarrow \text{argmin}(fobj(\{X_{hho}, X_{embs}, X_{cg}, X_{cov}\}))$  ;
27    Update  $stagnation\_count(i)$  based on fitness improvement ;
28  end
29   $History\_X \leftarrow X_{old}$  ;
30 end
31 return  $Rabbit\_Energy, Rabbit\_Location$  ;

```

4.3 实验设计

4.3.1 基准函数对比实验

4.3.1.1 实验准备

为了验证 IHHO 的优化效果, 本小节选取了 CEC 2020 测试函数用于验证实验。该测试集函数详情介绍在表 4-2 中展示。哈里斯鹰优化算法 (Harris Hawks optimization, HHO)、白鲸优化算法 (Beluga Whale Optimization, BWO)、算术优化算法 (arithmetic optimization algorithm, AOA)、正余弦优化算法 (Sine Cosine Algorithm, SCA) 和爬行动物搜索算法 (Reptile Search Algorithm, RSA) 作为对比实验。每个算法的种群个数 $N = 30$, 最大评价次数 $T = \text{dim} \times 10000$ 。这些算法的参数如表 4-1 所示。另外, 本实验的软硬件环境同 3.3 节中所述保持一致。

表 4-1 IHHO 对比实验中各算法参数设置表

Table 4-1 Parameter settings for each algorithm in the IHHO comparison experiment

算法	参数设定
HHO	$S = 0.01; \beta = 1.5$
BWO	$W_f \in [0.1, 0.05]$
AOA	$C_1 = 0.2; C_3 = 3; \mu = 25; \sigma = 3$
SCA	$C_1 \in [0, 2]; C_2 \in [0, 2]; C_3 \in [0, 2]$
RSA	$\alpha = 0.1; \beta = 0.005; S = 0.01; \beta = 1.5$
IHHO	$ph = 0.85; L = 5; elite_ratio = 0.2; \sigma_0 = 0.1$

表 4-2 CEC 2020 基准函数表

Table 4-2 CEC 2020 Benchmark Functions Table

函数类别	序号	函数方程	最优值
Unimodal Function	1	Shifted and Rotated Bent Cigar Function (CEC 2017 F1)	100
	2	Shifted and Rotated Schwefel's Function (CEC 2014 F11)	1100
Basic Functions	3	Shifted and Rotated Lunacek bi-Rastrigin Function (CEC 2017 F7)	700
	4	Expanded Rosenbrock's plus Griewangk's Function (CEC 2017 f_{19})	1900
Hybrid Functions	5	Hybrid Function 1 ($N = 3$) (CEC 2014 F17)	1700
	6	Hybrid Function 2 ($N = 4$) (CEC 2017 F16)	1600
	7	Hybrid Function 3 ($N = 5$) (CEC 2014 F21)	2100
Composition Functions	8	Composition Function 1 ($N = 3$) (CEC 2017 F22)	2200
	9	Composition Function 2 ($N = 4$) (CEC 2017 F24)	2400
	10	Composition Function 3 ($N = 5$) (CEC 2017 F25)	2500
搜索范围: $[-100, 100]^D$			

4.3.1.2 收敛曲线分析

figures/HH0/cov_cec2020.pdf

图 4-3 CEC 2020 对比实验收敛曲线图（10 维）
Fig. 4-3 Convergence curve of CEC 2020 comparative experiments (10D)

figures/HH0/cov_cec2020_30.pdf

图 4-4 CEC 2020 对比实验收敛曲线图（30 维）
Fig. 4-4 Convergence curve of CEC 2020 comparative experiments (30D)

表 4-3 和表 4-4 是 6 种算法在 IEEE CEC 2020 独立运行 30 次获得的统计结果，其中维度 $\text{dim} = 10$ 。从两张表的结果分析可知，在 CEC 2020 标准测试函数集上 IHHO 算法的综合性能明显好于其它比较算法。在 F1 到 F8 以及 F5 和 F6 函数中，该算法都取得了很好的均值性能，很好地表现出了它对于不同类型连续优化问题的求解能力。尤其是对于 F1、F5 和 F7 这类复杂的函数优化问题来说，IHHO 有着更为出色的表现，它不但可以大幅度地降低求解过程中出现的误差，而且还能有效地提升全局搜索能力以及鲁棒性，这再一次表明它的高维非线性优化应用前景。从标准差结果来看，采用 IHHO 算法处理的测试函数在各个维度上具有较好的一致性。其在 F2、F6、F8 和 F9 这些函数上标准差小，说明该算法具有较好的鲁棒性。虽然 IHHO 标准差不是最小的，在部分测试函数中，但是其平均性能指标最好。相对于只对某些函数性能优越、而全局最优性能却不高，其他的算法，IHHO 具有更好的综合优化能力。

原始 HHO 在解决复杂问题的时候虽然有它的优，但是它只用当前最好的个体和当前表现数据来更新位，没有利用历史的经，所以在多模态函数优化中容易造成种群多样性的下降以及后期收敛效果变差的现象。BWO 在部分测试函数上表现出较好的性，但是在 F1、F5、F7 这些高维或者非线性搜索空间的函数，它的平均结果明显偏，说明这个算法对于这类搜索空间的适应能力较，容易陷入局部最优或者无法充分探索到搜索空间中的各个角落。AOA 比 IHHO、HHO 的算术运算驱动更新容易造成高维复杂场景下步长控制失衡而降低全局开发效率。SCA 有较强的探索，但是周期性的因子会对它的行为产生很大的影，造成后期搜索轨迹的起，进而影响到收敛精度。RSA 在大多数测试函数中平均值、标准差都比其他方法，说明 RSA 对复杂的函数稳定性、鲁棒性不好，容易出现过早收敛和无效迭代。综合评价结果表，在大多数测试函数中 IHHO 算法的性能最，说明本文所提出的改进方法是具有很强适用性和较大优化效果的。

4.3.1.3 弗里德曼统计检验

为了进一步探究不同算法在 CEC 2020 测试函数集中综合表现的好坏，本文用弗里德曼 (Friedman) 统计的方法对 6 种优化算法进行了多指标排名比较，平均排名在图 4-5 和图 4-6 中进行展示。在 10 维基准测试中，IHHO 算法平均得分为 1.44，在各项评价指标上均位列第一。该结果充分表明，IHHO 具备出色的局部开发能力与稳定的全局寻优性能，同时展现出良好的普适性与实际应用潜力。在 30 维度实验中，IHHO 平均得分为 1.25，同样在所有评价指标中排名首位。这一优异表现进一步验证了其强大的局部搜索能力与稳定的全局优化特性，也印证了该算法具有较高的通用性与广阔的应用前景。具体的统计结果见表 4-5 和表 4-6。由各个函数的评价结果可知，IHHO 在所有的 F1-F8 的函数里都名列前茅，在 F9 和 F10 中也有明显的优势。在 F4 函数上，各个算法的性能差异不大，平均值也很接近，但是 IHHO 依然保持较高的位置。这就说明 F4 函数对于算法综合性能的区分度低，对于整体排名的影响也小。根据 IHHO 多次任务表现出色以及稳定的平均排名结果，可以推测出该算法优异的原因是由算法的设计和优化机制所造成的。相比于 IHHO，原始 HHO 的总体表现虽然不是最好的，但是其平均性能仍然保持在一个较高的水平上，说明它有着比较好的基础结构。在历史经验迁移、自适应参数调节和后期改良这些地方，最初的 HHO 还存在着较大的提升之处。SCA、AOA 的平均排名位于中间位置，说明它们在某些优化问题上具有一定的解题能力，但是并没有表现出很强的稳定性以及普适性，表现出的搜索机制对于问题类型适应性较低。BWO、RSA

表 4-3 各算法在 CEC 2020 的对比实验结果 (10 维)
Table 4-3 Comparative experimental results of each algorithm in CEC 2020 (10D)

函数	指标	IHHO	HHO	BWO	AOA	SCA	RSA
F1	best	1.0177E+02	6.4449E+04	2.4205E+09	9.4429E+03	1.2159E+08	5.3695E+09
	mean	2.4720E+03	2.5755E+05	6.2209E+09	3.2667E+09	5.4913E+08	9.8094E+09
	std	2.4488E+03	1.2905E+05	1.9951E+09	2.3104E+09	2.0857E+08	2.7628E+09
F2	best	1.2676E+03	1.4119E+03	1.9879E+03	1.5708E+03	1.6696E+03	2.1535E+03
	mean	1.6425E+03	1.9549E+03	2.3174E+03	2.0334E+03	2.2345E+03	2.6025E+03
	std	2.0459E+02	2.6798E+02	1.9309E+02	2.3036E+02	2.1303E+02	1.9830E+02
F3	best	7.2199E+02	7.4395E+02	7.6563E+02	7.4094E+02	7.4653E+02	7.8101E+02
	mean	7.4459E+02	7.7147E+02	7.9232E+02	7.9686E+02	7.6731E+02	8.0674E+02
	std	1.1508E+01	1.8362E+01	8.7851E+00	1.7386E+01	1.0021E+01	1.1275E+01
F4	best	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03
	mean	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9002E+03	1.9000E+03
	std	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	6.9767E-01	0.0000E+00
F5	best	2.0880E+03	2.5103E+03	1.7102E+04	4.1122E+03	4.9344E+03	1.5098E+05
	mean	6.9000E+03	2.7403E+04	1.4646E+05	3.4633E+04	1.9598E+04	4.5931E+05
	std	2.7948E+03	3.6537E+04	7.9944E+04	5.8621E+04	1.3211E+04	1.2569E+05
F6	best	1.6018E+03	1.6020E+03	1.7324E+03	1.7483E+03	1.6318E+03	1.9009E+03
	mean	1.6978E+03	1.7996E+03	1.8959E+03	1.9261E+03	1.7364E+03	2.1507E+03
	std	5.6612E+01	1.1884E+02	9.9586E+01	1.0746E+02	5.8877E+01	1.5832E+02
F7	best	2.1214E+03	2.4598E+03	4.4758E+03	2.4499E+03	3.7642E+03	7.7871E+03
	mean	4.0405E+03	1.0736E+04	2.0447E+04	6.5945E+03	9.0298E+03	2.0722E+06
	std	2.0922E+03	9.1267E+03	1.5733E+04	2.4883E+03	4.5091E+03	2.8823E+06
F8	best	2.3013E+03	2.3052E+03	2.3410E+03	2.4203E+03	2.2765E+03	2.7071E+03
	mean	2.3051E+03	2.3142E+03	2.5092E+03	2.6437E+03	2.3531E+03	3.1156E+03
	std	3.3555E+00	5.5781E+00	1.4129E+02	1.8207E+02	2.6589E+01	3.1597E+02
F9	best	2.5000E+03	2.5005E+03	2.5921E+03	2.5595E+03	2.5577E+03	2.6976E+03
	mean	2.7510E+03	2.8089E+03	2.6682E+03	2.8102E+03	2.7626E+03	2.8430E+03
	std	4.8804E+01	7.8272E+01	6.6220E+01	7.3680E+01	5.4737E+01	3.7559E+01
F10	best	2.8978E+03	2.8979E+03	3.0487E+03	2.9064E+03	2.9205E+03	3.1401E+03
	mean	2.9282E+03	2.9272E+03	3.1352E+03	3.0232E+03	2.9518E+03	3.3817E+03
	std	2.4281E+01	3.4458E+01	5.3037E+01	8.5484E+01	1.6605E+01	1.2498E+02

表 4-4 各算法在 CEC 2020 的对比实验结果 (30 维)
Table 4-4 Comparative experimental results of each algorithm in CEC 2020 (30D)

函数	指标	IHHO	HHO	BWO	AOA	SCA	RSA
F1	best	1.5917E+02	4.2185E+06	3.9447E+10	3.2362E+10	9.3365E+09	3.0205E+10
	mean	3.1964E+03	8.4882E+06	4.5256E+10	4.1825E+10	1.2252E+10	4.7685E+10
	std	4.1889E+03	1.4858E+06	3.3445E+09	6.5648E+09	1.9206E+09	7.8793E+09
F2	best	3.6018E+03	3.6611E+03	7.3472E+03	4.7589E+03	7.4225E+03	6.6028E+03
	mean	4.6503E+03	5.0494E+03	7.9246E+03	6.2065E+03	8.0162E+03	7.2526E+03
	std	5.7882E+02	8.2979E+02	2.9989E+02	5.8623E+02	2.5558E+02	3.2962E+02
F3	best	9.2850E+02	1.0612E+03	1.2075E+03	1.1554E+03	1.0545E+03	1.2921E+03
	mean	1.0225E+03	1.2019E+03	1.3422E+03	1.3039E+03	1.1200E+03	1.3637E+03
	std	4.8599E+01	8.1902E+01	4.4861E+01	5.4879E+01	3.4198E+01	3.2753E+01
F4	best	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03
	mean	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9002E+03	1.9000E+03
	std	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	1.1249E+00	0.0000E+00
F5	best	6.8122E+04	1.2488E+05	1.1856E+07	8.9012E+05	2.1794E+06	1.6764E+07
	mean	3.6094E+05	1.0556E+06	4.2430E+07	1.2017E+07	6.2495E+06	6.5493E+07
	std	1.8409E+05	8.3382E+05	1.6656E+07	1.1476E+07	2.7540E+06	2.7821E+07
F6	best	1.8250E+03	2.0229E+03	3.4845E+03	2.2747E+03	2.8309E+03	3.3766E+03
	mean	2.0777E+03	2.4955E+03	4.3394E+03	3.6961E+03	3.4328E+03	4.4828E+03
	std	1.8368E+02	3.8910E+02	3.7612E+02	1.1567E+03	2.3953E+02	6.0156E+02
F7	best	2.3548E+04	5.4336E+04	1.2224E+06	5.5506E+04	4.6012E+05	3.6125E+06
	mean	1.3835E+05	3.6699E+05	9.6681E+06	6.4842E+05	1.1763E+06	2.3206E+07
	std	1.1196E+05	2.2731E+05	5.3371E+06	5.4584E+05	4.2823E+05	1.4011E+07
F8	best	2.3000E+03	2.3174E+03	6.6118E+03	6.6001E+03	3.3777E+03	5.9590E+03
	mean	4.5776E+03	5.9354E+03	7.9295E+03	8.2014E+03	7.6919E+03	8.2032E+03
	std	2.0545E+03	2.3079E+03	4.0922E+02	6.9480E+02	2.6884E+03	1.0160E+03
F9	best	2.9045E+03	3.1015E+03	3.3258E+03	3.4160E+03	3.1083E+03	3.2566E+03
	mean	3.0064E+03	3.4143E+03	3.4408E+03	3.8085E+03	3.1641E+03	3.4083E+03
	std	5.8830E+01	1.4538E+02	5.1599E+01	2.3901E+02	2.5282E+01	2.2871E+02
F10	best	2.8836E+03	2.8849E+03	3.8626E+03	3.4001E+03	3.0903E+03	3.8520E+03
	mean	2.8938E+03	2.9069E+03	4.1699E+03	4.4851E+03	3.1934E+03	5.0113E+03
	std	1.3645E+01	1.5828E+01	1.2605E+02	4.9199E+02	5.2957E+01	6.6336E+02

的表现也较低，特别是 **RSA**，它在很多情况下都会出现测试函数中表现变坏的情况。根据 **Friedman** 检验统计分析结果可知，在综合性能上，**IHHO** 比其它对比算法都要好。



图 4-5 IHHO 与其他 5 种算法在 CEC 2020 测试集上的平均排名（10 维）
Fig. 4-5 Average ranking of IHHO with other five algorithms on the CEC 2020 test set(10D)

表 4-5 各算法弗里德曼排名结果（10 维）
Table 4-5 Friedman ranking results for each algorithm (10D)

函数	IHHO	HHO	BWO	AOA	SCA	RSA
F1	1.00	2.03	5.00	3.93	3.03	6.00
F2	1.00	2.13	4.97	2.93	3.97	6.00
F3	1.00	2.70	4.23	4.67	2.40	6.00
F4	3.42	3.42	3.42	3.42	3.92	3.42
F5	1.33	2.20	5.00	3.60	2.87	6.00
F6	1.13	2.83	4.23	4.77	2.03	6.00
F7	1.00	3.10	5.00	2.23	3.67	6.00
F8	1.10	2.10	4.00	5.00	2.80	6.00
F9	2.03	4.43	1.43	4.20	3.10	5.80
F10	1.37	1.67	4.97	3.97	3.03	6.00

4.3.2 特征选择应用

4.3.2.1 实验准备

为进一步验证 **IHHO** 在高维特征选择问题中的有效，本文选取 8 个高维数据集进行实验，这些数据集覆盖 **Breast**、**CNS**、**Colon**、**Leukemia**、**Lung**、**Ovarian** 等多种癌症类型及白血病多亚型细分场景，样本量、特征维度与类别数分布广泛，能够全面验证所提特征选择算法在不同高维生物数据场景下的有效性与适应性^[95]。本文对这些数据集并从适应度值和分类准确率两个角度对算法性能进行评价。每个算法的评估次数为 1000 次。



figures/Ftest/IHHO_DIM30_Ftest.pdf

图 4-6 IHHO 与其他 5 种算法在 CEC 2020 测试集上的平均排名 (30 维)

Fig. 4-6 Average ranking of IHHO with other five algorithms on the CEC 2020 test set (30D)

表 4-6 各算法弗里德曼排名结果 (30 维)

Table 4-6 Friedman ranking results for each algorithm (30D)

函数	IHHO	HHO	BWO	AOA	SCA	RSA
F1	1.00	2.00	5.00	4.23	3.00	5.77
F2	1.00	2.00	5.13	3.00	5.87	4.00
F3	1.00	2.97	5.00	4.00	2.03	6.00
F4	3.47	3.47	3.47	3.47	3.67	3.47
F5	1.00	2.00	5.00	3.67	3.33	6.00
F6	1.00	2.03	5.13	3.67	3.50	5.67
F7	1.00	2.00	5.00	3.07	3.93	6.00
F8	1.00	2.07	3.87	4.60	4.97	4.50
F9	1.00	3.93	4.60	5.97	2.03	3.47
F10	1.03	1.97	4.27	4.77	3.00	5.97

实验的软硬件环境同 3.3 节中所述保持一致。所用到的数据集的相关信息在表 4-7 中列出。

表 4-7 数据集信息汇总
Table 4-7 Summary of datasets

数据集名称	样本数	特征数	类别数
Brain_Tumor2	50	10368	4
Tumors_9	60	5727	9
Tumors_11	174	12534	11
Tumors_14	308	15010	26
DLBCL	77	5470	2
Leukemia	72	7131	2
Leukemia1	72	5328	3
Leukemia2	72	11226	3
Lung_Cancer	203	12601	3
Prostate_Tumor	102	10509	2

4.3.2.2 实验结果与分析

由表 4-8 可，在 Breast、CNS、Leukemia 和 Leukemia_3c 等数据集，IHHO 的平均适应度值均取得最优或接近最优结果。在 Colon、Lung 和 Ovarian 等数据，IHHO 也保持了较强竞争力。由表 4-9 可，IHHO 在 Breast 和 CNS 数据集上取得了最高平均准确，在 Leukemia 和 Leukemia_3c 数据集上准确率达到 1，表现出很强的分类能力。总体来，IHHO 在多数数据集上实现了较低适应度值与较高准确率的统，说明其能够有效选择对分类任务更有贡献的特征子集。从实证研究角度来，IHHO 算法高维特征选择方面的好处就是同时具备筛选效率和分类成绩两个方面。它的筛选能力，适应度函数值越，所选出的特征子集对于分类器的性能提升就越大。通过各个数据集上的测试可，IHHO 算法平均适应度比其它的对比方法要，说明 IHHO 算法对关键特征识别有较高的准确率和速度。分类任务上它所表现出的总效果和稳定程度更好一些。以 Breast、CNS、Leukemia 以及 Leukemia_3c 等数据集为，IHHO 不仅能取得较高的分类准确，而且能够得到低标准差的特征子，说明它所获得的特征子集有较好的重复验证性以及鲁棒，从而说明该算法对于实际应用是有可靠的、适用范围广的。与之相对，在处理高维特征选择问题的时候，各个对比算法都存在一定的缺陷。原始 HHO 在一些数据集上接近 IHHO，但是在 Leukemia_3c、Breast、CNS 等数据集上的平均适应度比后者低得，说明它的优化精度仍然不够，在迭代后期很容易陷入局部最优解中。BWO 虽然在 Colon、Ovarian 数据集上表现出一定的优，但是整体性能波动较，说明该算法对于不同数据集的特性适应性不均，不能形成稳定的算法性能。AOA 在大多数数据集中适应度值、分类准确率都比 IHHO 低很，说明它对于高维特征空间的探索比较粗，很难得到最佳的特征子集。SCA 在 Leukemia_3c、Lung 数据集上表现比较，但是由于它周期性的搜索造成的稳定性问，在复杂的高维空间中很难得到长期的效果。RSA 在大部分的数据集上适应度值、分类准确率都处在较低的水平，说明该算法对高维特征选择的问题容易受到随机性的影，不能给出较好的筛选结果以及分类性能保证。此，该方法对于所有数据集都不一定是最优的。在 Colon、Ovarian 数据集，BWO 算法适应度函数值或者分类精确度稍微占，在 Lung 数据集中 HHO、SCA 的平均分类精度比 IHHO 高。因，在一定的数据分布，某些

figures/HHO/IHHO_COV.pdf

图 4-7 IHHO 特征选择实验适应度收敛曲线图

Fig. 4-7 Fitness convergence curve of IHHO feature selection experiment

figures/HHO/IHHO_ACC.pdf

图 4-8 IHHO 特征选择实验精确度直方图

Fig. 4-8 Histogram of accuracy for IHHO versus feature selection experiments

figures/HHO/IHHO_FS_SIZE.pdf

图 4-9 IHHO 特征选择实验特征子集大小直方图

Fig. 4-9 Histogram of feature subset size for IHHO feature selection experiment

对比方法因为具有特有的更新方式而得到局部性的优势。对所有数据集的整体评价结果显，IHHO 一般都会得到低适应度和高准确，或者近似的准确，表现出较强鲁棒性和较好的泛化性。根据以上分析可，IHHO 对于高维特征的选择有较大的应用潜力和发展的空间。

表 4-8 IHHO 与其他五种算法适应度值统计结果及 Friedman 排名
Table 4-8 Friedman ranking of fitness statistical results between IHHO and other five algorithms

数据集	类型	IHHO	HHO	BWO	AOA	SCA	RSA
Breast	mean	1.0952E-01	1.5156E-01	1.3549E-01	3.1805E-01	2.1004E-01	2.9167E-01
	std	6.7010E-02	5.2390E-02	2.6891E-02	7.3611E-02	5.5040E-02	7.0646E-02
	rank	1.30	2.50	2.20	5.80	4.00	5.20
CNS	mean	3.3128E-02	6.6138E-02	1.0744E-01	2.0420E-01	4.2742E-02	1.7828E-01
	std	4.2516E-02	5.2183E-02	5.5592E-02	9.6823E-02	4.3447E-02	4.6563E-02
	rank	1.00	2.40	3.70	5.80	2.90	5.20
Colon	mean	1.6708E-02	3.3370E-02	3.3016E-02	6.3079E-02	1.7402E-02	1.6165E-01
	std	3.4682E-02	4.2533E-02	4.2594E-02	5.5940E-02	3.4820E-02	9.8749E-02
	rank	1.90	3.25	1.55	5.00	3.30	6.00
Leukemia	mean	5.6100E-05	4.7440E-04	2.0750E-04	1.2429E-02	9.1650E-04	1.2118E-02
	std	9.3600E-05	1.1926E-03	2.7580E-04	2.2875E-02	6.1400E-04	2.2304E-02
	rank	1.30	2.80	2.00	5.40	3.90	5.60
Leukemia_3c	mean	7.1400E-05	2.1629E-02	7.3640E-03	8.2831E-02	7.9140E-04	4.0470E-02
	std	1.0250E-04	3.4321E-02	2.2264E-02	6.1826E-02	1.4770E-04	4.9868E-02
	rank	1.00	3.35	2.25	6.00	3.40	5.00
Leukemia_4c	mean	7.8073E-02	7.8466E-02	7.8658E-02	8.3441E-02	6.4597E-02	1.3226E-01
	std	5.1812E-02	3.9329E-02	3.9936E-02	3.9744E-02	5.2024E-02	4.4683E-02
	rank	2.00	2.90	2.30	4.90	2.90	6.00
Lung	mean	1.7660E-02	1.4080E-02	2.8808E-02	2.2664E-02	1.6074E-02	3.7482E-02
	std	2.0312E-02	1.3924E-02	1.8443E-02	1.6692E-02	2.1001E-02	3.3035E-02
	rank	1.40	2.20	4.50	4.60	2.70	5.60
Ovarian	mean	7.9396E-03	9.9170E-03	5.9459E-03	7.0401E-02	3.8314E-02	5.8423E-02
	std	1.3845E-02	1.0442E-02	9.5637E-03	4.9303E-02	3.0227E-02	2.2976E-02
	rank	2.00	2.55	1.45	5.50	4.00	5.50

4.3.3 消融实验

为精准验证本文所提三种改进策略的实际优化效能及协同工作机制，基于控制变量原则，本文在 CEC 2020 标准测试函数集上开展了系统性消融实验。本次实验的参数配置、运行环境、迭代次数、种群规模等核心设置均与前文基准实验完全一致，仅通过逐一剔除对应改进策略的方式构建对比算法，最大程度保证不同算法对比的公平性与有效性。其中，IHHO 为集成三种改进策略的完整优化算法；IHHO1 为剔除经验互益策略后的算法变体；IHHO2 为剔除能量自适应 Cauchy-Gaussian 扰动策略后的算法变体；IHHO3 为剔除精英方差引导开发策略后的算法变体。

综合消融实验的整体测试结果可见，融合了全部三种改进策略的完整 IHHO 算法，依旧展现出卓越的综合优化竞争力。以函数求解平均值作为核心评价指标，IHHO 算法在 F1、F4、F7 和 F10 测试函数上均取得最优求解结果，在 F3、F8 函数上也保持着极强的性能优势；从最优值指标分析，IHHO 在 F1、F3、F4、F7、F8、F9、F10 等多个函数上均斩获最优值或并列最优值。上述结果充分证明，三种改进策略协同作用后，可有效驱动算法在全局探索能力、局部开发能力与求解结果稳定性之间实现高效平衡，充分发挥了多策略融合的增益效果。

表 4-9 IHHO 与其他五种算法准确率统计结果及 Friedman 排名
Table 4-9 Friedman ranking of accuracy statistical results between IHHO and other five algorithms

数据集	类型	IHHO	HHO	BWO	AOA	SCA	RSA
Breast	mean	8.8947E-01	8.4737E-01	8.6316E-01	6.8421E-01	7.8947E-01	7.1053E-01
	std	6.7720E-02	5.2338E-02	2.7179E-02	7.4432E-02	5.5479E-02	7.1264E-02
	rank	1.40	2.50	2.20	5.70	3.90	5.30
CNS	mean	9.6667E-01	9.3333E-01	8.9167E-01	8.0000E-01	9.5833E-01	8.2500E-01
	std	4.3033E-02	5.2705E-02	5.6246E-02	9.7816E-02	4.3921E-02	4.7304E-02
	rank	1.80	2.60	3.75	5.55	2.00	5.30
Colon	mean	9.8333E-01	9.6667E-01	9.6667E-01	9.4167E-01	9.8333E-01	8.4167E-01
	std	3.5136E-02	4.3033E-02	4.3033E-02	5.6246E-02	3.5136E-02	9.9768E-02
	rank	2.60	3.10	3.10	3.85	2.60	5.75
Leukemia	mean	1.0000E+00	1.0000E+00	1.0000E+00	9.9286E-01	1.0000E+00	9.9286E-01
	std	0.0000E+00	0.0000E+00	0.0000E+00	2.2588E-02	0.0000E+00	2.2588E-02
	rank	3.40	3.40	3.40	3.70	3.40	3.70
Leukemia_3c	mean	1.0000E+00	9.7857E-01	9.9286E-01	9.2143E-01	1.0000E+00	9.6429E-01
	std	0.0000E+00	3.4503E-02	2.2588E-02	6.2543E-02	0.0000E+00	5.0508E-02
	rank	2.70	3.45	2.90	5.35	2.70	3.90
Leukemia_4c	mean	9.2143E-01	9.2143E-01	9.2143E-01	9.2143E-01	9.3571E-01	8.7143E-01
	std	5.2705E-02	4.0546E-02	4.0546E-02	4.0546E-02	5.2705E-02	4.5175E-02
	rank	3.25	3.25	3.25	3.25	2.65	5.35
Lung	mean	9.8250E-01	9.8750E-01	9.7250E-01	9.8250E-01	9.8500E-01	9.6750E-01
	std	2.0582E-02	1.3176E-02	1.8447E-02	1.6874E-02	2.1082E-02	3.3437E-02
	rank	3.20	2.65	4.40	3.20	2.95	4.60
Ovarian	mean	9.9200E-01	9.9000E-01	9.9400E-01	9.3400E-01	9.6200E-01	9.4600E-01
	std	1.3984E-02	1.0541E-02	9.6609E-03	4.9933E-02	3.0478E-02	2.3190E-02
	rank	2.15	2.30	2.00	5.40	3.85	5.30

从各消融变体的性能表现来看，剔除能量自适应扰动策略的 IHHO2 算法性能缺陷最为突出。该算法在优化过程中表现出明显的能力不足，尤其在 F1 和 F7 函数上，其求解平均值分别达到 17568 与 6230，远差于完整 IHHO 算法。这一结果直接表明，能量自适应扰动策略是提升算法全局搜索广度、帮助算法突破局部最优的核心关键模块。剔除经验互益策略的 IHHO1 仅在 F5、F6 函数上取得更优平均值，而剔除精英方差引导开发策略的 IHHO3 则在 F2、F3、F8 函数上表现更佳。该规律清晰揭示了各策略的功能侧重：经验互益策略主要作用于算法优化中期，能够有效强化种群个体间的信息交互与协同搜索能力；精英方差引导开发策略则聚焦于优化后期，精准提升算法的局部精细开发精度。

总体而言，本文提出的三种改进策略功能定位清晰、互补性极强，不存在冗余重叠的优化环节。三者协同配合弥补了单一策略的性能短板，最终使得完整 IHHO 算法突破了单一改进策略的局限，获得了更均衡、更全面的综合优化性能。

4.3.4 参数敏感度实验

表 4-11 列出了正交实验中各算法编号对应的参数组合。本文将 ph 、 L 、 $elite_ratio$ 和 θ_0 作为待分析的关键参数，基于正交试验设计构建 9 组实验方案，依次编号为 IHHO1 IHHO9。该方法可在有效控制实验规模的前提下，精准剖析不同参数组合对算法求解性能的影响规律，同时为算法最优参数的确定提供实验依据。

表 4-4 中是种群大小 $N=30$ ， $dim=30$ ，每个算法在 IEEE CEC 2020 独立运行 30 次获得的统计结果。由表中的各测试函数的实验结果可以看出，不同参数组合对 IHHO 的求解性能存在较为明显的影响，说明参数设置对算法的搜索行为具有直接作用。从具体结

表 4-10 IHHO 消融实验结果表
Table 4-10 Table of results from IHHO ablation experiments

函数	指标	IHHO	IHHO1	IHHO2	IHHO3
F1	best	1.0018E+02	1.7902E+02	9.2018E+02	1.2415E+02
	mean	3.0254E+03	3.1216E+03	1.7568E+04	3.9893E+03
	std	2.2721E+03	3.3248E+03	1.9181E+04	2.5060E+03
F2	best	1.2610E+03	1.2221E+03	1.7288E+03	1.1418E+03
	mean	1.6731E+03	1.6899E+03	1.9930E+03	1.6512E+03
	std	2.2021E+02	2.9642E+02	1.9724E+02	2.8937E+02
F3	best	7.2341E+02	7.3181E+02	7.5943E+02	7.2652E+02
	mean	7.4596E+02	7.4276E+02	7.7416E+02	7.4135E+02
	std	1.6991E+01	8.7682E+00	1.0967E+01	9.3579E+00
F4	best	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03
	mean	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03
	std	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00
F5	best	2.6195E+03	1.8410E+03	2.7476E+03	2.6143E+03
	mean	7.4796E+03	6.3820E+03	6.5101E+03	6.6371E+03
	std	3.0718E+03	4.4063E+03	3.3049E+03	2.7903E+03
F6	best	1.6014E+03	1.6011E+03	1.6015E+03	1.6017E+03
	mean	1.7046E+03	1.6642E+03	1.7256E+03	1.6844E+03
	std	7.8501E+01	8.4399E+01	7.9622E+01	6.6736E+01
F7	best	2.1817E+03	2.4816E+03	2.6214E+03	2.2234E+03
	mean	3.4717E+03	4.2014E+03	6.2303E+03	3.7143E+03
	std	2.0093E+03	1.3367E+03	4.6270E+03	2.3667E+03
F8	best	2.2379E+03	2.3028E+03	2.3027E+03	2.2428E+03
	mean	2.2985E+03	2.3052E+03	2.3123E+03	2.2921E+03
	std	2.1477E+01	2.2391E+00	5.8756E+00	2.5791E+01
F9	best	2.5000E+03	2.5000E+03	2.5004E+03	2.7466E+03
	mean	2.7068E+03	2.7364E+03	2.7750E+03	2.7565E+03
	std	1.0946E+02	8.3593E+01	1.0364E+02	5.6626E+00
F10	best	2.8977E+03	2.9452E+03	2.8985E+03	2.8979E+03
	mean	2.9299E+03	2.9472E+03	2.9312E+03	2.9331E+03
	std	2.7698E+01	2.8430E+00	2.8388E+01	2.3556E+01

果来看，各组参数在不同函数上的优势并不完全一致。例如，IHHO6 在 F1 上取得了较好的平均值，IHHO7 在 F2 上表现较优，IHHO4 在 F3 上更具优势，IHHO8 在 F7 上取得了较好的结果，IHHO5 则在 F10 上表现突出。这表明，不同测试函数对搜索步长、精英保留比例以及初始扰动强度的要求并不相同，单一参数组合难以在所有问题上同时保持绝对优势。从整体趋势上看，部分参数组合虽然在个别函数上能够取得较小的最优值，但其平均值或标准差并不占优；相反，一些组合虽然不是在所有函数上排名第一，却能够在多数测试问题上保持较稳定的结果。这说明，在参数选择过程中，不能仅依据单次最优值判断参数优劣，还应结合平均值与标准差对算法的精度和稳定性进行综合评价。基于上述结果，本文最终参数的确定并非依赖某一测试函数上的局部最优表现，而是在综合考虑多类函数上的整体求解效果后选取，从而使 IHHO 在不同类型问题上均能够保持较好的平衡性能。

表 4-11 IHHO 算法参数敏感度正交实验方案表 ($L_9(3^4)$)
Table 4-11 Orthogonal experiments on parameter sensitivity of IHHO ($L_9(3^4)$)

实验编号	ph	L	$elite_ratio$	σ_0
1	0.75	3	0.1	0.05
2	0.75	5	0.2	0.1
3	0.75	7	0.3	0.15
4	0.85	3	0.2	0.15
5	0.85	5	0.3	0.05
6	0.85	7	0.1	0.1
7	0.95	3	0.3	0.1
8	0.95	5	0.1	0.15
9	0.95	7	0.2	0.05

4.4 本章小结

本章针对原始哈里斯鹰优化算法易陷入局部最优、后期收敛精度不足等问，本文提出一种多策略改进的哈里斯鹰优化算法。算法从三个层面进行增强。引入经验互益策，利用历史信息提升跳出局部最优的能力。设计能量自适应 Cauchy-Gaussian 扰动策，根据逃逸能量动态平衡全局探索与局部开发。提出精英方差引导开发策略，依据精英方差调整搜索步长，提高后期收敛精度。与其他先进算法比较，IHHO 在 Friedman 平均排名 1.44、收敛速度与鲁棒性上均显著优于对比算法。进一步，将 IHHO 应用于 8 个高维生物医学数据集的特征选择问题，其在多数数据集上取得了更低的分类错误率与更高的准确率，证明了其在特征筛选中的有效性。综上所述，IHHO 有效克服了原始算法的缺陷，在连续优化与高维特征选择中均表现出优越性，为相关优化问题提供了更高效的解决方案。

表 4-12 IHHO 参数敏感度实验结果表
Table 4-12 Table of experimental results of IHHO parameter sensitivity

函数	指标	IHHO	IHHO1	IHHO2	IHHO3	IHHO4	IHHO5	IHHO6	IHHO7	IHHO8	IHHO9
F1	best	1.0653E+02	1.0408E+02	1.0004E+02	1.2821E+02	1.1149E+02	2.4195E+02	1.0601E+02	1.0437E+02	1.0059E+02	1.0203E+02
	mean	4.0855E+03	3.3830E+03	3.5751E+03	4.1623E+03	4.6495E+03	4.0018E+03	3.1267E+03	3.7856E+03	3.5602E+03	3.9361E+03
	std	3.0449E+03	3.0103E+03	2.8069E+03	3.5317E+03	3.8468E+03	3.4639E+03	2.8527E+03	3.5382E+03	3.7576E+03	3.8772E+03
F2	best	1.2701E+03	1.2414E+03	1.2411E+03	1.2303E+03	1.2452E+03	1.2320E+03	1.1535E+03	1.1038E+03	1.2584E+03	1.1619E+03
	mean	1.5512E+03	1.6185E+03	1.6302E+03	1.6464E+03	1.6615E+03	1.6710E+03	1.6759E+03	1.5366E+03	1.5616E+03	1.5778E+03
	std	1.6030E+02	2.8756E+02	1.8876E+02	2.2928E+02	2.3113E+02	2.2160E+02	2.3057E+02	2.5906E+02	1.8740E+02	2.2040E+02
F3	best	7.2318E+02	7.2466E+02	7.1828E+02	7.1876E+02	7.1960E+02	7.3194E+02	7.1995E+02	7.2527E+02	7.2059E+02	7.2476E+02
	mean	7.4543E+02	7.4393E+02	7.4320E+02	7.4352E+02	7.3928E+02	7.4638E+02	7.4605E+02	7.4701E+02	7.4429E+02	7.4596E+02
	std	9.5907E+00	1.2241E+01	1.1033E+01	1.2486E+01	1.2585E+01	8.9605E+00	1.3444E+01	1.4204E+01	1.2463E+01	1.2919E+01
F4	best	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03
	mean	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03	1.9000E+03
	std	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00	0.0000E+00
F5	best	2.0285E+03	2.1192E+03	1.8098E+03	1.8699E+03	2.4353E+03	2.1233E+03	2.0488E+03	1.9134E+03	2.0927E+03	1.9709E+03
	mean	5.3301E+03	7.3862E+03	5.6553E+03	6.0929E+03	6.3933E+03	5.4953E+03	6.9265E+03	5.8670E+03	7.0023E+03	5.7600E+03
	std	3.2313E+03	2.7877E+03	2.7164E+03	3.2029E+03	2.8652E+03	2.9312E+03	3.4217E+03	3.3036E+03	3.8168E+03	2.7207E+03
F6	best	1.6013E+03	1.6010E+03	1.6014E+03	1.6015E+03	1.6006E+03	1.6015E+03	1.6012E+03	1.6010E+03	1.6013E+03	1.6012E+03
	mean	1.6933E+03	1.6683E+03	1.6900E+03	1.6877E+03	1.7001E+03	1.6949E+03	1.6768E+03	1.6762E+03	1.6984E+03	1.6953E+03
	std	8.3565E+01	7.0602E+01	7.3667E+01	7.5737E+01	8.7687E+01	7.9670E+01	6.4695E+01	8.0060E+01	6.5867E+01	6.3855E+01
F7	best	2.2797E+03	2.1207E+03	2.2020E+03	2.1391E+03	2.2349E+03	2.2221E+03	2.1462E+03	2.1588E+03	2.2813E+03	2.1183E+03
	mean	3.8601E+03	3.9023E+03	3.2848E+03	3.5764E+03	3.6005E+03	3.2662E+03	3.5627E+03	3.3069E+03	3.1677E+03	3.4309E+03
	std	1.6374E+03	1.7599E+03	1.2976E+03	1.3595E+03	1.7672E+03	1.1150E+03	1.6915E+03	1.2473E+03	1.0036E+03	1.1387E+03
F8	best	2.2383E+03	2.2306E+03	2.2179E+03	2.2283E+03	2.3010E+03	2.2455E+03	2.2262E+03	2.2225E+03	2.2114E+03	2.2344E+03
	mean	2.3015E+03	2.3023E+03	2.2956E+03	2.2993E+03	2.3052E+03	2.3027E+03	2.3033E+03	2.2988E+03	2.2997E+03	2.3033E+03
	std	1.7177E+01	1.8025E+01	2.3736E+01	2.3237E+01	3.9629E+00	1.1174E+01	1.4892E+01	2.3509E+01	2.1798E+01	1.3306E+01
F9	best	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03	2.5000E+03
	mean	2.7491E+03	2.7482E+03	2.7243E+03	2.7226E+03	2.7498E+03	2.7281E+03	2.7422E+03	2.7397E+03	2.7407E+03	2.7397E+03
	std	4.8043E+01	4.7682E+01	8.9913E+01	8.9232E+01	4.8022E+01	7.8089E+01	6.6510E+01	6.5816E+01	6.6340E+01	6.5910E+01
F10	best	2.8977E+03	2.8979E+03	2.8979E+03	2.8981E+03	2.6001E+03	2.6002E+03	2.8979E+03	2.8979E+03	2.8987E+03	2.8979E+03
	mean	2.9331E+03	2.9345E+03	2.9406E+03	2.9344E+03	2.9130E+03	2.9019E+03	2.9288E+03	2.9350E+03	2.9296E+03	2.9297E+03
	std	2.5007E+01	2.3894E+01	2.5539E+01	2.3843E+01	6.4650E+01	8.5543E+01	2.5466E+01	2.2198E+01	2.3255E+01	2.3425E+01

5 总结与展望

5.1 全文总结

本文针对高维医学数据集在处理过程中面临的特征维度高、计算资源消耗大、模型性能受冗余特征干扰等挑战，深入研究了元启发算法在特征选择任务中的应用。通过对雾凇算法和哈里斯鹰优化算法的改进，提出了两种综合性能更优的算法，并验证了其在医学高维特征选择场景下的实用价值。主要研究工作总结如下：

- (1) 改进雾凇算法 (IRIME) 的提出与验证：针对原始雾凇算法 (RIME) 收敛速度慢、易陷入局部最优等问题，融合信息熵评估策略、拉格朗日插值法与随机重启机制构建 IRIME。信息熵评估策略通过动态特征加权增强种群多样性，拉格朗日插值法通过多项式逼近加速全局最优解收敛，随机重启机制有效避免早熟收敛。在 CEC 2017 基准函数测试中，IRIME 在 30 维和 50 维场景下的弗里德曼排名分别为 1.31 和 1.21，显著优于原始 RIME 及其他 7 种对比算法；在 8 个中低维度医学数据集和 4 个高维医学数据集的特征选择实验中，IRIME 在适应度值、分类准确率和特征子集精简度上均表现突出，尤其在 ALLAML 高维数据集上实现 100% 分类准确率，验证了其在医学特征选择中的实用价值。
- (2) 改进哈里斯鹰优化算法 (IHHO) 的提出与验证：为解决原始哈里斯鹰优化算法迭代中种群多样性下降、后期收敛精度不足等问题，设计融合多策略的 IHHO。引入经验互益策略整合历史搜索信息，提升跳出局部最优的能力；构建能量自适应柯西 - 高斯扰动策略，动态平衡全局探索与局部开发；提出精英方差引导开发策略，优化后期局部搜索精度。在 CEC 2020 基准函数测试中，IHHO 的弗里德曼平均排名达 1.44，优于原始 HHO 及 5 种经典群智能算法；在 8 个高维医学数据集的特征选择实验中，IHHO 在 Breast、CNS、Leukemia 等数据集上取得更低的平均适应度值和更高的分类准确率，部分数据集准确率达 100%，所选特征子集兼具强判别性与泛化性，有效实现高维特征的精准筛选与冗余消除。
- (3) 核心技术贡献：本文通过多策略融合的设计思路，针对性解决了元启发算法在医学高维特征选择中的核心痛点。两种改进算法均通过基准函数测试验证了优化性能的优越性，再通过真实医学数据集实验验证了实际应用价值，为医学高维数据的特征选择提供了两种可靠的技术方案，丰富了元启发算法在生物医学领域的应用场景。

5.2 未来研究展望

本文针对医学数据集特征选择任务所提出的 IRIME 算法与 IHHO 算法，凭借优化后的搜索机制、适配医学数据特性的筛选策略，在多组公开医学数据集上完成了有效测试，不仅大幅剔除了冗余、干扰特征，降低了数据维度与计算开销，还有效提升了后续分类任务的准确率与鲁棒性，在医学数据特征选择领域展现出了优异的性能与实用价值，取得了较为理想的实验效果。但受限于当前实验条件、算法设计思路以及医学数据的复杂性，两种算法依旧存在一定的改进余地，在泛化能力、运行效率、适配场景等方面仍有进一步优化与拓展的空间，结合领域发展需求与技术前沿趋势，未来可从以下几个方向开展更加深入、细致的研究工作：

- (1) 算法性能的进一步优化：当前两种算法的改进策略虽已实现协同增效，但在超大规模医学数据集场景下，仍可能面临计算效率不足的问题。未来可探索引入代理模型技术，通过构建简化模型替代复杂的适应度函数计算，降低算法时间复杂度；同时，可研究自适应参数调节机制，减少算法对人工调参的依赖，提升其在不同类型医学数据集中的泛化能力。
- (2) 多目标特征选择模型的构建：现有研究主要聚焦于分类准确率最大化与特征维度最小化的单目标或复合目标优化，而医学特征选择实际还需考虑特征的临床可解释性、检测成本等多维度目标。未来可构建多目标优化框架，将临床实用性指标纳入目标函数，实现性能、效率、与实用性的多维度平衡，更好地满足临床实践需求。
- (3) 与深度学习模型的融合应用：当前算法主要与传统机器学习模型结合进行特征选择，未来可探索将改进算法与深度学习模型深度融合。一方面，利用元启发算法优化深度学习模型的输入特征子集，降低模型训练成本；另一方面，可尝试将改进算法用于深度学习模型的超参数优化，实现特征选择与模型优化的协同，进一步提升医学数据处理的精度与效率。

参考文献

- [1] IQBAL N, KUMAR P. From data science to bioscience: Emerging era of bioinformatics applications, tools and challenges[J]. *Procedia Computer Science*, 2023, 218: 1516-1528.
- [2] NGUYEN N H, PICETTI D, DULAI P S, et al. Machine learning-based prediction models for diagnosis and prognosis in inflammatory bowel diseases: a systematic review[J]. *Journal of Crohn's and Colitis*, 2022, 16(3): 398-413.
- [3] THENG D, BHOYAR K K. Feature selection techniques for machine learning: a survey of more than two decades of research[J]. *Knowledge and Information Systems*, 2024, 66(3): 1575-1637.
- [4] SADEGHIAN Z, AKBARI E, NEMATZADEH H, et al. A review of feature selection methods based on meta-heuristic algorithms[J]. *Journal of Experimental & Theoretical Artificial Intelligence*, 2025, 37(1): 1-51.
- [5] AZMAN N S, SAMAH A A, LIN J T, et al. Support vector machine-recursive feature elimination for feature selection on multi-omics lung cancer data[J]. *Prog Microbes Mol Biol*, 2023, 6(1): a0000327.
- [6] ASIF S, WENHUI Y, UR REHMAN S, et al. Advancements and prospects of machine learning in medical diagnostics: unveiling the future of diagnostic precision[J]. *Archives of Computational Methods in Engineering*, 2025, 32(2): 853-883.
- [7] PUDJIHARTONO N, FADASON T, KEMPA-LIEHR A W, et al. A review of feature selection methods for machine learning-based disease risk prediction[J]. *Frontiers in bioinformatics*, 2022, 2: 927312.
- [8] BOMMERT A, SUN X, BISCHL B, et al. Benchmark for filter methods for feature selection in high-dimensional classification data[J]. *Computational Statistics & Data Analysis*, 2020, 143: 106839.
- [9] AUTHOR B. Embedded feature selection methods: A review[J]. *Journal of Machine Learning Research*, 2019, 20: 1-30.
- [10] MALDONADO S, et al. Review of feature selection methods[J]. *Information Sciences*, 2022, 582: 1-20.
- [11] BABALIK A, et al. Binary optimization for feature selection[J]. *Expert Systems with Applications*, 2024, 235: 121111.
- [12] PENG H, LONG F, DING C. Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2005, 27(8): 1226-1238.

- [13] HUSSIEN A, et al. S-shaped transfer functions for binary particle swarm optimization[J]. *Swarm and Evolutionary Computation*, 2019, 44: 1-10.
- [14] GONZALEZ A, et al. New wrapper feature selection method[J]. *Knowledge-Based Systems*, 2019, 163: 1-15.
- [15] BREZOČNIK L, FISTER JR I, PODGORELEC V. Swarm intelligence algorithms for feature selection: a review[J]. *Applied sciences*, 2018, 8(9): 1521.
- [16] ALY M, ALOTAIBI A S. Hybrid butterfly-grey wolf optimization (hb-gwo): A novel metaheuristic approach for feature selection in high-dimensional data[J]. *Statistics, Optimization & Information Computing*, 2025, 13(6): 2575-2600.
- [17] CHEN Z, FU B, YANG Y. A novel elite-guided hybrid metaheuristic algorithm for efficient feature selection[J]. *Biomimetics*, 2025, 10(11): 747.
- [18] CAI T, MA F, YE Z, et al. Dynamic niche technology based hybrid breeding optimization algorithm for multimodal feature selection[J]. *Scientific Reports*, 2025, 15(1): 8001.
- [19] KAMAL R, AMIN E, ABDELMINAAM D S, et al. A comprehensive survey on metaheuristic algorithms for feature selection in high-dimensional data: challenges, applications, and future directions[C]//2024 International Mobile, Intelligent, and Ubiquitous Computing Conference (MIUCC). IEEE, 2024: 84-90.
- [20] JIA W, SUN M, LIAN J, et al. Feature dimensionality reduction: a review[J]. *Complex & Intelligent Systems*, 2022, 8(3): 2663-2693.
- [21] HUANG C, WANG M, ASGHAR H A, et al. Q-learning enhanced differential evolution for feature selection in high-dimensional medical data analysis[J]. *Journal of King Saud University Computer and Information Sciences*, 2025, 37(9): 280.
- [22] KAUR S, KUMAR Y, KOUL A, et al. A systematic review on metaheuristic optimization techniques for feature selections in disease diagnosis: Open issues and challenges: S. kaur et al.[J]. *Archives of Computational Methods in Engineering*, 2023, 30(3): 1863-1895.
- [23] NASKAR A, PRAMANIK R, HOSSAIN S S, et al. Late acceptance hill climbing aided chaotic harmony search for feature selection: An empirical analysis on medical data[J]. *Expert Systems with Applications*, 2023, 221: 119745.
- [24] DHINAKARAN D, SRINIVASAN L, RAJA S E, et al. Synergistic feature selection and distributed classification framework for high-dimensional medical data analysis[J]. *MethodsX*, 2025, 14: 103219.
- [25] WOLPERT D H, MACREADY W G. No free lunch theorems for optimization[J]. *IEEE Transactions on Evolutionary Computation*, 1997, 1(1): 67-82.

- [26] KARIMI M, et al. Machine learning and optimization[J]. Journal of Optimization Theory and Applications, 2022, 192: 1-25.
- [27] SS A. Nature-inspired optimization algorithms: A comprehensive review[J]. Archives of Computational Methods in Engineering, 2022, 29: 1-30.
- [28] LIANG J, LOU Y, YU M, et al. A survey of surrogate-assisted evolutionary algorithms for expensive optimization: J. liang et al.[J]. Journal of Membrane Computing, 2025, 7 (2): 108-127.
- [29] PRIYADARSHI R, KUMAR R R. Evolution of swarm intelligence: a systematic review of particle swarm and ant colony optimization approaches in modern research[J]. Archives of Computational Methods in Engineering, 2025, 32(6): 3609-3650.
- [30] ZHAO W, et al. Triangulation topology-based optimization[J]. Information Sciences, 2024, 650: 119666.
- [31] LIAO X, et al. Genetic algorithm improvements for optimization[J]. Applied Soft Computing, 2023, 132: 109867.
- [32] SONG Y, et al. Dynamic differential evolution[J]. IEEE Transactions on Evolutionary Computation, 2023, 27: 1-15.
- [33] WANG G, et al. Ant colony optimization for feature selection[J]. Expert Systems with Applications, 2021, 168: 114299.
- [34] DU Z, et al. Orderly particle swarm optimization[J]. Information Sciences, 2023, 625: 1-20.
- [35] XUE J, SHEN B. A novel sparrow search algorithm[J]. Systems Science & Control Engineering, 2020, 8(1): 22-34.
- [36] ALSATTAR H, et al. Bald eagle search algorithm[J]. Artificial Intelligence Review, 2020, 53: 1-25.
- [37] DHIMAN G, KUMAR V. Seagull optimization algorithm: Theory and its applications for industrial engineering problems[J]. Knowledge-Based Systems, 2019, 165: 169-196.
- [38] VINCENT C, et al. Simulated annealing: A review[J]. Engineering Applications of Artificial Intelligence, 2022, 112: 104867.
- [39] WANG J, et al. Modified sine cosine algorithm[J]. Expert Systems with Applications, 2021, 170: 114539.
- [40] MENG Z, et al. Novel water cycle algorithm[J]. Applied Soft Computing, 2023, 136: 110065.

-
- [41] ATASHPAZ-GARGARI E, LUCAS C. Imperialist competitive algorithm: An algorithm for optimization inspired by imperialistic competition[J]. IEEE Congress on Evolutionary Computation, 2007: 4661-4667.
- [42] WANG L, et al. Status-based optimization algorithm[J]. Knowledge-Based Systems, 2025, 285: 111333.
- [43] COELLO C. Efficient cultural algorithm[J]. Evolutionary Computation, 2004, 12: 1-20.
- [44] TIWARI S, et al. Developments in differential evolution[J]. Swarm and Evolutionary Computation, 2024, 84: 101456.
- [45] DHAR J, et al. Covariance matrix adaptation for gwo[J]. Applied Soft Computing, 2022, 118: 108499.
- [46] PENG H, et al. Q-learning based hho (ehho)[J]. Expert Systems with Applications, 2024, 238: 122155.
- [47] ZHANG Y, et al. Velocity-based grey wolf optimizer (vgwo-awlo)[J]. Knowledge-Based Systems, 2024, 286: 111366.
- [48] DEEP K, et al. Random walk grey wolf optimizer (rwgwo)[J]. Applied Intelligence, 2022, 52: 1-20.
- [49] PHAM Q, et al. Enhancing sine cosine algorithm with adversarial learning[J]. Engineering Applications of Artificial Intelligence, 2024, 128: 107388.
- [50] ZHANG M, et al. Msig algorithm for flow shop scheduling[J]. Computers & Industrial Engineering, 2025, 188: 109888.
- [51] MEJIA-DE-DIOS J, et al. Bi-level evolutionary algorithm for supply chain[J]. Applied Soft Computing, 2025, 152: 111222.
- [52] SHAHEEN A, et al. Enhanced fractional-order kepler optimizer (foko)[J]. Energy, 2024, 288: 129777.
- [53] LIU B, et al. Kriging-assisted differential evolution (kdpde)[J]. IEEE Transactions on Cybernetics, 2024, 54: 1-14.
- [54] YU C, et al. Particle swarm optimization with team cooperation[J]. Information Sciences, 2025, 660: 119888.
- [55] OZDEMIR H, et al. Improved marine predator algorithm (stmpa)[J]. Applied Soft Computing, 2024, 151: 111100.
- [56] SU H, et al. Discrete adaptive grey wolf optimization (dagwo)[J]. Expert Systems with Applications, 2025, 240: 122555.

- [57] SU H, ZHAO D, et al. Rime: A physics-based optimization[J]. *Neurocomputing*, 2023, 532: 183-214.
- [58] DORIGO M, STÜTZLE T. Ant colony optimization[M]. MIT press, 2007.
- [59] ZHONG K, et al. Srime: Enhanced rime with latin hypercube sampling[J]. *Engineering Applications of Artificial Intelligence*, 2024, 129: 107666.
- [60] GUO L, et al. Improved rime for lung cancer image segmentation[J]. *Computers in Biology and Medicine*, 2024, 168: 107777.
- [61] HOSNEY M, et al. Efficient rime with orthogonal learning for bladder cancer diagnosis [J]. *Biomedical Signal Processing and Control*, 2024, 88: 105666.
- [62] CHEN H, et al. Terime for photovoltaic parameter extraction[J]. *Energy Conversion and Management*, 2025, 300: 117888.
- [63] WANG X, et al. Cgwrime: Collaborative and competitive rime[J]. *Knowledge-Based Systems*, 2025, 288: 111444.
- [64] GU Y, et al. Multi-strategy improved rime for usv path planning[J]. *Ocean Engineering*, 2024, 292: 116555.
- [65] ZHENG J, et al. Stochastic rime for image segmentation[J]. *Pattern Recognition*, 2024, 146: 110022.
- [66] ABU KHURMA R, BRAIK M, ALZaqEBAH A, et al. Advanced rime architecture for global optimization and feature selection[J]. *Journal of Big Data*, 2024, 11(1): 89.
- [67] WANG L, XU J, JIA L, et al. Multi-strategy rime optimization algorithm for feature selection of network intrusion detection[J]. *Computers & Security*, 2025, 153: 104393.
- [68] WU H, CHEN Y, ZHU W, et al. Feature selection in high-dimensional data: an enhanced rime optimization with information entropy pruning and dbscan clustering[J]. *International journal of machine learning and cybernetics*, 2024, 15(9): 4211-4254.
- [69] HEIDARI A A, MIRJALILI S, FARIS H, et al. Harris hawks optimization: Algorithm and applications[J]. *Future generation computer systems*, 2019, 97: 849-872.
- [70] PHAM Q V, HUYNH-THE T, ALAZAB M, et al. Sum-rate maximization for uav-assisted visible light communications using noma: Swarm intelligence meets machine learning[J]. *IEEE Internet of Things Journal*, 2020, 7(10): 10375-10387.
- [71] FETANAT M, STEVENS M, JAIN P, et al. Fully elman neural network: a novel deep recurrent neural network optimized by an improved harris hawks algorithm for classification of pulmonary arterial wedge pressure[J]. *IEEE Transactions on Biomedical Engineering*, 2021, 69(5): 1733-1744.

- [72] XU H, ZHANG G, ZHAO J, et al. Intelligent reflecting surface aided wireless networks: harris hawks optimization for beamforming design[C]//2020 IEEE 6th International Conference on Computer and Communications (ICCC). IEEE, 2020: 200-205.
- [73] VAN STEIN N, BÄCK T. Llamea: A large language model evolutionary algorithm for automatically generating metaheuristics[J]. IEEE Transactions on Evolutionary Computation, 2024, 29(2): 331-345.
- [74] DE ROSA G H, RODER M, PAPA J P, et al. Improving pre-trained weights through metaheuristics fine-tuning[C]//2021 IEEE Symposium Series on Computational Intelligence (SSCI). IEEE, 2021: 1-8.
- [75] ALAZAB M, KHURMA R A, CASTILLO P A, et al. An effective networks intrusion detection approach based on hybrid harris hawks and multi-layer perceptron[J]. Egyptian Informatics Journal, 2024, 25: 100423.
- [76] ISSA A, ALI Y, RASHID T. An efficient hybrid classification approach for covid-19 based on harris hawks optimization and salp swarm optimization[A]. 2022.
- [77] KHATRI I, CHOUDHRY A, RAO A, et al. Influence maximization in social networks using discretized harris' hawks optimization algorithm[J]. Applied Soft Computing, 2023, 149: 111037.
- [78] AZEEM S, JAVED S, NASEER I, et al. A new hybrid pso-hho wrapper based optimization for feature selection[J]. IEEE Access, 2025.
- [79] JAIN M K, GOPALANI D, MEENA Y K. Hybrid cnn-bilstm model with hho feature selection for enhanced fake news detection[J]. Social Network Analysis and Mining, 2025, 15(1): 43.
- [80] LUTHFI A F, HERTENO R, ABADI F, et al. Enhancing software defect prediction: Hho-based wrapper feature selection with ensemble methods[J]. Indonesian Journal of Electronics, Electromedical Engineering, and Medical Informatics, 2025, 7(2): 188-202.
- [81] 陈志鹏. 改进的乌鸦搜索算法及其在特征选择中的研究与应用[D]. 东莞理工学院, 2025.
- [82] 徐粤婷. 改进飞蛾火焰优化算法及其在特征选择问题上的应用[D]. 温州大学, 2020.
- [83] CHERRINGTON M, THABTAH F, LU J, et al. Feature selection: filter methods performance challenges[C]//2019 International Conference on Computer and Information Sciences (ICCIS). IEEE, 2019: 1-4.
- [84] GONG H, LI Y, ZHANG J, et al. A new filter feature selection algorithm for classification task by ensembling pearson correlation coefficient and mutual information[J]. Engineering Applications of Artificial Intelligence, 2024, 131: 107865.

- [85] MASOOD F, MASOOD J, ZAHIR H, et al. Novel approach to evaluate classification algorithms and feature selection filter algorithms using medical data[J]. *Journal of Computational and Cognitive Engineering*, 2023, 2(1): 57-67.
- [86] EL ABOUDI N, BENHLIMA L. Review on wrapper feature selection approaches[C]// 2016 international conference on engineering & MIS (ICEMIS). IEEE, 2016: 1-5.
- [87] 白晓彤. 面向基因表达数据的混合式特征选择方法研究[D]. 吉林师范大学, 2025.
- [88] SONG Y W, WANG J S, QI Y L, et al. Serial filter-wrapper feature selection method with elite guided mutation strategy on cancer gene expression data[J]. *Artificial Intelligence Review*, 2025, 58(4): 111.
- [89] CHEN G, CHEN J. A novel wrapper method for feature selection and its applications[J]. *Neurocomputing*, 2015, 159: 219-226.
- [90] 黄洋. 粒计算视角下嵌入式特征选择方法研究[D]. 哈尔滨工程大学, 2025.
- [91] HAO P, GAO W, HU L. Embedded feature fusion for multi-view multi-label feature selection[J]. *Pattern Recognition*, 2025, 157: 110888.
- [92] LIU H, ZHOU M, LIU Q. An embedded feature selection method for imbalanced data classification[J]. *IEEE/CAA Journal of Automatica Sinica*, 2019, 6(3): 703-715.
- [93] WANG S, TANG J, LIU H. Embedded unsupervised feature selection[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 29. 2015.
- [94] MALDONADO S, LÓPEZ J. Dealing with high-dimensional class-imbalanced datasets: Embedded feature selection for svm classification[J]. *Applied Soft Computing*, 2018, 67: 94-105.
- [95] ZHU Z, ONG Y S, DASH M. Markov blanket-embedded genetic algorithm for gene selection[J]. *Pattern Recognition*, 2007, 40(11): 3236-3248.